



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Inteligencia Artificial

Predicción de Cadenas de Ataque en Infraestructuras Kubernetes mediante Graph Neural Networks

Trabajo fin de estudio presentado por:	Milton Obed Rayo Viana
Tipo de trabajo:	Desarrollo de software
Director/a:	Pedro León Millán
Fecha:	Septiembre de 2026

Resumen

Las herramientas de análisis estático de *Kubernetes* detectan configuraciones inseguras aisladas, pero no si se encadenan en una ruta de ataque viable. El objetivo de este trabajo es identificar automáticamente esas cadenas a partir de manifiestos estáticos, sin acceso a un clúster activo. *kubescan* combina un clasificador *Random Forest* (Capa 1), una red de atención sobre grafos (*Graph Attention Network*, GAT) (Capa 2) y pesos de *ensemble* optimizados por Algoritmo Genético (Capa 3).

El corpus reunido —2.827 manifiestos de cinco fuentes públicas complementarias— y su protocolo de particionado anti-fuga son la contribución metodológica central. Los grafos de clúster derivados incorporan aristas de alcance de privilegio, movimiento lateral, proximidad, espacio de nombres y control de acceso basado en roles (RBAC). El particionado, consciente de grupos y de familias de plantilla, elimina la fuga entre familias casi duplicadas.

La Capa 1 alcanza $F1 \text{ macro} = 0,9946$ y área bajo la curva ROC (AUC) = 0,9986, sin falsos negativos en test. La Capa 2 logra $F1 \text{ macro} = 0,803 \pm 0,137$ y $\text{Precisión}@5 = 0,720 \pm 0,160$ en validación cruzada. Sobre el test independiente (86 grafos, 5 cadenas reales) el sistema alcanza $\text{Precisión}@1 = 1,00$, $\text{Precisión}@3 = 1,00$ y $\text{Precisión}@5 = 0,80$, sin falsos positivos en los tres clústeres limpios del conjunto (tasa de falsos positivos, $FPR_{\text{clean}} = 0 \%$). La restricción de viabilidad estructural es decisiva: sin ella $P@1$ y $P@3$ caen a 0,00 y 0,33. Tres expertos otorgan 88,3 de media en la escala de usabilidad del sistema (SUS), «excelente».

El análisis estático de manifiestos basta, por tanto, para situar las cadenas de ataque en cabeza del ranking. *kubescan* es viable como control preventivo integrable en flujos de integración y entrega continua (CI/CD), antes de que las configuraciones de riesgo lleguen a producción.

Palabras clave: Kubernetes, Graph Neural Networks, Random Forest, cadenas de ataque, infraestructura como código.

Abstract

Static analysis tools for *Kubernetes* detect isolated insecure settings, but not whether they chain into a viable attack path. The objective of this work is to identify such chains automatically from static manifests, without access to a live cluster. *kubescan* combines a Random Forest classifier (Layer 1), a *Graph Attention Network* (GAT) (Layer 2) and ensemble weights optimised by a Genetic Algorithm (Layer 3).

The corpus assembled —2,827 manifests from five complementary public sources— and its anti-leakage partitioning protocol are the central methodological contribution. The cluster graphs derived from it carry edges for privilege-reach, lateral-movement, proximity, namespace, and Role-Based Access Control (RBAC). Partitioning is group- and template-family-aware, which removes the leakage between near-duplicate families.

Layer 1 achieves macro-F1=0.9946 and an area under the ROC curve (AUC)=0.9986, with no false negatives on test. Layer 2 achieves macro-F1=0.803 $\pm$ 0.137 and Precision@5=0.720 $\pm$ 0.160 under cross-validation. On the independent test set (86 graphs, 5 real chains) the system achieves Precision@1=1.00, Precision@3=1.00 and Precision@5=0.80, with no false positives on the three clean clusters of that set (false positive rate, FPR_clean = 0 %). The structural feasibility constraint is decisive: without it P@1 and P@3 fall to 0.00 and 0.33. Three experts award a mean System Usability Scale (SUS) score of 88.3, an “excellent” rating.

Static analysis of manifests therefore suffices to place attack chains at the top of the risk ranking. *kubescan* is viable as a preventive control integrable into Continuous Integration / Continuous Delivery (CI/CD) pipelines, before risky configurations reach production.

Keywords: Kubernetes, Graph Neural Networks, Random Forest, attack chains, infrastructure as code.

Índice de contenidos

Resumen	I
Abstract	II
Índice de figuras	VII
Índice de tablas	VIII
Índice de ecuaciones	IX
1. Introducción	1
1.1. Motivación	1
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	3
2. Contexto y estado del arte	5
2.1. Contexto del problema: seguridad en infraestructuras Kubernetes	5
2.2. Análisis estático de IaC	7
2.3. Aprendizaje automático para detección de vulnerabilidades	8
2.4. Redes neuronales de grafos	11
2.5. GNNs aplicadas a ciberseguridad	12
2.6. Detección de cadenas de ataque y grafos de ataque en Kubernetes	14
2.7. Conclusiones del estado del arte	15
3. Objetivos concretos y metodología de trabajo	17
3.1. Objetivo general	17
3.2. Objetivos específicos	17
3.3. Metodología del trabajo	20
4. Identificación de requisitos	22
	III

4.1.	Requisitos del sistema	22
4.1.1.	Requisitos funcionales	22
4.1.2.	Requisitos no funcionales	24
4.1.3.	Trazabilidad de los requisitos	26
4.2.	Justificación del alcance	26
4.3.	Estrategia de partición y validación de datos	28
4.4.	Métricas de evaluación	29
5.	Descripción de la herramienta software desarrollada	31
5.1.	Arquitectura general del sistema	31
5.2.	Construcción del conjunto de datos	32
5.2.1.	Fuentes de datos	33
5.2.2.	Características extraídas	34
5.3.	Construcción del grafo de clúster	35
5.3.1.	Detección de escape y movimiento lateral	38
5.3.2.	Detección de privilegio RBAC	39
5.4.	Capa 1: Random Forest	39
5.4.1.	Modelo binario	39
5.4.2.	Modelo de severidad	40
5.5.	Capa 2: Graph Attention Network	40
5.5.1.	Arquitectura	40
5.5.2.	Entrenamiento	41
5.5.3.	Aumentación de datos	43
5.6.	Capa 3: Ensemble con Algoritmo Genético	44
5.6.1.	Restricción de viabilidad estructural	45
5.7.	Implementación de kubescan	46
5.8.	Tabla de características del sistema	48
5.9.	Calidad de software y proceso de desarrollo	48
6.	Evaluación	52
6.1.	Línea de base del estado del arte	52
6.1.1.	Capa 1 en contexto	52

6.1.2.	Capa 2 en contexto	53
6.2.	Resultados de la Capa 1: Random Forest	54
6.2.1.	Clasificación binaria	54
6.2.2.	Importancia de características	56
6.2.3.	Modelo de severidad	57
6.3.	Resultados de la Capa 2: GNN	58
6.3.1.	Evolución por fase experimental	59
6.3.2.	Análisis de Precisión@5	61
6.3.3.	Resultados por pliegue (fase final)	62
6.3.4.	Ablación de función de pérdida y criterio de selección	63
6.3.5.	Ablación de arquitectura	65
6.3.6.	Robustez frente a la semilla de entrenamiento	66
6.4.	Resultados de la Capa 3: Ensemble	68
6.5.	Análisis de la clasificación por clases: GNN	71
6.6.	Validación con herramientas de análisis estático	72
6.7.	Métrica global del proceso completo	73
6.8.	Verificación de cumplimiento de requisitos	74
6.8.1.	Requisitos funcionales	74
6.8.2.	Requisitos no funcionales	75
6.9.	Evaluación de usabilidad y aplicabilidad con usuarios expertos	76
6.9.1.	Perfil de los participantes	77
6.9.2.	Éxito por tarea	77
6.9.3.	Usabilidad percibida (SUS)	78
6.9.4.	Aplicabilidad y análisis cualitativo	78
6.9.5.	Amenazas a la validez de la evaluación	79
7.	Conclusiones y trabajo futuro	80
7.1.	Conclusiones	80
7.2.	Consideraciones éticas y uso responsable	84
7.3.	Limitaciones	85
7.3.1.	Amenazas a la validez	89
7.4.	Líneas de trabajo futuro	90

Referencias bibliográficas	93
Anexo A. Código fuente y datos analizados	97
Anexo B. Guía de uso y reproducción	100
B.1. Instalación	100
B.2. Uso de la interfaz de línea de comandos	100
B.2.1. Análisis de un directorio de manifiestos	100
B.2.2. Análisis de un clúster en ejecución	104
B.3. Reproducción del pipeline de investigación	104
Anexo C. Acrónimos y abreviaturas	106

Índice de figuras

Figura 1.	Arquitectura del sistema <i>kubescan</i>	32
Figura 2.	Ejemplo de grafo de clúster Kubernetes con cuatro nodos	37
Figura 3.	Matriz de confusión del Random Forest en el conjunto de test	56
Figura 4.	Importancia de características del clasificador Random Forest	57
Figura 5.	Evolución de F1 macro y Precisión@5 de la Capa 2	61
Figura 6.	Precisión@5 de la ablación de pérdida y selección	64
Figura 7.	Precisión@5 por pliegue con tres semillas de entrenamiento	67
Figura 8.	Efecto de la restricción de viabilidad estructural	70
Figura 9.	Precisión@k del ensemble sobre el conjunto de test	70
Figura 10.	Matriz de confusión del ensemble de pliegues en test	72
Figura 11.	Flujo de ejecución de <i>kubescan scan</i>	102

Índice de tablas

Tabla 1.	Comparativa de algoritmos de ML para clasificación de manifiestos Infrastructure as Code (Infraestructura como Código) (IaC)	11
Tabla 2.	Comparativa de herramientas de seguridad para Kubernetes	15
Tabla 3.	Trazabilidad de requisitos	26
Tabla 4.	Composición del conjunto de datos de manifiestos Kubernetes	33
Tabla 5.	Tipos de aristas en el grafo de clúster	36
Tabla 6.	Opciones de la interfaz de línea de comandos de <i>kubescan</i>	47
Tabla 7.	Características del clasificador Random Forest (Bosque Aleatorio) (RF) — grupo Rahman (1/2)	49
Tabla 8.	Características del clasificador RF — grupos derivado y extendido, y nodo (2/2)	50
Tabla 9.	Resultados del Random Forest — clasificación binaria	55
Tabla 10.	F1 por clase — modelo de severidad (3 clases, test)	58
Tabla 11.	Evolución de resultados de la Capa 2 (GAT, 5-fold CV)	60
Tabla 12.	Resultados por pliegue — Capa 2, fase final	62
Tabla 13.	Ablación de función de pérdida y criterio de selección	64
Tabla 14.	Ablación de arquitectura — Capa 2	66
Tabla 15.	Robustez multi-semilla de la configuración final	67
Tabla 16.	Ablación de componentes del ensemble en el conjunto de test	71
Tabla 17.	Perfil de los participantes expertos	77
Tabla 18.	Tasa de éxito por tarea (3 participantes)	77

Índice de ecuaciones

Ecuación 1.	Actualización de la representación de un nodo en una capa GNN . .	11
Ecuación 2.	Coeficiente de atención en Graph Attention Networks	12
Ecuación 4.	Función de puntuación del ensemble (Capa 3)	31
Ecuación 5.	Cálculo de pesos de clase para el entrenamiento de la GAT	42
Ecuación 6.	Función objetivo (fitness) del Algoritmo Genético	44

1. Introducción

La seguridad de una infraestructura *Kubernetes* queda determinada, en buena medida, antes de que el clúster llegue a existir: son los manifiestos declarativos los que fijan los privilegios de cada carga de trabajo, los montajes que expone al nodo anfitrión y las relaciones de acceso entre recursos. Esa configuración se revisa habitualmente recurso a recurso, comprobando cada manifiesto contra un catálogo de reglas de buenas prácticas. El resultado es una visión fragmentada del riesgo, porque un compromiso real rara vez depende de una única configuración incorrecta y sí de la manera en que varias debilidades menores se encadenan a través de la estructura del clúster.

1.1. Motivación

La adopción masiva de *Kubernetes* como plataforma de orquestación de contenedores ha transformado la manera en que las organizaciones despliegan y gestionan sus aplicaciones. La encuesta anual de 2021 de la Cloud Native Computing Foundation (Fundación de Computación Nativa en la Nube) (CNCF) reporta que el 96 % de las organizaciones utilizan o evalúan *Kubernetes* (Cloud Native Computing Foundation, 2022), y el informe sectorial *State of Kubernetes Security* de Red Hat de 2024 documenta que el 89 % de las organizaciones sufrió al menos un incidente de seguridad relacionado con *Kubernetes* durante el último año (Red Hat, 2024). Sin embargo, esta proliferación ha ampliado considerablemente la superficie de ataque: una sola configuración insegura en un manifiesto YAML Ain't Markup Language (Lenguaje de Serialización de Datos Legible por Humanos) (YAML) puede habilitar la escalada de privilegios desde un contenedor comprometido hasta el nodo anfitrión del clúster o, en casos extremos, hasta la infraestructura subyacente completa (National Security Agency y Cybersecurity and Infrastructure Security Agency, 2022).

Los enfoques de análisis estático tradicionales —herramientas como *Checkov* (Bridgecrew, 2021) o *kube-linter* (StackRox, 2021)— detectan configuraciones incorrectas aisladas en

manifiestos individuales. *Checkov* incorpora además comprobaciones basadas en grafos sobre las dependencias entre recursos, pero se trata de reglas declarativas escritas manualmente: ninguna de estas herramientas dispone de un modelo aprendido de la estructura del clúster ni predice de forma supervisada la existencia de una cadena de ataque. Un único indicador de privilegio en un pod no es suficiente para determinar si existe una cadena de ataque viable; es la combinación de nodos de escape con recursos de movimiento lateral la que habilita rutas de explotación completas, siguiendo la lógica de encadenamiento de etapas del modelo de *kill chain* de Hutchins, Cloppert y Amin (2011); las técnicas concretas de escalada de privilegios en contenedores están catalogadas en el marco MITRE ATT&CK for Containers (MITRE Corporation y Center for Threat-Informed Defense, 2021).

Herramientas más recientes como *KubeHound* (Datadog Security Labs, 2023) e *IceKube* (WithSecure Labs, 2023) abordan este problema construyendo grafos de ataque sobre clústeres activos. Sin embargo, requieren recolectar el estado de un clúster activo mediante acceso de lectura amplio a su servidor API de *Kubernetes*, lo que limita su aplicabilidad como control preventivo en el proceso de CI/CD, conforme al principio conocido como *shift-left security*, que consiste en adelantar los controles de seguridad a las etapas más tempranas del desarrollo. Este trabajo aborda ese vacío: construir un sistema capaz de razonar sobre la *estructura* del clúster a partir de manifiestos YAML estáticos, sin requerir un clúster activo, para identificar automáticamente cadenas de ataque potenciales antes de que sean desplegadas.

1.2. Planteamiento del trabajo

Formalmente, dado un conjunto de manifiestos YAML que describen un clúster *Kubernetes*, el problema consiste en:

1. Clasificar cada manifiesto individual como seguro o mal configurado (Capa 1).
2. Modelar el clúster como un grafo heterogéneo y clasificarlo en una de tres categorías: *clean* (sin misconfiguraciones relevantes), *isolated* (misconfiguraciones sin cadena viable) o *attack_chain* (existe una ruta de escalada de privilegios hasta movimiento lateral) (Capa 2).
3. Combinar las señales de ambas capas, junto con una señal binaria de escape derivada

de las características de nodo, mediante una función de puntuación con pesos optimizados por Algoritmo Genético para maximizar la Precisión@5 —la fracción de clústeres de cadena de ataque en el top-5 del ranking— minimizando falsos positivos, y aplicar una restricción de viabilidad estructural sobre el ranking final (Capa 3).

La capacidad de operar sobre manifiestos YAML estáticos —sin requerir acceso al clúster activo— es un requisito de diseño explícito que diferencia el presente trabajo de las soluciones de grafo de ataque existentes y lo posiciona como un control de seguridad integrable en pipelines CI/CD. En términos generales, el objetivo es diseñar, implementar y evaluar un sistema de detección de cadenas de ataque en *Kubernetes* que complemente los enfoques de análisis estático por manifiesto individual con el contexto estructural del clúster, mediante la combinación de aprendizaje automático clásico y aprendizaje sobre grafos, operando principalmente sobre manifiestos YAML estáticos, si bien incorpora opcionalmente una vía de consulta directa a un clúster activo. Los objetivos específicos que concretan este planteamiento general, junto con la metodología de seis fases seguida para alcanzarlos, se detallan en el Capítulo 3.

1.3. Estructura del trabajo

El trabajo se organiza en siete capítulos. El Capítulo 2 revisa el estado del arte en seguridad de *Kubernetes*, herramientas de análisis estático y grafos de ataque, redes neuronales de grafos y detección de cadenas de ataque; incluye una tabla comparativa de las herramientas más relevantes y un análisis del posicionamiento de *kubescan*. El Capítulo 3 define los objetivos específicos y la metodología de seis fases. El Capítulo 4 identifica y justifica los requisitos funcionales y no funcionales del sistema, delimita su alcance y describe la estrategia de partición de datos y las métricas de evaluación que esos requisitos determinan. El Capítulo 5 describe la herramienta desarrollada: la arquitectura de tres capas, la construcción del dataset y el grafo, el diseño de cada capa, la implementación de *kubescan* como herramienta de línea de comandos, la tabla completa de las 28 características del clasificador y la calidad de software y el proceso de desarrollo seguidos. El Capítulo 6 evalúa el sistema frente a una línea de base del estado del arte, reporta los resultados de cada capa, sintetiza la métrica de proceso completo y verifica el cumplimiento de los requisitos, incluida la evaluación de usabilidad con usuarios

expertos. El Capítulo 7 recoge las conclusiones vinculadas a cada objetivo, las limitaciones, las consideraciones éticas y las líneas de trabajo futuro.

2. Contexto y estado del arte

La detección automática de vulnerabilidades en infraestructuras *Kubernetes* se encuentra en la intersección de cuatro áreas de investigación activa: el análisis de seguridad en infraestructura como código (*Infrastructure as Code*, IaC), el aprendizaje automático aplicado a la ciberseguridad, las redes neuronales de grafos para razonamiento estructural, y la construcción de grafos de ataque para la identificación de rutas de explotación. Cada una de estas áreas aporta una pieza del problema: el análisis estático delimita qué constituye una misconfiguración, el aprendizaje automático permite estimar el riesgo asociado a esos indicadores, las redes neuronales de grafos añaden razonamiento sobre las relaciones entre recursos, y los grafos de ataque definen qué combinaciones de esas relaciones constituyen una ruta de explotación viable. Ninguna de las cuatro líneas ha producido hasta la fecha un sistema que prediga cadenas de ataque a partir de manifiestos estáticos mediante un modelo supervisado, carencia que delimita el espacio en el que se sitúa la contribución de este trabajo.

2.1. Contexto del problema: seguridad en infraestructuras Kubernetes

Kubernetes es la plataforma de orquestación de contenedores dominante en entornos de producción empresariales, con un 96 % de organizaciones que la utilizan o evalúan según la encuesta anual de 2021 de la CNCF (Cloud Native Computing Foundation, 2022). A pesar de su adopción generalizada, la seguridad sigue siendo uno de los principales retos operacionales: el informe *State of Kubernetes Security* de Red Hat 2024 (Red Hat, 2024) revela que el 89 % de las organizaciones sufrió al menos un incidente de seguridad relacionado con *Kubernetes* en el último año, y que el 67 % retrasó despliegues a producción por preocupaciones de seguridad. El 46 % reportó pérdidas de clientes o ingresos directamente atribuibles a incidentes en entornos de contenedores. Entre los riesgos más temidos, las vulnerabilidades representan el 33 % de las preocupaciones de los equipos, mientras que las misconfiguraciones y exposiciones alcanzan el 27 %.

Su modelo declarativo, basado en ficheros YAML que especifican el estado deseado del clúster, ofrece grandes ventajas en reproducibilidad y automatización, pero también introduce una amplia superficie de ataque: un fichero mal configurado desplegado en producción puede conceder privilegios excesivos a un contenedor o exponer secretos en texto plano. La flexibilidad de *Kubernetes* —que permite configurar desde el sistema de ficheros del anfitrión hasta los permisos de red a nivel de pod— implica que el número de vectores de ataque crece proporcionalmente con la riqueza del modelo de configuración. La Agencia de Seguridad Nacional de Estados Unidos (NSA) y la Agencia de Ciberseguridad e Infraestructura (CISA) publicaron en 2022 una guía técnica (National Security Agency y Cybersecurity and Infrastructure Security Agency, 2022) que enumera las misconfiguraciones más críticas: uso de `privileged: true`, montaje del socket de Docker, compartición del espacio de nombres de proceso del anfitrión (*hostPID*), y automontaje de tokens de cuenta de servicio con permisos excesivos. Estos vectores son precisamente los que este trabajo modeliza como nodos de escape en el grafo del clúster.

Los trabajos de BishopFox (Art, 2021) demostraron empíricamente que un único pod con configuración *everything-allowed* puede comprometer el nodo anfitrión en segundos y pivotar lateralmente a través del clúster. La plataforma educativa *Kubernetes Goat* (Akula, 2020) sistematiza más de veinte escenarios de vulnerabilidad con los que se pueden reproducir rutas de explotación completas en un entorno controlado. Ambas constituyen fuentes de manifiestos del presente trabajo; las etiquetas de cadena de ataque no proceden de ellas, sino de la regla explícita de etiquetado descrita en el Capítulo 5.

El marco taxonómico de referencia para los ataques en entornos de contenedores y *Kubernetes* es *MITRE ATT&CK for Containers* (MITRE Corporation y Center for Threat-Informed Defense, 2021), incorporado en la versión 9 de la base de conocimiento ATT&CK. Este marco describe las tácticas y técnicas empleadas por adversarios a nivel de orquestador (*Kubernetes*) y a nivel de contenedor (*Docker*), incluyendo las que este trabajo detecta directamente: escape de contenedor hacia el nodo anfitrión (T1611, *Escape to Host*), movimiento lateral mediante el uso de *tokens* de cuentas de servicio (T1550.001, *Use Alternate Authentication Material: Application Access Token*) y abuso de cuentas válidas (T1078, *Valid Accounts*). La alineación entre las *escape flags* del presente sistema y las técnicas ATT&CK valida que el espacio de detección cubre los

vectores de ataque documentados y más explotados en la industria.

2.2. Análisis estático de IaC

El análisis estático de manifiestos IaC cuenta con una larga trayectoria en la literatura. Rahman et al. (Rahman, Shamim, Bose, y Pandita, 2023) construyeron un conjunto de datos de referencia para manifiestos *Kubernetes* extraídos de repositorios públicos, con 2.039 manifiestos de 92 repositorios etiquetados en 11 categorías de *misconfiguration* identificadas mediante análisis cualitativo y cuantificadas con su herramienta de análisis estático (SLI-KUBE). Su aportación se circunscribe a la construcción del conjunto de datos y a la medición de la densidad de misconfiguraciones mediante reglas estáticas: no incluye ningún modelo de clasificación supervisada entrenado sobre ese corpus, por lo que no ofrece una cifra de rendimiento predictivo con la que contrastar directamente. De ese trabajo, el presente sistema recupera y codifica 1.906 manifiestos de GitHub y GitLab como vectores de características binarias que indican la presencia o ausencia de cada patrón.

Las herramientas industriales actuales más utilizadas son *Checkov* (Bridgecrew, 2021), que verifica más de mil políticas de seguridad predefinidas, y *kube-linter* (StackRox, 2021), especializado en buenas prácticas de *Kubernetes*. *kube-linter* opera al nivel de manifiesto individual, mientras que *Checkov* incorpora además comprobaciones basadas en grafos sobre las dependencias entre recursos (por ejemplo, escalada de privilegios a través de un *RoleBinding*); no obstante, se trata de reglas declarativas escritas manualmente, sin un modelo aprendido de la estructura del clúster ni predicción supervisada de cadenas de ataque. También destaca *Kubescape* (ARMO Ltd., 2021), una plataforma de seguridad de código abierto integrada en la CNCF que combina análisis estático con validación de cumplimiento contra los marcos National Security Agency (Agencia de Seguridad Nacional) (NSA), MITRE ATT&CK y Center for Internet Security (Centro para la Seguridad en Internet) (CIS) *Benchmarks*. Al igual que *Checkov* y *kube-linter*, sin embargo, *Kubescape* evalúa recursos de forma independiente y no construye ningún modelo del clúster como estructura relacional.

La noción de un índice unificado de misconfiguraciones (*unified misconfiguration index*), propuesta por Malul, Meidan, Mimran, Elovici, y Shabtai (2024) en *GenKubeSec*, normaliza y unifica

las etiquetas de múltiples herramientas de análisis basadas en reglas para poder compararlas, un problema afín al de generar un *risk_score* unificado como el de la Capa 1 del presente sistema; la fuente original emplea esa expresión descriptiva sin acuñar una sigla, por lo que la abreviatura UMI que se usa en el resto de este documento es una convención propia. Su propuesta, que incorpora un modelo de lenguaje de gran escala (LLM) para la clasificación, es complementaria a la de este trabajo, aunque opera en el mismo nivel de manifiesto individual. La limitación estructural común a estas herramientas es que ninguna aprende ni predice cadenas de ataque a partir de la estructura del clúster: incluso las comprobaciones de grafo de *Checkov* son reglas fijas sobre dependencias conocidas, no un modelo entrenado. Estas herramientas detectan que un pod tiene `privileged: true`, pero no infieren si ese pod encadena con el acceso de red a los recursos críticos del clúster para formar una ruta de ataque completa. La detección de cadenas de ataque requiere, inevitablemente, razonar sobre la estructura del clúster como un todo.

2.3. Aprendizaje automático para detección de vulnerabilidades

El aprendizaje automático se ha aplicado a la detección de vulnerabilidades en código fuente y configuraciones desde hace más de una década. Los clasificadores basados en *Random Forest* (Breiman, 2001) —que combinan múltiples árboles de decisión mediante *bagging* y selección aleatoria de características— han demostrado resultados robustos en escenarios de alta dimensionalidad y clases desbalanceadas, características típicas de los conjuntos de datos de seguridad; el desequilibrio se aborda además mediante la ponderación de clases que ofrece su implementación en *scikit-learn* (Pedregosa y cols., 2011). En la literatura, el ajuste de hiperparámetros de este tipo de clasificadores suele realizarse mediante búsqueda en rejilla (*grid search*) con validación cruzada estratificada sobre parámetros como `n_estimators` o `min_samples_leaf`. El presente trabajo no realiza tal búsqueda: emplea una única configuración fija de hiperparámetros, escogida para el escenario de clases desbalanceadas y documentada en el Capítulo 5, de modo que los resultados de la Capa 1 no deben interpretarse como el óptimo de un espacio de hiperparámetros explorado.

En el dominio de la detección de intrusiones en red, el conjunto de datos UNSW-NB15 (Moustafa y Slay, 2015) se ha convertido en un referente de evaluación para clasificadores supervi-

sados. Conviene precisar el alcance de esa referencia: el trabajo que lo presenta es un artículo de construcción de conjunto de datos, y su evaluación comparativa se limita a la exactitud y la tasa de falsas alarmas de árboles de decisión, regresión logística, *naïve Bayes*, redes neuronales artificiales y modelos de mezclas esperadas, sin reportar valores de F1 macro ni resultados de *Random Forest*. No constituye, por tanto, una revisión del rendimiento de *Random Forest* sobre ese conjunto ni permite derivar de él un rango de referencia para dicha métrica. El conjunto de manifiestos de este trabajo presenta un desequilibrio de clases moderado (56,3 % seguros vs. 43,7 % mal configurados); el desafío de desequilibrio más severo se concentra en las *flags* de escape individuales, algunas presentes en menos del 1 % de los manifiestos reales. El desequilibrio de clases es un problema generalizado en los conjuntos de datos de seguridad: las misconfiguraciones críticas son rarísimas en repositorios reales, lo que obliga a adoptar estrategias explícitas de compensación. La alternativa más común es asignar pesos de clase inversamente proporcionales a su frecuencia (*class_weight=balanced* en *scikit-learn*), que es la estrategia adoptada en este trabajo (Pedregosa y cols., 2011). Otras alternativas como SMOTE (*Synthetic Minority Over-sampling Technique*) no se consideraron apropiadas dado que las características son binarias, y la interpolación lineal entre muestras binarias puede generar vectores fuera del espacio semántico válido.

Trabajos más recientes han explorado el uso de modelos de lenguaje de gran escala (LLM) para la detección y remediación de misconfiguraciones en *Kubernetes* (Malul y cols., 2024). Si bien los LLMs ofrecen capacidades de razonamiento semántico superiores, requieren recursos computacionales sustancialmente mayores, producen salidas no deterministas y son más opacos que los clasificadores clásicos, lo que dificulta su interpretación en auditorías de seguridad donde la trazabilidad de las reglas de detección es un requisito normativo. Para entornos de producción donde el operador de seguridad debe poder justificar ante una auditoría por qué un clúster fue marcado como de alto riesgo, la interpretabilidad del *Random Forest* —mediante importancia de características y reglas de árbol legibles— representa una ventaja operacional significativa sobre los modelos de caja negra.

La aplicación de técnicas de Machine Learning (Aprendizaje Automático) (ML) a la predicción de vulnerabilidades en software es un enfoque consolidado que supera de forma consistente a los modelos estadísticos clásicos (Jabeen y cols., 2022). Dentro de ese espacio, el *Random*

Forest resulta especialmente adecuado para el problema de la Capa 1 por su comportamiento sobre características binarias de alta dimensión con clases desbalanceadas. Ese comportamiento, unido a sus ventajas de interpretabilidad en auditorías de seguridad, motivó su adopción como componente de Capa 1 de *kubescan*.

La elección de *Random Forest* sobre otros algoritmos clásicos para la clasificación de manifiestos laC responde a tres criterios derivados de la naturaleza de los datos del problema:

1. **Robustez ante datos binarios y escasos.** Las características del presente trabajo son en su mayoría binarias (presencia/ausencia de una misconfiguration), con alta proporción de ceros. Los *Random Forests* manejan este tipo de datos de forma nativa sin requerir normalización, a diferencia de las Máquinas de Vectores Soporte (SVM) o las Redes Neuronales, sensibles a la escala de las características.
2. **Gestión intrínseca del desequilibrio de clases.** El parámetro `class_weight=balanced` de *scikit-learn* implementa una estrategia de ponderación inversamente proporcional a la frecuencia de clase, lo que eleva efectivamente el coste de clasificar erróneamente las muestras de la clase minoritaria (misconfiguraciones críticas) sin modificar la función de pérdida subyacente (Pedregosa y cols., 2011).
3. **Generación de puntuaciones continuas utilizables.** El promedio de los votos del *ensemble* de árboles produce puntuaciones suaves en $[0, 1]$ que pueden utilizarse directamente como características continuas (*risk_scores*) en el grafo de la Capa 2. Un Árbol de Decisión individual concentra su salida en valores próximos a los extremos, al derivarse de la composición de una única hoja, y los *k*-Nearest Neighbours la restringen a múltiplos de $1/k$, de modo que ambos ofrecen un rango efectivo mucho más pobre como señal continua. El requisito que se persigue aquí es la granularidad y el ordenamiento de la puntuación, no su interpretación como probabilidad en sentido frecuentista, que exigiría un procedimiento de calibración explícito no aplicado en este trabajo.

La Tabla 1 resume esta comparativa entre algoritmos candidatos para la Capa 1.

Tabla 1. Comparativa de algoritmos de ML para clasificación de manifiestos IaC

Algoritmo	Sin norma- lización	Desequilibrio	Puntuación continua	Observación
Random Forest	✓	✓	Suave	Adoptado (Capa 1)
Árbol de Decisión	✓	Parcial	Casi binaria	Alta varianza
Support Vector Machine (Máqui- na de Vectores Soporte) (SVM) (RBF)	No	Parcial	Margen sin acotar	Entrenamiento $O(n^2)$ – $O(n^3)$; viable pero menos eficiente
Red Neuronal (MLP)	No	Con pesos	Variable	Sensible a la escala de en- trada
k -NN	No	No	Múltiplos de $1/k$	Costoso en inferencia

Fuente: elaboración propia.

2.4. Redes neuronales de grafos

Las redes neuronales de grafos (*Graph Neural Networks*, GNN) han emergido como la herramienta principal para aprendizaje en datos con estructura relacional (Hamilton, 2020; Zhou y cols., 2020). A diferencia de los clasificadores tabulares clásicos, las GNNs operan directamente sobre la topología del grafo, propagando información entre vecinos mediante operaciones de paso de mensajes (*message passing*). Formalmente, en una capa GNN la representación del nodo v se actualiza como:

$$\mathbf{h}_v^{(l+1)} = \sigma(\mathbf{W}^{(l)} \cdot \text{AGGREGATE}(\{\mathbf{h}_u^{(l)} : u \in \mathcal{N}(v)\}) + \mathbf{b}^{(l)}) \quad (1)$$

donde $\mathcal{N}(v)$ es el conjunto de vecinos de v , $\mathbf{W}^{(l)}$ y $\mathbf{b}^{(l)}$ son parámetros entrenables de la capa l , y σ es una función de activación no lineal. La elección de la función AGGREGATE diferencia las principales arquitecturas.

Las arquitecturas más relevantes para este trabajo son:

Graph Convolutional Networks (GCN) (Kipf y Welling, 2017): implementan AGGREGATE como la media ponderada de los estados de los vecinos normalizada por sus grados. Son eficientes, pero los pesos quedan fijados por la estructura del grafo (los grados de los nodos) y no se aprenden, sin distinción entre tipos de arista.

GraphSAGE (Hamilton, Ying, y Leskovec, 2017): extensión inductiva que permite aplicar el modelo a grafos no vistos durante el entrenamiento, relevante en escenarios donde aparecen nuevos clústeres en producción. La inducción se logra aprendiendo funciones de agregación en lugar de *embeddings* fijos.

Graph Attention Networks (GAT) (Veličković y cols., 2018): sustituyen la normalización fija de GCN por coeficientes de atención aprendidos. Para cada par de nodos (v, u) el coeficiente de atención es:

$$\alpha_{vu} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_v \parallel \mathbf{W}\mathbf{h}_u]))}{\sum_{k \in \mathcal{N}(v)} \exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_v \parallel \mathbf{W}\mathbf{h}_k]))} \quad (2)$$

donde $\mathbf{a}$ es un vector de parámetros de atención y $\parallel$ denota concatenación. Este diseño es especialmente apropiado para grafos de clúster *Kubernetes*, donde una arista de privilegio (*privilege_reach*) debe pesar más que una arista de proximidad de directorio (*dir_proximity*). El modelo *How Powerful are GNNs?* de Xu, Hu, Leskovec, y Jegelka (2019) establece que la capacidad discriminativa de las GNNs está acotada por el test de isomorfismo de Weisfeiler-Lehman, y que la suma de vecinos maximiza el poder expresivo frente a la media o el máximo. En este trabajo se adopta un *pooling* combinado de media y máximo por su robustez ante grafos de tamaño muy variable, aceptando explícitamente ese compromiso de expresividad.

2.5. GNNs aplicadas a ciberseguridad

La aplicación de GNNs a la detección de amenazas es un campo emergente con rápido crecimiento. Bilot, Madhoun, Agha, y Zouaoui (2023) proporcionan una revisión exhaustiva de los

enfoques basados en GNN para la detección de intrusiones en red, organizada en torno a enfoques basados en red (grafos de flujo) y basados en host (grafos de procedencia). Una segunda revisión publicada en *Computers & Security* en 2024 (Zhong, Lin, Zhang, y Xu, 2024) amplía esta taxonomía y documenta un crecimiento sostenido de la investigación en el área en los últimos años.

E-GraphSAGE (Lo, Layeghy, Sarhan, Gallagher, y Portmann, 2022) propone representar flujos de red como grafos de transacción para clasificación de intrusiones en Internet of Things (Internet de las Cosas) (IoT), alcanzando tasas de detección superiores a los clasificadores tabulares clásicos sobre las re-publicaciones en formato NetFlow de los conjuntos de referencia habituales del área (NF-UNSW-NB15-v2, NF-ToN-IoT y NF-BoT-IoT), y no sobre la versión original de UNSW-NB15. La analogía con el presente trabajo es directa: los manifiestos *Kubernetes* son los nodos y las relaciones de privilegio y movimiento lateral son las aristas del grafo de amenaza. Una diferencia clave es que *E-GraphSAGE* modela flujos de tráfico en tiempo real, mientras que este trabajo modela configuraciones declarativas estáticas, lo que permite operar antes del despliegue.

Li, Zeng, Chen, y Liang (2022) construyen grafos de conocimiento de técnicas de ataque a partir de informes de inteligencia de amenazas (CTI) y demuestran que el razonamiento estructural sobre relaciones entre técnicas mejora la predicción de campañas de ataque. Este enfoque comparte con el presente trabajo la intuición central de que el grafo de relaciones entre recursos es más informativo que la suma de sus nodos individuales. Aunque opera sobre conocimiento de ataques pasados (retrospectivo) y no sobre configuraciones declarativas (preventivo), la arquitectura basada en grafos de conocimiento inspiró el diseño de los tipos de arista semánticamente diferenciados del presente sistema. Una limitación reconocida en la literatura es la escasez de conjuntos de datos de grafos etiquetados de alta calidad para ciberseguridad. Tanto Bilot y cols. (2023) como Zhong y cols. (2024) señalan la escasez de conjuntos de datos etiquetados y de benchmarks estandarizados entre los principales obstáculos para el avance del área, lo que refuerza la contribución del presente trabajo al generar un conjunto de datos original de 599 grafos de clúster (1.154 tras aumentación de datos) con etiquetas de cadena de ataque.

2.6. Detección de cadenas de ataque y grafos de ataque en Kubernetes

La noción de cadena de ataque (*kill chain*) fue formalizada originalmente por Hutchins y cols. (2011) para describir las fases secuenciales de una intrusión avanzada: reconocimiento, weaponización, entrega, explotación, instalación, comando y control, y acción. En el contexto de *Kubernetes*, esta cadena se concreta de forma más compacta: requiere como mínimo (1) un pod con capacidad de escape al anfitrión (*TRUE_HOST_PID*, *privileged: true*, *hostPath* montado, etc.) y (2) un mecanismo de movimiento lateral hacia otros recursos del clúster (token de cuenta de servicio con permisos excesivos, montaje de secretos en el manifiesto, etc.). En los últimos años han surgido dos herramientas de código abierto que abordan la detección de rutas de ataque en *Kubernetes* mediante grafos: *KubeHound* (Datadog Security Labs, 2023) e *IceKube* (WithSecure Labs, 2023).

KubeHound (Datadog, 2023) construye un grafo de ataque del clúster a partir de la consulta directa al servidor Application Programming Interface (Interfaz de Programación de Aplicaciones) (API) de *Kubernetes*, almacena el resultado en JanusGraph y permite explorar las rutas de ataque más cortas mediante el lenguaje de consulta Gremlin. El proyecto fue motivado por la misma intuición que subyace al presente trabajo, formulada por John Lambert y citada en su documentación: «*los defensores piensan en listas, los atacantes piensan en grafos*» (Datadog Security Labs, 2023). KubeHound cubre un amplio conjunto de ataques y ha sido adoptado por equipos de seguridad en producción.

IceKube (WithSecure Labs, 2023) sigue un enfoque análogo, basado en Neo4j, y permite definir rutas de ataque mediante consultas Cypher. Modela un amplio conjunto de técnicas de ataque como relaciones en el grafo y puede encontrar rutas desde cualquier identidad de bajo privilegio hasta *cluster-admin*. La diferencia fundamental entre estas herramientas y *kubescan* es de paradigma: KubeHound e IceKube operan sobre un **clúster activo**, requiriendo acceso con privilegios elevados a `kubectl`. *kubescan*, en cambio, opera sobre **manifiestos YAML estáticos** antes del despliegue, integrándose en el pipeline CI/CD como un control de seguridad *shift-left*. Además, ambas herramientas utilizan búsqueda de rutas mediante consultas ad-hoc en bases de datos de grafos, sin componente de aprendizaje automático supervisado; *kubescan* es el primer sistema, según la revisión bibliográfica no sistemática realizada en este trabajo, que

combina análisis estático de manifiestos con GNNs para la predicción de cadenas de ataque como tarea de clasificación supervisada.

2.7. Conclusiones del estado del arte

El análisis de la literatura permite identificar tres carencias fundamentales que motivan el presente trabajo. En primer lugar, las herramientas de análisis estático existentes (Checkov, kube-linter, Kubescape) no aprenden ni predicen cadenas de ataque a partir de la estructura del clúster; aunque Checkov incorpora comprobaciones de grafo basadas en reglas declarativas sobre dependencias entre recursos, ninguna emplea un modelo supervisado que razone sobre las relaciones que habilitan dichas cadenas. En segundo lugar, los conjuntos de datos de referencia para seguridad de *Kubernetes* son escasos, de pequeño tamaño y desequilibrados hacia las clases de riesgo bajo, lo que dificulta el entrenamiento de clasificadores de clúster: el análisis del corpus de manifiestos reales recopilado en este trabajo (Capítulo 5) confirma que `TRUE_HOST_PID` —la flag de escape más peligrosa— aparece en sólo el 0,3 % de las filas antes de incorporar fuentes especializadas. En tercer lugar, las herramientas de grafo de ataque más avanzadas (KubeHound, IceKube) requieren un clúster activo, lo que impide su uso como control preventivo en el pipeline CI/CD.

La Tabla 2 resume el posicionamiento de *kubescan* frente a las principales herramientas del estado del arte.

Tabla 2. Comparativa de herramientas de seguridad para Kubernetes

Herramienta	Análisis estático	Requiere clúster	Grafos	ML supervisado
Checkov (Bridgecrew, 2021)	✓	No	Parcial	No
kube-linter (StackRox, 2021)	✓	No	No	No
Kubescape (ARMO Ltd., 2021)	✓	Opcional	No	No
KubeHound (Datadog Security Labs, 2023)	No	Sí	✓	No
IceKube (WithSecure Labs, 2023)	No	Sí	✓	No
kubescan	✓	No	✓	✓

Fuente: elaboración propia.

El sistema *kubescan* presentado en este trabajo responde a las tres carencias identificadas: adopta una arquitectura de grafo heterogéneo con tipos de arista semánticamente significativos para el dominio *Kubernetes*, combina el análisis estático (Capa 1) con el razonamiento estructural (Capa 2) en un *ensemble* optimizado (Capa 3), y contribuye un conjunto de datos de 599 grafos de clúster originales con etiquetas de cadena de ataque derivadas de reglas de seguridad explícitas y auditables. Al operar sobre manifiestos YAML sin requerir acceso al clúster, *kubescan* se posiciona como un control preventivo integrable en pipelines CI/CD, complementario a —y no sustituto de— las herramientas de análisis de clúster activo como KubeHound. Los capítulos siguientes describen en detalle los objetivos específicos, el diseño e implementación del sistema y la evaluación experimental de cada una de sus tres capas.

3. Objetivos concretos y metodología de trabajo

Este capítulo define los objetivos del trabajo y describe la metodología seguida para alcanzarlos. En primer lugar se formula el objetivo general y los objetivos específicos; los de naturaleza cuantificable incorporan criterios de éxito medibles. A continuación se describen las seis etapas del proceso de trabajo que estructuran el resto del documento. Estas etapas son independientes de las fases experimentales de entrenamiento de la Capa 2 numeradas en el Capítulo 6, que responden a una progresión metodológica distinta y no guardan correspondencia uno a uno con ellas.

3.1. Objetivo general

Diseñar, implementar y evaluar un sistema automático de predicción de cadenas de ataque en infraestructuras *Kubernetes* que complemente los enfoques de análisis estático por manifiesto individual con el contexto estructural del clúster, mediante la combinación de un clasificador de manifiestos individuales (*Random Forest*) con una red neuronal de grafos (*Graph Attention Network*) y optimización de ensemble mediante Algoritmo Genético. El sistema opera principalmente sobre manifiestos YAML estáticos, sin requerir acceso a un clúster activo, si bien incorpora opcionalmente una vía de consulta directa al clúster (OE6). Los objetivos específicos que concretan este objetivo general, numerados OE1 a OE6, se detallan a continuación.

3.2. Objetivos específicos

Los criterios de éxito de los objetivos específicos se expresan mediante tres métricas —F1 macro, Precisión@5 y FPR_clean— cuya definición formal y justificación frente a alternativas de uso más extendido se recogen en la Sección 4.4. Los umbrales numéricos asociados a esos criterios son criterios de diseño adoptados en este trabajo, no cotas tomadas de una referencia externa. Cada objetivo indica, junto a su criterio, la sección que aporta la evidencia de cumplimiento.

- OE1.** Construir un conjunto de datos de manifiestos *Kubernetes* etiquetados que combine múltiples fuentes públicas, contenga al menos 2.000 manifiestos, y alcance una cobertura mínima del 2 % en la bandera de escape `TRUE_HOST_PID`, superando el 0,3 % de los repositorios reales no aumentados. Ambas cifras son criterios de diseño fijados en este trabajo: el mínimo de 2.000 manifiestos responde al tamaño necesario para sostener una validación cruzada de 5 pliegues manteniendo representación de la clase minoritaria en cada partición, y el suelo del 2 % se estableció para garantizar un número suficiente de manifiestos con capacidad de escape, dado que la regla de etiquetado de grafos sólo marca un clúster como *attack_chain* cuando existe una ruta de escalada de privilegios que enlaza un nodo con bandera de escape activa con un nodo de movimiento lateral. Con la cobertura del 0,3 % observada en los repositorios reales no aumentados esa regla apenas llega a activarse, de modo que la clase minoritaria quedaría sin ejemplos suficientes para entrenar la Capa 2. La composición final del conjunto y la cobertura alcanzada se detallan en la Sección 5.2.
- OE2.** Desarrollar una Capa 1 de clasificación de manifiestos individuales basada en *Random Forest* con F1 macro superior a 0,85, que produzca *risk scores* continuos en el rango [0,1] para usar como características de nodo en la Capa 2. El umbral de 0,85 se adopta como criterio de diseño propio de este trabajo, no derivado de una referencia externa: la literatura de detección de intrusiones sobre conjuntos comparables no reporta rangos de F1 macro para *Random Forest* que puedan trasladarse a este dominio (Sección 2.3). La Sección 6.2 sitúa además el resultado obtenido frente a una línea de base trivial calculada sobre el propio corpus, que constituye la comparación informativa.
- OE3.** Diseñar un esquema de grafo de clúster con tipos de arista semánticamente significativos para el dominio *Kubernetes*: proximidad de directorio, alcance de privilegio, movimiento lateral mediante cuenta de servicio, co-espacio de nombres semántico y escalada RBAC. El criterio de éxito se formula a nivel de arquitectura: la configuración adoptada —GAT con *embedding* de tipos de arista— debe igualar o superar en F1 macro y Precisión@5 a una GCN sin tipado de arista bajo idéntico protocolo de evaluación. Este contraste varía simultáneamente el mecanismo de agregación (atención frente a convolución) y la presencia de tipado de arista, por lo que un resultado favorable acredita la configuración

completa pero no permite atribuir la ventaja al esquema de tipos de arista por separado. Aislar esa contribución exigiría una tercera rama de ablación —GAT sin tipos de arista— que no forma parte del conjunto de configuraciones entrenadas en este trabajo y queda como línea de trabajo futuro (Capítulo 7). La evidencia experimental correspondiente se recoge en la Tabla 14.

- OE4.** Desarrollar una Capa 2 de clasificación de clústeres basada en GAT que alcance Precisión@5 superior a 0,70, medida como media de la validación cruzada de 5 pliegues sobre el modelo desplegado con la semilla documentada. El umbral de 0,70 es un criterio de diseño propio de este trabajo y no una cota externa: con $k = 5$ equivale a que, en promedio, entre tres y cuatro de los cinco clústeres priorizados sean cadenas de ataque reales, de forma que la mayor parte del esfuerzo de revisión manual recaiga sobre hallazgos verdaderos. El criterio se evalúa sobre esa configuración concreta y admite, por tanto, resultado negativo si la media de sus pliegues queda por debajo del umbral. De forma complementaria —y sin formar parte del criterio— se reporta la dispersión entre semillas de entrenamiento, cuya media puede situarse por debajo de 0,70 sin invalidar el objetivo; la Sección 6.3.6 la cuantifica y el Capítulo 7 discute su alcance. El resultado del modelo desplegado se reporta en la Sección 6.3.
- OE5.** Implementar una Capa 3 que optimice mediante Algoritmo Genético una función objetivo combinada de Precisión@5 y falsos positivos de clústeres limpios sobre las predicciones *out-of-fold* de la validación cruzada, con criterios de éxito sobre el conjunto de test reservado: FPR_clean = 0 y Precisión@5 no inferior a la del mejor componente individual del *ensemble*. La verificación de ambos criterios se aporta en la Sección 6.4.
- OE6.** Empaquetar el sistema completo como una herramienta de línea de comandos (*kubescan*) con soporte para análisis de directorios locales y, opcionalmente, consulta directa al API de *Kubernetes* mediante *kubectf*; instalable mediante un único `pip install` en entornos Python 3.10 o superior, con verificación efectiva sobre las versiones 3.10 y 3.11. La evaluación funcional y de instalabilidad se documenta en la Sección 6.8 y la evaluación con usuarios expertos en la Sección 6.9.

La correspondencia entre estos objetivos y los requisitos que los operacionalizan se recoge en la Tabla 3 del Capítulo 4, que asocia cada requisito con la sección de diseño que lo materializa y con

la sección de evaluación que aporta su evidencia. El Capítulo 7 cierra el ciclo enunciando, para cada objetivo específico, la conclusión que lo responde. Ambos elementos permiten recorrer la cadena objetivo–requisito–diseño–evidencia en los dos sentidos.

3.3. Metodología del trabajo

El trabajo sigue un proceso iterativo de seis etapas definido específicamente para este proyecto, sin adoptar ninguna metodología estandarizada de referencia, que articula las actividades propias del desarrollo de *software* (diseño, implementación y prueba) con las del proceso de ciencia de datos (adquisición, preparación, modelado y evaluación). La especificación de requisitos antecede a las seis etapas y se documenta de forma independiente en el Capítulo 4, donde se fijan los requisitos funcionales y no funcionales junto con sus criterios de aceptación. Las etapas se enumeran a continuación en el orden en que se ejecutaron:

Etapas 1 — Adquisición de datos. Descarga y normalización de manifiestos *Kubernetes* de cinco fuentes públicas complementarias (agrupadas en cuatro categorías): el conjunto de datos de Rahman et al. (Rahman y cols., 2023) (repositorios reales etiquetados), BishopFox BadPods (Art, 2021) (pods intencionadamente vulnerables), *Kubernetes Goat* (Akula, 2020) (escenarios de vulnerabilidad) y repositorios de seguridad adicionales (CTFs, laboratorios y *fixtures*). El criterio de inclusión de repositorios adicionales fue la presencia de al menos una bandera de escape activa (HOSTPATH_MOUNT, TRUE_HOST_PID, etc.) en al menos un manifiesto del directorio. Este criterio de selección se adoptó porque los directorios sin ninguna bandera de escape activa no pueden originar clústeres de la clase *attack_chain* bajo la regla de etiquetado empleada, de modo que su incorporación aumentaría el volumen del conjunto sin aportar ejemplos de la clase minoritaria que la Capa 2 debe aprender a discriminar. La contrapartida es un sesgo de muestreo que se documenta como decisión de selección deliberada: los 779 manifiestos incorporados por esta vía sobre-representan configuraciones vulnerables respecto de la distribución esperable en un clúster de producción, por lo que las tasas de prevalencia del corpus no admiten lectura como estimaciones poblacionales. Las fuentes de repositorios reales se incorporaron sin aplicar este filtro, lo que acota el sesgo a una fracción identificable del conjunto.

Etapas 2 — Extracción de características y construcción del grafo. Extracción de 28 caracte-

rísticas por manifiesto (25 indicadores binarios y 3 agregados derivados) mediante análisis estático multi-herramienta (Sección 5.8) y construcción del grafo de clúster con cinco tipos de arista (Tabla 5). En esta etapa se realizó también la validación de cobertura de la bandera `HOSTPATH_MOUNT`, documentada en la Sección 5.2.

Etapas 3 — Entrenamiento de la Capa 1. Entrenamiento de un clasificador *Random Forest* mediante validación cruzada de 5 pliegues para predecir la presencia de misconfiguraciones individuales y generar *risk scores* continuos en el rango $[0,1]$, con los hiperparámetros fijos detallados en la Sección 5.4.

Etapas 4 — Entrenamiento de la Capa 2. Entrenamiento de una GAT de 3 capas con agrupamiento de grafos (*graph pooling*) y validación cruzada estratificada de 5 pliegues consciente de grupos y de familias de plantilla: las variantes aumentadas siguen a su grafo base y las familias de plantilla con etiquetas mixtas (p. ej. `badpods_*`) se asignan como unidades atómicas a una única partición, nunca repartidas entre pliegues. La aumentación de datos se aplica sobre los grafos de entrenamiento para mitigar la escasez de ejemplos de cadena de ataque, y el *checkpoint* de cada pliegue se selecciona por Precisión@5 de validación.

Etapas 5 — Optimización de ensemble y evaluación. Optimización de los pesos del ensemble de tres componentes (RF, GNN, señal de escape) mediante Algoritmo Genético sobre las predicciones *out-of-fold* de la validación cruzada de la Capa 2, aplicación de una restricción de viabilidad estructural en el *ranking* final (un grafo de un solo nodo no puede albergar una cadena de ataque multi-salto), y evaluación final sobre el conjunto de test reservado desde el inicio y no utilizado en ninguna etapa de entrenamiento ni selección de hiperparámetros.

Etapas 6 — Empaquetado y evaluación funcional y de usabilidad. Empaquetado del sistema como herramienta de línea de comandos instalable (*kubescan*), evaluación funcional de rendimiento e integración (latencia, formatos de salida, resolución de *checkpoints*) y estudio de usabilidad y aplicabilidad con usuarios expertos mediante el cuestionario SUS y un conjunto de tareas guiadas; los protocolos y resultados de esta etapa se detallan en el Capítulo 6.

4. Identificación de requisitos

Este capítulo identifica y justifica los requisitos que condicionaron el diseño de *kubescan*. Los requisitos funcionales y no funcionales se derivan del análisis de vectores de ataque documentado en el estado del arte y de las limitaciones detectadas en las herramientas existentes. Delimitan además el alcance del sistema: qué analiza, sobre qué capas se apoya y qué queda fuera de sus objetivos. El capítulo cierra con dos estudios previos que determinaron directamente el diseño de la herramienta: la estrategia de partición y validación de datos, y las métricas empleadas para evaluarla.

4.1. Requisitos del sistema

El diseño de *kubescan* parte de un análisis de requisitos derivado tanto de las limitaciones identificadas en el estado del arte (Sección 2.7) como de los vectores de ataque documentados por la NSA y la Cybersecurity and Infrastructure Security Agency (Agencia de Ciberseguridad y Seguridad de Infraestructuras) (CISA) (National Security Agency y Cybersecurity and Infrastructure Security Agency, 2022). Este análisis se traduce en dos conjuntos de requisitos: funcionales, que definen las capacidades que el sistema debe ofrecer, y no funcionales, que acotan sus propiedades de calidad. Ambos conjuntos se detallan a continuación, junto con la justificación concreta de cada uno.

4.1.1. Requisitos funcionales

RF-1 — Detección de misconfiguraciones individuales. El sistema debe cumplir dos obligaciones separables sobre cada manifiesto YAML. La primera es clasificarlo como seguro o *misconfigured*. La segunda es producir un índice de severidad en tres niveles (limpio, bajo – medio, alto – crítico) que ordene las misconfiguraciones detectadas por gravedad. *Criterio de aceptación:* ambas obligaciones se consideran satisfechas cuando cada una de las dos clasificaciones alcanza F1 macro superior a 0,85 sobre el conjunto de test re-

servado, umbral adoptado de OE2 (Capítulo 3) y aplicado también al índice de severidad por tratarse del mismo clasificador sobre el mismo corpus. *Justificación:* las herramientas de análisis estático existentes (*Checkov*, *kube-linter*) ya cubren esta capacidad a nivel de manifiesto individual (Sección 2.2); el sistema debe igualarla como condición previa a razonar sobre la estructura del clúster, y el índice de severidad aporta priorización que las herramientas de reglas fijas no ofrecen.

RF-2 — Detección de cadenas de ataque. El sistema debe clasificar un conjunto de manifiestos que describe un clúster en una de tres categorías: *clean*, *isolated* (misconfiguraciones sin cadena viable) o *attack_chain* (ruta de escalada de privilegios hasta movimiento lateral). *Criterio de aceptación:* toda ejecución debe emitir exactamente una de esas tres categorías por clúster analizado, expuesta en la salida JSON, y las cadenas de ataque del conjunto de test reservado deben quedar situadas en las primeras posiciones del *ranking* de riesgo con arreglo al umbral fijado en RF-5. La proporción de cadenas clasificadas correctamente por *argmax* se reporta como métrica descriptiva del comportamiento del modelo y no constituye por sí sola condición de aceptación, dado que el caso de uso operativo del sistema es la priorización y no el etiquetado exacto. *Justificación:* es la carencia central identificada en el estado del arte (Sección 2.7): ninguna herramienta de análisis estático por manifiesto individual emplea un modelo supervisado que razone sobre las relaciones entre recursos que habilitan una cadena, y las comprobaciones de grafo basadas en reglas declarativas que incorpora *Checkov* se limitan a dependencias conocidas de antemano.

RF-3 — Interfaz de línea de comandos. El sistema debe exponer un comando `kubescan scan <dir>` para análisis de directorios locales y un comando `kubescan live` para análisis de clústeres activos mediante *kubectrl*. *Justificación:* un control de seguridad solo es adoptable en la práctica si se integra en los flujos de trabajo existentes de un equipo de seguridad o de CI/CD; una interfaz de línea de comandos es el punto de integración mínimo común a ambos.

RF-4 — Formatos de salida. El sistema debe producir informes en formato texto legible y en formato JSON estructurado para integración con herramientas externas. *Justificación:* el formato texto sirve a la revisión manual de un operador, mientras que el formato JSON

permite el consumo automatizado del veredicto por otras herramientas del *pipeline* de CI/CD.

RF-5 — Priorización de riesgos. El sistema debe producir una clasificación ordenada de clústeres por puntuación de riesgo, de modo que las cadenas de ataque reales queden situadas en las primeras posiciones. *Criterio de aceptación:* Precisión@5 superior a 0,70 sobre el *ranking* del sistema desplegado en el conjunto de test reservado. *Alcance del umbral:* la cifra de 0,70 se adopta de OE4 (Capítulo 3), donde se define como media de validación cruzada de 5 pliegues de la Capa 2; el presente requisito la traslada al *ranking* del sistema completo, de manera que ambas medidas comparten umbral pero no protocolo de cálculo. *Precisión estadística:* el tamaño del conjunto de test reservado (86 grafos, 5 cadenas) hace que el intervalo de confianza *bootstrap* al 95 % de la Precisión@5 abarque [0,60, 1,00] y por tanto contenga el propio umbral, de modo que la superación del criterio debe leerse como consistente con el objetivo de diseño y no como una garantía estadística. *Justificación:* un equipo de seguridad revisa manualmente un número reducido de alertas por jornada; un *ranking* que sitúe las cadenas reales en las primeras posiciones hace viable esa revisión sobre un volumen de clústeres que de otro modo sería inabarcable.

4.1.2. Requisitos no funcionales

RNF-1 — Trazabilidad. Todas las reglas de detección de nodos de escape y movimiento lateral deben ser explícitas, auditables y derivadas de fuentes normativas documentadas (Art, 2021; National Security Agency y Cybersecurity and Infrastructure Security Agency, 2022). *Criterio de aceptación:* cada veredicto debe poder rastrearse a las banderas concretas que lo originan, expuestas en la salida JSON junto a la identificación de los nodos con capacidad de escape, y cada regla debe remitir a una fuente normativa citable. *Justificación:* un sistema que informa decisiones de seguridad debe permitir que su veredicto sea auditado y cuestionado; basar cada regla en una fuente pública evita además introducir vectores de ataque no documentados.

RNF-2 — Reproducibilidad. Los modelos entrenados deben almacenarse como *checkpoints* que el paquete pueda localizar sin intervención del usuario y que se distribuyan junto al

repositorio del proyecto, de forma que el análisis sea idempotente dado el mismo directorio de entrada. *Criterio de aceptación:* el requisito se descompone en dos condiciones comprobables por separado. La primera es de disponibilidad: los pesos deben resolverse mediante la cadena documentada de resolución de *checkpoints* —opción explícita de línea de comandos, variable de entorno y ubicación por defecto dentro del paquete— y quedar publicados en el repositorio distribuido, sin descarga adicional por parte del usuario. La segunda es de determinismo: dos ejecuciones consecutivas sobre el mismo directorio de manifiestos y el mismo conjunto de pesos deben producir informes JSON idénticos. *Justificación:* un control de seguridad con salidas no deterministas no es fiable como *gate* de CI/CD, donde el mismo manifiesto debe producir siempre el mismo veredicto.

RNF-3 — Instalabilidad. El sistema debe ser instalable mediante `pip install -e kubescan/` sin dependencias de compiladores externos. *Criterio de aceptación:* la instalación debe completarse sin error en intérpretes Python 3.10 o superior, cota declarada en OE6 (Capítulo 3) y en los metadatos de empaquetado, resolviendo todas las dependencias sin invocar un compilador del sistema. *Justificación:* reduce la fricción de adopción por un equipo de seguridad que no necesariamente dispone de un entorno de compilación preparado para dependencias nativas.

RNF-4 — Latencia. El análisis de un clúster de hasta 500 manifiestos debe completarse en menos de 60 segundos en hardware de gama media (CPU). *Criterio de aceptación:* la cota de 500 manifiestos se formula como límite de diseño y no como tamaño de un caso de prueba disponible, ya que el mayor clúster del corpus recopilado no alcanza esa dimensión. La verificación consiste, por tanto, en medir el tiempo de análisis sobre clústeres de tamaño creciente y comprobar que el coste por manifiesto observado mantiene el tiempo proyectado a 500 manifiestos por debajo del límite de 60 segundos. *Justificación:* un tiempo de análisis del orden de segundos es condición necesaria para que el sistema pueda operar como control preventivo dentro de un *pipeline* de CI/CD sin introducir un cuello de botella perceptible.

4.1.3. Trazabilidad de los requisitos

Cada requisito se materializa en una decisión de diseño concreta y se contrasta después con una evidencia experimental u operacional determinada. La Tabla 3 recoge esa correspondencia, indicando para cada identificador la sección del Capítulo 5 que describe el componente encargado de satisfacerlo y la sección del Capítulo 6 que aporta la evidencia de su cumplimiento. Los requisitos que no admiten una métrica predictiva dedicada, como los de interfaz, formatos de salida y propiedades no funcionales, se concentran en la verificación operacional de la Sección 6.8.

Tabla 3. Trazabilidad de requisitos

ID	Requisito	Diseño	Verificación
RF-1	Misconfiguraciones individuales	5.4	6.2
RF-2	Cadenas de ataque	5.5	6.3
RF-3	Interfaz de línea de comandos	5.7	6.8
RF-4	Formatos de salida	5.7	6.8
RF-5	Priorización de riesgos	5.6	6.7
RNF-1	Trazabilidad	5.8	6.8
RNF-2	Reproducibilidad	5.7	6.8
RNF-3	Instalabilidad	5.7	6.8
RNF-4	Latencia	5.7	6.8

Fuente: elaboración propia.

El índice de severidad exigido por RF-1 se verifica de forma diferenciada respecto de la clasificación binaria, mediante los resultados por clase de la Tabla 10. La restricción de viabilidad estructural que condiciona el *ranking* evaluado en RF-5 se describe en la Sección 5.6.1 y su efecto se cuantifica en la Sección 6.4.

4.2. Justificación del alcance

El sistema opera principalmente sobre manifiestos YAML estáticos, sin requerir acceso a un clúster activo, aunque incorpora opcionalmente una vía de consulta directa al clúster mediante

`kubescan live`. La elección del análisis estático como vía principal responde al principio *shift-left security*: detectar una cadena de ataque antes del despliegue evita el coste de remediarla en producción, mientras que las herramientas de grafo de ataque sobre clúster activo (*KubeHound* (Datadog Security Labs, 2023), *IceKube* (WithSecure Labs, 2023)) solo pueden operar *a posteriori* del despliegue y requieren acceso con privilegios elevados a `kubectl` sobre un clúster ya en ejecución. La vía de consulta directa se mantiene como capacidad complementaria para auditorías puntuales sobre clústeres ya desplegados, no como sustituto de la vía preventiva.

La arquitectura de tres capas responde a una separación de responsabilidades entre dos niveles de análisis y su combinación: la Capa 1 evalúa cada manifiesto de forma aislada (RF-1), la Capa 2 razona sobre la estructura relacional del clúster que ningún manifiesto individual expone por sí solo (RF-2), y la Capa 3 combina ambas señales en un único veredicto priorizable (RF-5). Ninguna capa por sí sola satisface el conjunto completo de requisitos funcionales: un clasificador de manifiesto individual no puede expresar una relación entre dos recursos, y un modelo de grafo sin las características de nodo de la Capa 1 pierde la señal de riesgo específica de cada manifiesto. La elección de *Random Forest* para la Capa 1 está además condicionada por tres propiedades que la Tabla 1 contrasta entre algoritmos candidatos: su independencia respecto de la normalización de escala de las entradas, su tolerancia al desequilibrio de clases y la granularidad de la puntuación continua que produce, requisito este último derivado de que dicha salida se emplea como característica de nodo en la Capa 2.

A las tres capas se añade una cuarta componente arquitectónica: la restricción de viabilidad estructural descrita en la Sección 5.6.1, que excluye del *ranking* de riesgo aquellos clústeres cuya topología no puede albergar una cadena de ataque, como los compuestos por un único recurso. Su inclusión no responde a una preferencia de diseño sino a una necesidad verificada empíricamente: sin ella, la Precisión@1 sobre el conjunto de test reservado cae a 0,00 y la Precisión@5 a 0,60, valor este último situado por debajo del umbral que el propio RF-5 fija como criterio de aceptación. La restricción actúa así como condición previa de admisibilidad al *ranking*, complementaria a las señales aprendidas por los tres modelos y no sustitutiva de ninguna de ellas.

Quedan explícitamente fuera del alcance del sistema: la explotación activa de las cadenas de ataque detectadas (el sistema identifica rutas potenciales, no las verifica mediante ataque con-

trolado); la remediación automática de las misconfiguraciones encontradas; y el análisis de vulnerabilidades a nivel de imagen de contenedor (*CVE scanning*), cubierto por herramientas especializadas de escaneo de imágenes y complementario, no sustitutivo, del análisis estructural que aporta *kubescan*.

4.3. Estrategia de partición y validación de datos

La estrategia de partición de datos difiere entre la Capa 1 (datos tabulares) y la Capa 2 (datos de grafos), dado que sus tamaños y distribuciones son distintos. Esta estrategia condiciona directamente la comprobabilidad de RF-1 y RF-2, cuyos criterios de aceptación se formulan sobre un conjunto de test reservado, y de RF-5, cuyo umbral de Precisión@5 se mide sobre el *ranking* producido para ese mismo conjunto. El tamaño final de cada partición depende del proceso de adquisición y construcción descrito en las Secciones 5.2 y 5.3 del Capítulo 5.

Para la Capa 1, el conjunto de manifiestos se divide en un conjunto de entrenamiento (80 %) y un conjunto de test (20 %), con estratificación por la variable objetivo para mantener la proporción de clases en ambos subconjuntos. La validación cruzada de 5 pliegues aplicada sobre el corpus tabular constituye un protocolo de estimación del rendimiento esperado, no un procedimiento de búsqueda de hiperparámetros: la configuración del clasificador es fija y se documenta en la Sección 5.4, sin que intervenga ninguna exploración de rejilla ni muestreo aleatorio del espacio de configuraciones. Al no existir búsqueda de hiperparámetros, ninguna decisión de modelado queda condicionada por el rendimiento observado, lo que preserva la validez del conjunto de test como medida final del criterio de aceptación de RF-1.

Ambos protocolos difieren, no obstante, en el corpus sobre el que operan, y esa diferencia debe explicitarse para interpretar correctamente los resultados de la Capa 1. La validación cruzada de 5 pliegues se ejecuta sobre la totalidad del corpus tabular, es decir, sobre las mismas filas que después integran el conjunto de test, mientras que la columna de test procede del modelo entrenado únicamente sobre el 80 % de entrenamiento. En consecuencia, la cifra de validación cruzada no constituye una estimación sobre datos completamente ajenos al ajuste y debe leerse como indicador de estabilidad del rendimiento entre particiones del corpus; la única estimación sobre datos retenidos es la de la columna de test, que es la que sustenta la

verificación de RF-1.

Para la Capa 2 se reserva desde el inicio una partición de test de clústeres originales, y el resto se evalúa mediante validación cruzada estratificada de 5 pliegues, con estratificación por etiqueta de clúster (*clean*, *isolated*, *attack_chain*) y particionado consciente de grupos y de familias de plantilla, cuyo procedimiento detalla la Sección 5.5.3. La partición global reserva 815 grafos para entrenamiento, 88 para validación y 86 para test, mientras que el conjunto sobre el que operan los pliegues de validación cruzada comprende 513 clústeres originales. La validación cruzada complementa al conjunto de test reservado porque es la estrategia estándar para conjuntos de grafos pequeños (Hamilton, 2020): con pocas muestras de la clase minoritaria, una única partición de validación no sería representativa por sí sola, de modo que el criterio de aceptación de RF-2 requiere ambas evidencias.

4.4. Métricas de evaluación

La selección de métricas de evaluación responde a los requisitos operacionales del sistema y a las características del dataset. Cada métrica se corresponde con el criterio de aceptación de un requisito concreto: la F1 macro cuantifica el criterio de RF-1 y describe la clasificación por clases invocada en RF-2, la Precisión@5 cuantifica el criterio de RF-5, y la AUC-ROC y la FPR_clean caracterizan el margen operativo con el que ambos criterios se satisfacen. Todas ellas se calculan sobre las particiones definidas en la Sección 4.3, cuyo alcance determina si el valor resultante constituye una estimación sobre datos retenidos. Las cuatro se definen a continuación junto con la razón por la que resultan preferibles a alternativas de uso más extendido.

F1 macro. Se aplica a la Capa 1 y a la clasificación por clases de la Capa 2. La F1 macro calcula la media no ponderada de la F1 de cada clase, otorgando igual importancia a las clases minoritarias (misconfiguraciones críticas) que a las mayoritarias (manifiestos seguros). Esta propiedad es fundamental en datasets de seguridad desequilibrados, donde la exactitud (*accuracy*) sería una métrica engañosa —sobre el conjunto de test de la Capa 1 (566 muestras), un clasificador que predice siempre «seguro» obtendría una exactitud del 56,3 % pero F1 macro del 36,0 %.

AUC-ROC. Se aplica al modelo binario de la Capa 1 y mide la capacidad del clasificador para separar las dos clases independientemente del umbral de decisión, lo que permite al operador ajustar la sensibilidad según las necesidades del entorno.

Precisión@k. Se aplica a la Capa 2 y al *ranking* del sistema completo. En lugar de evaluar la clasificación por umbral, P@k cuenta los clústeres de cadena de ataque situados en las primeras k posiciones del *ranking* por puntuación de riesgo y normaliza ese recuento por $\min(k, n_{\text{pos}})$, siendo n_{pos} el número de cadenas presentes en el conjunto evaluado:

$$P@k = \frac{|\{i \in \text{top-}k : y_i = \text{attack_chain}\}|}{\min(k, n_{\text{pos}})} \quad (3)$$

Esta definición coincide con la fracción convencional sobre k únicamente cuando el conjunto evaluado contiene al menos k cadenas; cuando contiene menos, el denominador pasa a ser n_{pos} y la métrica alcanza el valor 1 si y solo si todas las cadenas existentes ocupan posiciones dentro del top- k . La forma normalizada es la que dota de sentido al techo teórico de la métrica analizado en la Sección 6.3: sin ella, un conjunto con menos de k cadenas tendría un máximo alcanzable inferior a la unidad por construcción y no por deficiencia del modelo. Esta métrica está directamente alineada con el caso de uso operacional: un equipo de seguridad que audita los k clústeres de mayor riesgo en su infraestructura quiere que todos sean cadenas de ataque reales, no falsas alarmas. La elección de $k = 5$ refleja la capacidad de revisión manual típica de un equipo de seguridad reducido en una jornada laboral, valor de k que coincide con el fijado en el criterio de aceptación de RF-5.

FPR_clean. Esta tasa de falsos positivos sobre clústeres limpios mide la fracción de clústeres limpios entre los k primeros del *ranking* de riesgo¹. Un FPR_clean = 0 significa que ningún clúster limpio aparece entre los de mayor puntuación, eliminando las investigaciones innecesarias.

¹Operacionalmente es una tasa de limpios en el top- k , no una tasa de falsos positivos en sentido estricto (que normalizaría por el total de clústeres limpios); se mantiene la denominación FPR_clean por coherencia con la implementación.

5. Descripción de la herramienta software desarrollada

El sistema *kubescan* se organiza en tres capas que transforman un directorio de manifiestos YAML en una puntuación de riesgo de cadena de ataque, y se distribuye como una herramienta de línea de comandos instalable. Su construcción abarca la obtención del conjunto de datos, la derivación del grafo de clúster que representa las relaciones de seguridad entre manifiestos, el diseño y entrenamiento de cada capa, y las prácticas de ingeniería de software aplicadas al desarrollo. La implementación completa se encuentra disponible en el repositorio indicado en el Anexo A.

5.1. Arquitectura general del sistema


El sistema *kubescan* implementa una arquitectura de tres capas que transforma un directorio de manifiestos YAML en una puntuación de riesgo de cadena de ataque (Figura 1):

1. **Capa 1 (Random Forest):** extrae 28 características por manifiesto (25 indicadores binarios y 3 agregados derivados) y produce un *risk_score* $\in [0, 1]$.
2. **Capa 2 (GAT):** modela el clúster como un grafo donde los nodos son manifiestos y las aristas representan relaciones de seguridad; produce una probabilidad de cadena de ataque $\in [0, 1]$.
3. **Capa 3 (Ensemble GA):** combina las señales de las dos capas anteriores con una señal binaria de escape según la ecuación:

$$\text{score}(C) = w_{\text{rf}} \cdot \overline{\text{risk}}(C) + w_{\text{gnn}} \cdot p_{\text{chain}}(C) + w_{\text{esc}} \cdot \mathbf{1}[\exists \text{ nodo de escape en } C] \quad (4)$$

donde los pesos w_{rf} , w_{gnn} , w_{esc} son optimizados mediante Algoritmo Genético sobre las predicciones *out-of-fold* de la validación cruzada (Sección 5.6).

Figura 1. Arquitectura del sistema kubescan



Fuente: elaboración propia.

La Figura 1 muestra el proceso de tres capas, desde los manifiestos YAML de entrada hasta la clasificación de riesgo del clúster. Los *risk_scores* producidos por la Capa 1 se incorporan como atributo nodal 26 del grafo de entrada de la Capa 2, de modo que la señal por manifiesto queda disponible como atributo de nodo para el razonamiento estructural.

5.2. Construcción del conjunto de datos

La construcción del conjunto de datos parte de la recolección de manifiestos YAML procedentes de fuentes públicas heterogéneas y avanza hasta la extracción de las características que alimentan la Capa 1. El origen y la composición de los manifiestos recopilados determinan la cobertura de patrones de misconfiguración disponible, y el proceso de extracción de características transforma cada manifiesto en un vector estructurado de dimensión fija. El conjunto resultante es la base tanto del clasificador de la Capa 1 como del grafo de clúster construido en la Sección 5.3.

5.2.1. Fuentes de datos

El conjunto de datos tabular final contiene 2.827 filas y 58 columnas, combinando cinco fuentes (agrupadas en cuatro categorías, dado que Rahman et al. aporta dos plataformas distintas con características de distribución diferentes; ver Tabla 4):

Tabla 4. Composición del conjunto de datos de manifiestos Kubernetes

Fuente	Filas	Rol
Rahman et al. (Rahman y cols., 2023) — GitHub	1.510	Manifiestos reales, etiquetados
Rahman et al. (Rahman y cols., 2023) — GitLab	396	Ídem, plataforma distinta
BishopFox BadPods (Art, 2021)	128	Pods vulnerables intencionales
Kubernetes Goat (Akula, 2020)	14	Escenarios de vulnerabilidad
Repositorios de seguridad adicionales	779	CTFs, <i>fixtures</i> de herramientas, labs; etiqueta derivada por regla
Total	2.827	

Fuente: elaboración propia.

La procedencia de la etiqueta binaria no es homogénea entre las fuentes de la Tabla 4, y esa heterogeneidad condiciona la interpretación de los resultados de la Capa 1. Las 1.906 filas de Rahman et al. (Rahman y cols., 2023) conservan la anotación *INSECURE* del corpus original, ajena al extractor de características de este trabajo: sólo 245 de las 1.510 filas de GitHub y 87 de las 396 de GitLab coinciden con la disyunción de las columnas de misconfiguración observadas. Las 779 filas de los repositorios de seguridad adicionales, en cambio, carecen de anotación en origen y reciben una etiqueta derivada por regla en la ingesta (`compute_label` en `ingest_attack_repos.py`), definida como la disyunción de las columnas de misconfiguración; las 779 satisfacen por construcción esa equivalencia exacta. El corpus final combina, por tanto, verdad de referencia externa y etiquetado por regla, circunstancia que se retoma al analizar la circularidad entre etiqueta y características en la Sección 6.2.2.

La incorporación de BadPods fue esencial para mitigar la escasez de ejemplos de misconfiguraciones críticas en los repositorios reales: antes de añadir esta fuente, TRUE_HOST_PID aparecía en sólo el 0,3 % de las filas; tras la incorporación, la cobertura ascendió al 3,78 %. En cuanto a los conjuntos de datos de referencia existentes para intrusión en red, como UNSW-NB15 (Moustafa y Slay, 2015), se estudió su metodología de construcción como guía para el diseño del proceso de etiquetado y la estrategia de balanceo de clases, dado que sus particiones curadas de entrenamiento y evaluación presentan un desequilibrio de clases del mismo orden de magnitud que el de este trabajo (56,3 % seguros vs. 43,7 % mal configurados). El conjunto *GenKubeSec* (Malul y cols., 2024), publicado en 2024, no estaba disponible durante el desarrollo de este trabajo; en su lugar se empleó *Checkov* (Bridgecrew, 2021) directamente sobre los ficheros YAML descargados como fuente de validación multi-herramienta equivalente.

5.2.2. Características extraídas

El extractor de características aplica 28 reglas de análisis estático a cada manifiesto YAML, organizadas en tres grupos:

- **18 flags Rahman** (subconjunto del trabajo original): TRUE_HOST_PID, CAP_SYS_ADMIN, SEC_CONT_OVER_PRIVIL, INSECURE_HTTP, etc.
- **3 features derivadas**: cap_misuse (OR de las dos flags de capacidades de sistema), all_secrets (OR de los indicadores de exposición de secretos), total_misconfigs (suma de todas las flags activas).
- **7 features extendidas**: NO_RUN_AS_NON_ROOT, IMAGE_USES_LATEST, SA_AUTOMOUNT_TOKEN, HOSTPATH_MOUNT, etc. Seis de ellas presentan una procedencia mixta de valores; la séptima, HOSTPATH_MOUNT, se extrae siempre del propio manifiesto.

La procedencia de los valores de las seis características extendidas con equivalente en *Checkov* (Bridgecrew, 2021) —NO_RUN_AS_NON_ROOT, NO_READ_ONLY_ROOT_FS, IMAGE_USES_LATEST, SA_AUTOMOUNT_TOKEN, USES_DEFAULT_SA y UNTRUSTED_REGISTRY— se reparte en tres vías sobre las 2.827 filas del corpus: 921 filas (32,6 %) reciben el valor extraído directamente por el analizador YAML, 1.175 filas (41,6 %) se rellenan con la salida de

Checkov a través de la tabla `CHECKOV_FILL`, y las 731 restantes (25,9 %) se imputan mediante la mediana de columna. Ese relleno no es un mecanismo general aplicable a toda fila con YAML disponible, sino específico de la fuente: *Checkov* se ejecutó únicamente sobre el subconjunto de GitHub —1.175 de sus 1.510 filas— y no produjo salida alguna para los repositorios de seguridad adicionales, GitLab, BadPods ni Kubernetes Goat, cuyas filas se resuelven por el analizador YAML o por mediana. La séptima característica extendida queda al margen de este esquema, ya que `HOSTPATH_MOUNT` se deriva por completo del análisis estático del manifiesto y está poblada para las 2.827 filas.

La Capa 2 (GNN) consume únicamente las 18 flags Rahman y las 7 features extendidas (25 en total, `FEATURE_COLS` en `yaml_parser.py`) como vector de nodo, excluyendo las 3 features derivadas —agregados calculados a partir de las otras 25 que no aportan información estructural adicional al grafo—; ver Sección 5.8. De estas 25, tres presentan varianza casi nula pero se mantienen en el entrenamiento, con importancia residual o nula (Sección 6.2.2): `SECCOMP_UNCONFINED` (15/2.827 activa), `VALID_TAINT_SECRET` (0/2.827 activa) y `NO_NETWORK_POLICY` (2.818/2.827 activa, sin poder discriminativo). Las importancias de característica registradas por el modelo RF confirman ese aporte marginal: $1,6 \times 10^{-5}$ para `SECCOMP_UNCONFINED`, 0,0 para `VALID_TAINT_SECRET` y $2,4 \times 10^{-5}$ para `NO_NETWORK_POLICY`. Se conservan para preservar la estabilidad del contrato de características (`FEATURE_COLS`) y la correspondencia exacta con el conjunto de flags de Rahman et al. (Rahman y cols., 2023); no se ha realizado un estudio de ablación que cuantifique el efecto de su eliminación.

5.3. Construcción del grafo de clúster

Cada directorio de manifiestos se representa, mediante *NetworkX* (Hagberg, Schult, y Swart, 2008), como un grafo dirigido $G = (V, E)$ donde $|V|$ es el número de manifiestos del clúster y E contiene aristas de cinco tipos semánticamente distintos (Tabla 5). La Figura 2 ilustra un ejemplo con cuatro nodos que incluye los tres tipos de nodo posibles: escape, movimiento lateral y limpio. Las reglas de asignación de cada tipo de nodo y de arista se detallan en las dos subsecciones siguientes.


Tabla 5. Tipos de aristas en el grafo de clúster

Tipo	Código	Dirección	Criterio
Proximidad de directorio	0	Bidireccional	Mismos dos componentes finales de ruta YAML
Alcance de privilegio	1	Dirigida (escape→mismo namespace)	Flag de escape activa
Movimiento lateral SA	2	Dirigida (lateral→mismo namespace)	Flag de movimiento lateral
Co-espacio de nombres (SEMANTIC_NS)	3	Bidireccional	Mismo namespace K8s
Escalada RBAC	4	Dirigida (elevado→mismo namespace)	Service Account (Cuenta de Servicio de Kubernetes) (SA) vinculado a rol privilegiado

Fuente: elaboración propia.

Cada nodo v_i lleva un vector de características $\mathbf{x}_i \in \mathbb{R}^{26}$: índices 0–24 corresponden a las 25 features binarias de la Capa 1 y el índice 25 contiene el *risk_score* producido por el modelo *Random Forest*.

Figura 2. Ejemplo de grafo de clúster Kubernetes con cuatro nodos



Fuente: elaboración propia.

La Figura 2 muestra los tres tipos de nodo (escape, movimiento lateral y limpio) y las aristas dirigidas que cada uno origina. El nodo rojo (pod-A) tiene flags de escape activas y emite aristas de tipo 1 (*privilege_reach*) hacia todos los demás nodos de su mismo *namespace*. El nodo naranja (pod-B) tiene flags de movimiento lateral y emite aristas de tipo 2 (*sa_lateral*). La arista de tipo 4 (RBAC) representa la vinculación de un *ServiceAccount* a un rol privilegiado.

El conjunto de datos de grafos final comprende 599 grafos originales (25 clean, 537 isolated, 37 attack_chain) y 1.154 grafos totales tras la aumentación de datos, cuyas variantes se destinan exclusivamente al conjunto de entrenamiento. De los 555 grafos aumentados que componen ese *pool*, solo 390 entran efectivamente en el entrenamiento: los 165 restantes derivan de clústeres asignados a validación o test y quedan excluidos por la regla de asignación consciente de grupos descrita en la Sección 5.5.3. Esta cifra incorpora el corpus completo de Rahman et al. (Rahman y cols., 2023), cuyos *namespaces* cruzados se resolvieron mediante descarga auten-

ticada desde GitHub, lo que amplió sustancialmente el número de clústeres *isolated* respecto a las fases experimentales preliminares descritas en la Sección 6.3 del Capítulo 6.

5.3.1. Detección de escape y movimiento lateral

La clasificación de nodos utiliza dos conjuntos de flags definidos en el código como constantes inmutables (*frozenset*). Un nodo se clasifica como de **escape** si tiene activa al menos una de las siguientes 8 flags: `TRUE_HOST_PID`, `TRUE_HOST_IPC`, `TRUE_HOST_NET`, `DOCKERSOCK_PATH`, `CAP_SYS_ADMIN`, `CAP_SYS_MODULE`, `SEC_CONT_OVER_PRIVIL` o `HOSTPATH_MOUNT`. Este último vector fue incorporado durante el desarrollo al detectar que *badpods_hostpath* —que monta el sistema de ficheros del anfitrión— era incorrectamente etiquetado como *isolated* al no tener ninguna otra flag de escape activa. Con la corrección, el número de clústeres de cadena de ataque del corpus preliminar ascendió de 13 a 15; la trayectoria completa del tamaño del corpus y del número de cadenas a lo largo de las fases experimentales se recoge en la Tabla 11.

Un nodo se clasifica como de **movimiento lateral** si tiene activa al menos una de las siguientes 4 flags: `SA_AUTOMOUNT_TOKEN` (token de cuenta de servicio automontado), `USES_DEFAULT_SA` (usa la cuenta de servicio por defecto del *namespace*), `WITHIN_MANIFEST_SECRET` (secreto referenciado en el manifiesto) o `ALLOW_PRIVI` (contenedor con capacidad de escalada). Las aristas de movimiento lateral (tipo 2) se construyen de forma análoga a las de escape: se emite una arista dirigida desde cada nodo lateral hacia los demás nodos de su mismo *namespace*.

La convivencia de los cinco tipos sobre un mismo par de nodos se resuelve por orden de inserción y no por una jerarquía explícita de prioridades. Las aristas se añaden en la secuencia proximidad de directorio (tipo 0), alcance de privilegio (tipo 1), movimiento lateral (tipo 2), co-espacio de nombres (tipo 3) y escalada RBAC (tipo 4). Las de alcance de privilegio son las únicas que sobrescriben incondicionalmente cualquier etiqueta previa, de modo que un nodo con capacidad de escape nunca queda degradado a mero vecino; los cuatro tipos restantes se emiten bajo la guarda `not G.has_edge`, por lo que una arista de proximidad de directorio ya presente impide que el par se reetiquete como movimiento lateral, y las aristas RBAC, al añadirse en último lugar, nunca desplazan a las de movimiento lateral.

5.3.2. Detección de privilegio RBAC

La construcción de aristas RBAC (tipo 4) requiere dos pasadas sobre el conjunto de manifiestos. La primera pasada identifica los roles privilegiados: aquellos cuyo nombre está en el conjunto {cluster-admin, admin, edit} o cuyas reglas contienen verbos de escalada {*, escalate, bind, impersonate}. La segunda pasada recorre los objetos *RoleBinding* y *ClusterRoleBinding*: sólo cuando el campo *roleRef* referencia un rol privilegiado identificado en la primera pasada se emite una arista RBAC desde el pod que usa esa cuenta de servicio hacia los demás nodos de su mismo *namespace*, coherentemente con el ámbito de los objetos *RoleBinding* de los que se derivan las cuentas elevadas.

5.4. Capa 1: Random Forest

La Capa 1 clasifica cada manifiesto de forma individual a partir de las características descritas en la Sección 5.2. Se entrenan dos modelos independientes sobre el mismo conjunto de características: un clasificador binario que distingue manifiestos seguros de mal configurados, y un modelo de severidad que estima el grado de gravedad de la configuración incorrecta detectada. Ambos comparten el conjunto de 28 características y los mismos hiperparámetros de bosque, y difieren únicamente en la variable objetivo.

5.4.1. Modelo binario

Se entrena un *RandomForestClassifier* (Breiman, 2001) de *scikit-learn* (Pedregosa y cols., 2011) con los hiperparámetros siguientes:

- `n_estimators = 500`
- `max_features = sqrt` (clasificación estándar)
- `min_samples_leaf = 2` (evita hojas de muestra única)
- `class_weight = balanced` (compensa ratio 1,29:1)
- `random_state = 42`

El modelo se entrena sobre 2.261 muestras (80 % del total) y se evalúa en 566 muestras de test no vistas durante el entrenamiento. La probabilidad predicha para la clase *misconfigured* (clase 1) se usa como *risk_score* del nodo en el grafo.

5.4.2. Modelo de severidad

Además del modelo binario, se entrena un clasificador de severidad de tres clases (*clean*, *low-medium*, *high-critical*) para ofrecer información más granular al operador de seguridad. Este modelo no interviene en el cálculo del grafo; se incluye como salida adicional de la Capa 1.

5.5. Capa 2: Graph Attention Network

La Capa 2 opera sobre el grafo de clúster construido en la Sección 5.3 y clasifica el clúster completo según el riesgo de cadena de ataque que presenta. Su diseño se apoya en tres decisiones acopladas: una arquitectura GAT con *embedding* de tipo de arista, un procedimiento de entrenamiento con validación cruzada estratificada de 5 pliegues, y una estrategia de aumentación de datos que mitiga la escasez de clústeres con cadena de ataque confirmada.

5.5.1. Arquitectura

El modelo GAT (Veličković y cols., 2018) implementado tiene la siguiente estructura, con las dimensiones exactas verificadas en `gat_encoder.py`:

1. **Embedding de tipo de arista:** `Embedding(5, 8)`. Los cinco tipos de arista (proximidad de directorio, alcance de privilegio, lateral por *ServiceAccount*, espacio de nombres y RBAC) son categóricos: codificarlos como un escalar continuo implicaría un orden espurio (el tipo 4 «valdría» cuatro veces el tipo 1). Cada tipo se proyecta a un vector aprendido de 8 dims que `GATConv` consume como atributo de arista (*edge_dim=8*).
2. **Proyección inicial:** `Linear(26, 256) + LayerNorm(256) + Rectified Linear Unit` (Unidad Lineal Rectificada) (`ReLU`) + `Dropout(0.3)`. Proyecta el vector de nodo de 26 dims a 256 dims (64×4 cabezas).
3. **Capas GAT 0 y 1** (*concat=True*): `GATConv(256, 64, heads=4)` con *edge_dim=8*; salida

256 dims (64×4); seguidas de LayerNorm, Exponential Linear Unit (Unidad Lineal Exponencial) (ELU), conexión residual y Dropout (0.3).

4. **Capa GAT 2** (*concat=False, heads=1*): GATConv(256, 64, heads=1); salida 64 dims (una sola cabeza de atención que produce directamente el embedding final del nodo, sin concatenación); seguida de LayerNorm, ELU y Dropout (0.3) (sin conexión residual: las dimensiones de entrada y salida difieren, 256 frente a 64).
5. **Global pooling**: `global_mean_pool` y `global_max_pool` sobre los 64-dim embeddings de todos los nodos; concatenación $\rightarrow$ 128 dims ($64 + 64$).
6. **Clasificador Multi-Layer Perceptron (Perceptrón Multicapa) (MLP)**: `Linear(128, 64) + ReLU + Dropout(0.3) + Linear(64, 3)`.

La elección de GAT sobre GCN responde a que el mecanismo de atención permite al modelo aprender qué aristas son más informativas para la señal de ataque: una arista de *privilege_reach* debe recibir mayor peso que una arista de proximidad de directorio. El *pooling* combinado de media y máximo captura dos señales complementarias: la media refleja la postura de seguridad promedio del clúster, mientras que el máximo identifica el nodo más peligroso, ambas necesarias para detectar cadenas de ataque que pueden estar concentradas en un único nodo crítico.

5.5.2. Entrenamiento

El modelo se entrena con *PyTorch Geometric* (Fey y Lenssen, 2019), construido sobre *PyTorch* (Paszke y cols., 2019), bajo los siguientes hiperparámetros: optimizador AdamW con tasa de aprendizaje 5×10^{-4} y *weight_decay* = 10^{-4} ; *scheduler* CosineAnnealingLR con $T_{\text{max}} = 300$ y $\eta_{\text{mín}} = 10^{-5}$; función de pérdida CrossEntropyLoss con pesos de clase calculados por frecuencia inversa; *gradient clipping* con norma máxima 2,0; *early stopping* con paciencia de 50 épocas; tamaño de lote 8; semilla global 42 (idéntica para el entrenamiento y para la generación de particiones); y validación cruzada estratificada de 5 pliegues. El *checkpoint* de cada pliegue se selecciona por la mejor Precisión@5 de validación, con la F1 macro como criterio de desempate (`--select-by p5`), alineando la selección de modelos con la métrica primaria del sistema en lugar de con la métrica de clasificación.

El guion de entrenamiento (`train_gnn.py`) expone tres opciones que seleccionan variantes de esa configuración y que hacen reproducibles los estudios de ablación reportados en el Capítulo 6. La opción `--conv` escoge el operador de convolución sobre el grafo entre `gat`, el GAT con *embedding* de tipo de arista descrito en la arquitectura y empleado en la configuración desplegada, y `gcn`, una GCN de referencia que ignora los tipos de arista y pondera todos los vecinos por igual. La opción `--focal-loss`, acompañada del parámetro de enfoque `--focal-gamma` (valor 2 por defecto), sustituye la entropía cruzada ponderada por la *focal loss* (Lin, Goyal, Girshick, He, y Dollár, 2017), que reduce el peso de los ejemplos ya bien clasificados para concentrar el gradiente en los difíciles. La opción `--select-by` fija el criterio de selección del *checkpoint* de cada pliegue entre `f1` (F1 macro de validación) y `p5` (Precisión@5 de validación), con la métrica restante como criterio de desempate. La configuración desplegada corresponde a `--conv gat`, sin `--focal-loss` y con `--select-by p5`; las alternativas se cuantifican en las Secciones 6.3.4 y 6.3.5.

Los pesos de clase se calculan en cada pliegue de entrenamiento mediante la siguiente fórmula implementada en `train_gnn.py`:

$$w_i = \frac{1/n_i}{\sum_{j=0}^{K-1} 1/n_j} \cdot K \quad (5)$$

donde n_i es el número de grafos de entrenamiento de la clase i y $K = 3$ es el número de clases. Esta fórmula normaliza los pesos para que su media sea 1,0, proporcionalmente equivalente al comportamiento de `class_weight=balanced` de *scikit-learn* (misma ponderación relativa entre clases). Cabe destacar que los pesos se calculan **después** de la aumentación de datos: como la aumentación genera 15 variantes por grafo de cadena de ataque, la clase *attack_chain* pasa de ser la minoría a ser la mayoría en el conjunto de entrenamiento. Los tres recuentos varían de un pliegue a otro, ya que las variantes de los clústeres reservados para validación se excluyen en cada iteración: entre 360 y 405 grafos de *attack_chain* aumentados frente a 17–18 *clean* y 361–371 *isolated*. La Ecuación 5 se auto-adapta a esta nueva distribución asignando mayor peso a *clean* e *isolated*, y menor peso a *attack_chain*, compensando el efecto de la sobre-representación creada por la aumentación.

5.5.3. Aumentación de datos

Para mitigar la escasez de ejemplos de cadena de ataque (37 de 599 grafos originales), se aplican tres estrategias de aumentación exclusivamente sobre los grafos de entrenamiento: *edge dropout* (eliminación aleatoria de entre el 10 % y el 35 % de aristas de los tipos 0 y 3, los menos críticos para la señal de ataque, con tasa muestreada uniformemente por variante); *feature masking* (puesta a cero, con probabilidad por nodo entre el 10 % y el 25 %, restringida a seis características ajenas a la regla de etiquetado de cadena — nunca las flags de escape, `HOSTPATH_MOUNT` ni el *risk_score*); y *subgraph sampling* (extracción de un subgrafo inducido por entre el 40 % y el 70 % de nodos, aplicada a las últimas cinco de las 15 variantes y solo a grafos de más de 50 nodos, con *BFS* sembrada en el nodo de mayor *risk_score*; cada subgrafo se valida contra la regla de etiquetado de cadena y, si deja de cumplirla, se descarta en favor de una variante sobre el grafo completo, evitando introducir ruido de etiqueta). Cada grafo de cadena de ataque origina 15 variantes aumentadas, resultando en 555 grafos adicionales (37 originales $\times$ 15 variantes) en el *pool* de aumentación; de éstos, únicamente 390 (los correspondientes a los 26 grafos de cadena cuya base pertenece a la partición de entrenamiento) entran efectivamente en el entrenamiento, para un total de 1.154 grafos con aumentación.

La asignación de variantes a particiones es **consciente de grupos** (*group-aware*): una variante aumentada solo puede entrar en una partición de entrenamiento si su grafo base pertenece a esa misma partición. Las variantes derivadas de clústeres de validación o de test se excluyen del entrenamiento por completo, ya que entrenar con casi-duplicados de un grafo de evaluación constituiría fuga de datos.

El particionado es además **consciente de familias de plantilla**: los clústeres originales que comparten una misma plantilla base (por ejemplo, las ocho variantes `badpods_*`, que difieren únicamente en qué flag de escape activan —salvo `badpods_nothing-allowed`, que no activa ninguna—, o las nueve `datadog_*`) son casi duplicados entre sí, no muestras independientes. Cuando una familia contiene etiquetas mixtas, sus miembros se asignan como una unidad atómica a una única partición — nunca se reparten entre entrenamiento, validación y test ni entre pliegues — y la asignación emplea un reparto voraz ponderado por el número de grafos de cada etiqueta, de modo que la proporción real de cada clase por partición siga las fracciones

solicitadas. Sin esta regla, un modelo entrenado con cinco hermanos de una familia resuelve trivialmente al sexto en test, inflando las métricas. La partición resultante (semilla 42) es de 815 grafos de entrenamiento (con aumentación), 88 de validación y 86 de test. Adicionalmente, los 86 clústeres de test se mantienen fuera de los pliegues de validación cruzada: los pliegues particionan únicamente los 513 grafos originales restantes (32 de cadena), de modo que ni los modelos de pliegue ni las predicciones *out-of-fold* empleadas para ajustar los pesos del *ensemble* (Capa 3) observan ningún clúster de test, directa ni indirectamente.

5.6. Capa 3: Ensemble con Algoritmo Genético

Los pesos $(w_{rf}, w_{gnn}, w_{esc})$ de la Ecuación 4 son optimizados mediante un Algoritmo Genético (Holland, 1975) con 60 individuos codificados como pares $(w_{gnn}, w_{esc}) \in [0, 1]^2$, con w_{rf} derivado como $1 - w_{gnn} - w_{esc}$ (la representación 2D garantiza que la suma de los tres pesos sea siempre 1). La función objetivo combina la métrica de *ranking* Precisión@5 y la tasa de falsos positivos sobre clústeres limpios FPR_clean, ambas definidas en la Sección 4.4, junto con un término de regularización:

$$F = 0,7 \cdot P@5 + 0,3 \cdot (1 - \text{FPR_clean}) - \lambda \sum_i \max(0, w_{\min} - w_i) \quad (6)$$

El último término es una penalización de suelo con $w_{\min} = 0,1$ y $\lambda = 2,0$: sin ella, el optimizador es libre de anular cualquiera de los tres pesos cuando eso puntúa marginalmente mejor sobre la muestra *out-of-fold*, lo que produce soluciones degeneradas que no generalizan al conjunto de test. La penalización hace que ignorar una señal por completo esté estrictamente dominado salvo que la ganancia observada supere λ veces el déficit.

La selección se realiza mediante torneo de tamaño 3, con elitismo del 10 %; el cruce es aritmético (media de los dos padres) con probabilidad 0,7; la mutación combina perturbación gaussiana ($\sigma = 0,08$, tasa del 15 %) con una mutación de frontera (tasa del 5 %) que salta a los vértices del símplex, seguida de re-proyección al dominio válido ($w_{rf} \geq 0$); la población inicial se siembra con los vértices y puntos medios del símplex y con muestreo de Dirichlet, y el criterio de parada es 150 generaciones. Como *baseline* determinístico, antes de la optimización genética

se ejecuta una búsqueda en rejilla 2D con paso $1/20$ (231 evaluaciones); la comparación de su óptimo con el resultado del Genetic Algorithm (Algoritmo Genético) (GA) se discute en la Sección 6.4.

La señal de escape se define como un indicador binario que vale 1,0 si al menos un nodo del clúster tiene alguna flag de escape activa, y 0,0 en caso contrario. Esta formulación evita la dilución que produciría una fracción cuando la mayoría de los nodos del clúster son limpios.

La asignación de clase final a partir de la puntuación *ensemble_score* se realiza mediante los siguientes umbrales fijos, definidos en `ga_ensemble.py`:

- $ensemble_score \geq 0,60 \Rightarrow \text{ATTACK_CHAIN}$
- $ensemble_score \geq 0,30 \Rightarrow \text{ISOLATED_MISCONFIG}$
- De lo contrario $\Rightarrow \text{CLEAN}$

Estos umbrales son fijos y no se reoptimizan durante el entrenamiento del GA, que optimiza únicamente los pesos w_i de la Ecuación 4. Permiten al operador interpretar directamente la puntuación: cualquier clúster con $score \geq 0,60$ requiere revisión inmediata.

5.6.1. Restricción de viabilidad estructural

Una cadena de ataque multi-salto requiere, por definición, alcanzabilidad entre al menos dos manifiestos; un grafo de clúster con un único nodo no puede albergarla. Esta propiedad, verificada sobre el corpus completo (los 592 grafos de cadena —37 originales y 555 variantes aumentadas— tienen ≥ 2 nodos y ≥ 1 arista, mientras que 499 de los 537 grafos *isolated* son de un solo nodo), se incorpora como restricción de inferencia en `ga_ensemble.py` (`MIN_CHAIN_NODES`, `is_chain_feasible`, `chain_rank_key`): en el *ranking* por riesgo de cadena, ningún clúster de un solo manifiesto puede superar a un clúster estructuralmente viable, y el veredicto de un clúster inviable se limita a `ISOLATED_MISCONFIG` aunque su puntuación supere el umbral de 0,60. La restricción se aplica únicamente en inferencia y evaluación; el ajuste de los pesos del GA se realiza sobre el *ranking* sin restricción, donde los pesos están mejor determinados (la Sección 6.4 cuantifica el efecto de esta regla sobre las métricas de test).

5.7. Implementación de kubescan

El sistema se distribuye como un paquete Python instalable mediante `pip install -e kubescan/`. La estructura del paquete sigue la convención *src-layout* de *setuptools*: el código fuente reside en `kubescan/src/kubescan/` y los módulos se organizan en tres submódulos: `model/` (clasificadores RF, GAT y ensamblador GA), `utils/` (*parser* YAML y constructor de grafos) y `cli.py` (interfaz de línea de comandos basada en *Click*).

El punto de entrada principal expone dos comandos. El primero, `kubescan scan <dir>`, analiza un directorio local de manifiestos YAML y emite un informe de riesgo en formato texto o JavaScript Object Notation (Notación de Objetos de JavaScript) (JSON). El segundo, `kubescan live`, consulta el API de *Kubernetes* mediante *kubectl*, vuelca los recursos de *workloads* y RBAC en un directorio temporal y ejecuta el *pipeline* completo sobre ellos. La resolución de los pesos del modelo sigue la cadena: argumento `--checkpoints-dir` → variable de entorno `KUBESCAN_CHECKPOINTS` → enlace simbólico `kubescan/checkpoints/trained/` → `CheckpointNotFoundError`, excepción tipada derivada de `KubescanError` y definida en `exceptions.py`.

Ambos comandos comparten el conjunto de opciones recogido en la Tabla 6, definido con *Click* en `cli.py`. La opción `--format` selecciona entre el informe en texto y la salida JSON; `--show-nodes` añade el desglose por manifiesto al informe en texto; `--cluster-name` fija el nombre del clúster que encabeza el informe, que por defecto es el del directorio analizado; y `--checkpoints-dir` altera el primer eslabón de la cadena de resolución de pesos. Las opciones `--namespace` y `--all-namespaces` son exclusivas de `kubescan live` y delimitan el ámbito de la consulta al API de *Kubernetes*. El grupo raíz añade, por su parte, `--verbose`, que eleva el nivel del registro de WARNING a DEBUG, y `--version`, que emite la versión instalada del paquete.

El informe en texto se estructura en tres bloques. El encabezado identifica el clúster y la ruta analizada; el cuerpo emite el veredicto (CLEAN, ISOLATED_MISCONFIG o ATTACK_CHAIN) seguido de las señales que lo sustentan —*ensemble score*, probabilidad de cadena del ensemble de cinco pliegues, probabilidad de clúster limpio, riesgo RF medio, fracción de manifiestos con

Tabla 6. Opciones de la interfaz de línea de comandos de kubescan

Opción	Ámbito	Efecto
<code>--format</code> <code>{text,json}</code>	scan, live	Formato de salida; text por defecto
<code>--show-nodes</code>	scan, live	Desglose de riesgo por manifiesto (sólo formato texto)
<code>--cluster-name, -n*</code>	scan, live	Nombre legible del clúster en el informe
<code>--checkpoints-dir,</code> <code>-c</code>	scan, live	Directorio de <i>checkpoints</i> del modelo
<code>--namespace, -n</code>	live	<i>Namespace</i> consultado vía <i>kubectf</i>
<code>--all-namespaces, -A</code>	live	Consulta todos los <i>namespaces</i>
<code>--verbose, -v</code>	Grupo raíz	Registro en nivel DEBUG
<code>--version</code>	Grupo raíz	Versión instalada del paquete

*La forma corta `-n` corresponde a `--cluster-name` en scan y a `--namespace` en live.

Fuente: elaboración propia.

capacidad de escape y con capacidad de movimiento lateral— y de los tres pesos w_{rf} , w_{gnn} y w_{esc} efectivamente aplicados; el bloque final, condicionado a `--show-nodes`, tabula los manifiestos ordenados por *risk_score* descendente con su marca de escape (ESC) o movimiento lateral (LAT) y sus primeras cuatro flags activas. La Figura 11 del Anexo B traza el recorrido completo de una invocación de `kubescan scan` y reproduce una transcripción íntegra de este informe.

La salida JSON expone la misma información en un objeto de un solo nivel apto para consumo automatizado: los campos `cluster`, `cluster_dir` y `verdict` identifican el análisis; los campos `ensemble_score`, `chain_probability`, `clean_probability`, `mean_rf_risk` y `escape_fraction` recogen las señales numéricas redondeadas a seis decimales; los recuentos `n_manifests`, `n_escape_capable` y `n_lateral_capable` resumen la composición del clúster; el objeto anidado `weights` contiene los tres pesos del *ensemble*; y la lista `manifests`, ordenada por *risk_score* descendente, aporta por cada manifiesto su nombre de fichero, su *risk_score*, los indicadores booleanos `escape_capable` y `lateral_capable`, y la lista completa `flags` de características de seguridad activas. Estos dos últimos campos son la

evidencia de trazabilidad que verifica el requisito RNF-1 en la Sección 6.8.

5.8. Tabla de características del sistema

Las Tablas 7 y 8 describen las 28 características utilizadas por la Capa 1, organizadas por grupo y con indicación de si son relevantes para la detección de escape (ESC) o de movimiento lateral (LAT) en el grafo de la Capa 2. De estas 28, las 25 que no son derivadas (18 Rahman + 7 extendidas) también forman el vector de nodo de la Capa 2.

Las 8 flags de escape (ESC, `ESCAPE_FLAGS` en `graph_builder.py`) son `TRUE_HOST_PID`, `TRUE_HOST_IPC`, `TRUE_HOST_NET`, `DOCKERSOCK_PATH`, `CAP_SYS_ADMIN`, `CAP_SYS_MODULE`, `SEC_CONT_OVER_PRIVIL` y `HOSTPATH_MOUNT`. Las 4 flags de movimiento lateral (LAT, `LATERAL_FLAGS`) son `SA_AUTOMOUNT_TOKEN`, `USES_DEFAULT_SA`, `WITHIN_MANIFEST_SECRET` y `ALLOW_PRIVI`. Seis de las 7 características extendidas combinan tres vías de procedencia sobre las 2.827 filas del corpus —analizador YAML (921 filas), relleno desde *Checkov* sobre el subconjunto de GitHub (1.175) e imputación por mediana de columna (731)—, según detalla la Sección 5.2. La séptima, `HOSTPATH_MOUNT`, se extrae del manifiesto en la totalidad de las filas.

5.9. Calidad de software y proceso de desarrollo

El desarrollo de *kubescan* sigue prácticas de ingeniería de software orientadas a la producción. Cuatro herramientas integradas en un *pipeline* de pre-commit y CI/CD comprueban de forma automática el estilo, los tipos, el comportamiento y la complejidad del código, y bloquean la integración cuando alguna comprobación falla: (1) *ruff*, linter y formateador de código Python con reglas de estilo y seguridad; (2) *mypy* en modo estricto (`mypy kubescan/src --strict`), para comprobación estática de tipos en todos los módulos del paquete; (3) *pytest*, para la suite de tests unitarios y de integración del paquete; y (4) *radon*, para el control de la complejidad ciclométrica. El reparto entre las dos etapas del *pipeline* no es uniforme: los *hooks* de pre-commit ejecutan únicamente *ruff*, *ruff-format* y comprobaciones de higiene del repositorio (espacios finales, fin de fichero, validez de los YAML de configuración y tamaño máximo de los ficheros añadidos), mientras que *mypy*, *pytest* y *radon* se ejecutan en el flujo de integración continua

Tabla 7. Características del clasificador RF — grupo Rahman (1/2)

Nombre	Grupo	Rol en grafo	Descripción
TRUE_HOST_PID	Rahman	ESC	Comparte PID namespace del anfitrión
TRUE_HOST_IPC	Rahman	ESC	Comparte IPC namespace del anfitrión
TRUE_HOST_NET	Rahman	ESC	Comparte red del anfitrión
DOCKERSOCK_PATH	Rahman	ESC	Monta socket de Docker
CAP_SYS_ADMIN	Rahman	ESC	Capacidad SYS_ADMIN activa
CAP_SYS_MODULE	Rahman	ESC	Capacidad SYS_MODULE activa
WITHIN_MANIFEST_SECRET	Rahman	LAT	Secreto en texto plano embebido en el manifiesto
SEC_CONT_OVER_PRIVIL	Rahman	ESC	Contenedor privilegiado (privileged: true)
ALLOW_PRIVI	Rahman	LAT	Permite escalada de privilegios (allowPrivilegeEscalation: true)
INSECURE_HTTP	Rahman	—	Usa HTTP sin TLS en puerto conocido
NO_SECU_CONTEXT	Rahman	—	Ausencia de securityContext definido
HOST_ALIAS	Rahman	—	Usa hostAliases para resolución DNS manual
NO_DEFAULT_NAMESPACE	Rahman	—	Despliega en el namespace default
NO_RESO	Rahman	—	Sin límites/requests de recursos definidos
NO_ROLLING_UPDATE	Rahman	—	Sin estrategia de actualización <i>RollingUpdate</i>
SECCOMP_UNCONFINED	Rahman	—	Perfil <i>seccomp</i> unconfined (sin filtrado de <i>syscalls</i>)
VALID_TAINT_SECRET	Rahman	—	Secreto válido referenciado en <i>taint/toleration</i>
NO_NETWORK_POLICY	Rahman	—	Sin <i>NetworkPolicy</i> definida en el namespace

Tabla 8. Características del clasificador RF — grupos derivado y extendido, y nodo (2/2)

Nombre	Grupo	Rol en grafo	Descripción
cap_misuse	Derivada	—	OR lógico de CAP_SYS_ADMIN y CAP_SYS_MODULE
all_secrets	Derivada	—	OR de los indicadores de exposición de secretos
total_misconfigs	Derivada	—	Suma de todas las flags activas
NO_RUN_AS_NON_ROOT	Extendida	—	Sin restricción de usuario no root
NO_READ_ONLY_ROOT_FS	Extendida	—	Sistema de ficheros raíz con escritura
IMAGE_USES_LATEST	Extendida	—	Imagen con tag: latest
SA_AUTOMOUNT_TOKEN	Extendida	LAT	ServiceAccount con token automontado
USES_DEFAULT_SA	Extendida	LAT	Usa la ServiceAccount default del namespace
UNTRUSTED_REGISTRY	Extendida	—	Imagen proveniente de un registro no confiable
HOSTPATH_MOUNT	Extendida	ESC	Monta ruta del sistema de ficheros del anfitrión
risk_score	Nodo (Capa 2)	—	Probabilidad RF clase misconfigured $\in [0, 1]$

Fuente: elaboración propia.

de GitHub Actions sobre cada *push* y cada *pull request*.

La suite de tests cubre el parser de YAML (`utils/yaml_parser.py`), la construcción del grafo de clúster (`utils/graph_builder.py`), el clasificador RF (`model/rf_classifier.py`) y el ensamblador GA (`model/ga_ensemble.py`); la verificación funcional de extremo a extremo que estos tests de integración realizan se reporta como evidencia de los requisitos RF-1 y RF-2 en la Sección 6.8.

6. Evaluación

Este capítulo evalúa el sistema *kubescan* completo. Se parte de una línea de base tomada del estado del arte, frente a la cual se contrastan los resultados de cada capa; a continuación se reportan dichos resultados en el mismo orden que las fases de entrenamiento descritas en el Capítulo 5. El desglose por clases del clasificador de grafo sobre el conjunto de test (Sección 6.5) caracteriza la dirección de los errores residuales, y el contraste con una herramienta de análisis estático externa (Sección 6.6) delimita hasta qué punto el corpus admite verificación independiente. Sobre esa base se sintetiza una métrica de proceso completo que resume el comportamiento extremo a extremo del sistema y se verifica el cumplimiento de los requisitos funcionales y no funcionales definidos en el Capítulo 4. El capítulo cierra con la evaluación de usabilidad y aplicabilidad realizada con usuarios expertos. Las métricas empleadas se justifican en detalle en la Sección 4.4.

6.1. Línea de base del estado del arte

Antes de reportar los resultados propios, esta sección fija la línea de base frente a la que se contrastan: los trabajos revisados en el Capítulo 2 que abordan un problema comparable al de cada capa. La comparación se organiza por capa, dado que la Capa 1 dispone de referencias directas en la literatura de clasificación de *IaC*, mientras que la Capa 2 carece de trabajos previos estrictamente comparables. En ambos casos se prioriza la comparación con resultados obtenidos sobre conjuntos de datos de tamaño y naturaleza similares; los resultados propios que superan o contrastan con esta línea de base se presentan en las secciones siguientes.

6.1.1. Capa 1 en contexto

Rahman et al. (Rahman y cols., 2023), cuyos datos forman la base del presente trabajo, no reportan modelos de clasificación supervisada sobre el mismo conjunto: el objetivo de su trabajo era la construcción del dataset y el análisis de la densidad de misconfiguraciones, no la

predicción, por lo que no ofrece una cifra de referencia directa. Tampoco la literatura de IDS sobre UNSW-NB15 (Moustafa y Slay, 2015) proporciona una: ese trabajo presenta el conjunto de datos y compara exactitud y tasa de falsas alarmas de otros algoritmos, sin reportar F1 macro ni resultados de *Random Forest* (Sección 2.3). En consecuencia, el umbral $F1 > 0,85$ de OE2 es un criterio de diseño propio y no una cota tomada de la literatura, y la comparación informativa para la Capa 1 no es contra ese umbral sino contra una línea de base trivial calculada sobre el propio corpus: la mejor regla de una sola característica alcanza $F1 \text{ macro} = 0,8502$, frente al 0,9946 del modelo (Sección 6.2). Esa separación es consistente con la naturaleza del problema: las misconfiguraciones en manifiestos YAML son mayoritariamente discretas y acumulativas (más flags activas implica mayor riesgo), lo que hace que el espacio de características sea relativamente separable una vez que se dispone de un conjunto de datos suficientemente representativo.

6.1.2. Capa 2 en contexto

Según la revisión bibliográfica no sistemática realizada en este trabajo (Capítulo 2), no se ha localizado ningún trabajo previo que aborde la clasificación supervisada de cadenas de ataque en clústeres *Kubernetes* mediante GNNs, por lo que la Capa 2 no dispone de una línea de base directamente comparable. Las referencias más cercanas son los trabajos de GNNs para Intrusion Detection System (Sistema de Detección de Intrusiones) (IDS) en red, como *E-GraphSAGE* (Lo y cols., 2022), que reporta tasas de detección superiores a las de clasificadores tabulares clásicos sobre las re-publicaciones en formato NetFlow de los conjuntos de referencia del área; y la literatura que documenta la escasez de conjuntos de datos de grafos etiquetados en ciberseguridad (Zhong y cols., 2024). Conviene precisar que esta última no establece un régimen de tamaño concreto ni prescribe un protocolo de evaluación, de modo que no puede invocarse como respaldo de la varianza observada en este trabajo; la validación cruzada estratificada se adopta aquí como decisión metodológica propia. La ventaja del componente estructural se mide sobre el conjunto de test genuinamente no visto: $P@5$ pasa de 0,40 (RF-sólo) a 0,80 (configuraciones con GNN) y $P@1$ de 0,00 a 1,00 (Tabla 16; Sección 6.3 y siguientes), indicando que la información estructural del grafo es decisiva para identificar cadenas de ataque reales. La varianza entre pliegues de la fase final ($\sigma = 0,160$ para $P@5$) no se contrasta aquí con ninguna cota externa, al no disponerse de una referencia que la establezca para conjuntos de este tama-

ño; en este trabajo tiene, no obstante, una causa estructural identificada: el particionado por familias concentra las cadenas de validación de cada pliegue en 1, 1, 4, 5 y 5 familias independientes respectivamente (Sección 6.3), de modo que la desviación estándar entre pliegues mide en buena parte la dispersión de dificultad entre familias. El análisis multi-semilla (Sección 6.3.6) matiza esa lectura: cuatro de los cinco pliegues puntúan de forma idéntica con las tres semillas ensayadas, pero el único que varía —el pliegue 1, correspondiente a la familia `badpods_*`— es también el que más contribuye a esa desviación. En ese pliegue concreto, la dificultad de la familia y la sensibilidad a la semilla no resultan separables con los datos disponibles, de modo que la atribución estructural de la varianza es parcial y no total.

6.2. Resultados de la Capa 1: Random Forest

Esta sección presenta los resultados de los dos modelos de la Capa 1 descritos en el Capítulo 5: el clasificador binario y el modelo de severidad. Se reportan primero las métricas de clasificación binaria y la importancia de las características, y a continuación los resultados del modelo de severidad. Ambos modelos comparten el mismo conjunto de 28 características extraídas por manifiesto, descrito en la Sección 5.2.

6.2.1. Clasificación binaria

La Tabla 9 resume los resultados del modelo binario mediante cuatro métricas: F1 macro (media no ponderada de F1 entre las clases seguro y misconfigured, que da igual peso a ambas independientemente de su frecuencia en el dataset), exactitud (*accuracy*, porcentaje simple de aciertos), AUC-Receiver Operating Characteristic (Característica Operativa del Receptor) (ROC) (capacidad del modelo para separar las dos clases a cualquier umbral de decisión) y *out-of-bag score* (estimación interna de generalización que *Random Forest* calcula sobre las muestras que cada árbol no vio durante su entrenamiento, sin necesitar un conjunto de validación aparte). El clasificador alcanza una F1 macro de 0,9946 en el conjunto de test, superando el objetivo de diseño (OE2, F1 macro > 0,85) en 14,5 puntos porcentuales.

Conviene situar esa cifra frente a una línea de base trivial, porque el umbral de OE2 resulta poco exigente sobre este corpus: la mejor regla de una sola característica (`NO_RES0 = 1`) alcanza por

sí sola F1 macro = 0,8502, prácticamente el umbral de 0,85. El margen relevante del modelo no es, por tanto, el que separa 0,9946 de 0,85, sino el que lo separa de esa regla trivial: 14,4 puntos porcentuales sobre la mejor decisión de una única condición. Una disyunción de todas las *flags* binarias, en cambio, se desploma a F1 macro = 0,3042, al marcar como mal configurado casi cualquier manifiesto.

Tabla 9. Resultados del Random Forest — clasificación binaria

Métrica	Test	CV (5-fold)	Objetivo
F1 macro	0,9946	0,9917 ± 0,0053	> 0,85 ✓
Exactitud (<i>accuracy</i>)	0,9947	0,9919 ± 0,0052	—
AUC-ROC	0,9986	0,9984 ± 0,0011	—
<i>Out-of-bag score</i>	0,9920	—	—


Fuente: elaboración propia.

La Figura 3 muestra la matriz de confusión sobre el conjunto de test (566 muestras). El modelo comete sólo 3 errores totales: 3 falsos positivos (manifiestos seguros clasificados como misconfigured) y 0 falsos negativos. La ausencia de falsos negativos es la propiedad más crítica para seguridad operacional: significa que ningún manifiesto con misconfiguraciones reales escapa al filtrado de la Capa 1, independientemente de cuántas flags estén activas o de su rareza en el dataset. Los 3 falsos positivos corresponden a manifiestos seguros que acumulan varias features de riesgo de severidad media (por ejemplo, NO_RUN_AS_NON_ROOT y IMAGE_USES_LATEST simultáneamente), pero que no tienen ninguna flag de escape activa; el operador de seguridad puede descartarlos rápidamente inspeccionando el campo *flags* de la salida JSON.

El AUC-ROC de 0,9986 (prácticamente 1,00) indica que el modelo puede ordenar las muestras por probabilidad de misconfiguration de forma casi perfecta a cualquier umbral de decisión. En la práctica, este valor implica que, si se ordenan los 566 manifiestos de test de mayor a menor *risk_score*, los manifiestos misconfigured aparecen casi todos antes que los seguros. Esta propiedad es la que habilita el uso del *risk_score* como característica nodal cuantitativa en el grafo de la Capa 2: la señal transmitida a la GNN no es un bit binario sino una puntuación continua que ordena los manifiestos por densidad de misconfiguraciones. No se aplica ninguna técnica

de calibración de probabilidades, por lo que el valor no debe interpretarse como una probabilidad calibrada en sentido estricto; el ordenamiento resultante es, en cambio, consistente con la matriz de confusión de la Figura 3.

Figura 3. Matriz de confusión del Random Forest en el conjunto de test



Fuente: elaboración propia.


6.2.2. Importancia de características

La Figura 4 muestra las 10 características más relevantes del modelo. La característica más discriminativa es `total_misconfigs` (33,05 % de importancia), seguida de `NO_RESO` (14,79 %) e `INSECURE_HTTP` (11,90 %). Las flags de escape críticas (`TRUE_HOST_PID`, `SEC_CONT_OVER_PRIVIL`) presentan importancias menores (<1 %) por su rareza en el dataset, pero son identificadas correctamente cuando están presentes, como confirma la ausencia de falsos negativos en la clasificación binaria. Las dos primeras características de la Figura 4 (en rojo) concentran el 48 % de la capacidad discriminativa total del modelo. Un estudio de ablación eliminando `total_misconfigs` produce F1 idéntico y la misma matriz de confusión, lo que confirma que el modelo no depende de esa característica derivada: su señal es recuperable a partir de las flags que la componen.

Esa ablación, sin embargo, no permite concluir que no exista circularidad entre etiqueta y características. La etiqueta binaria del corpus de Rahman et al. se define como la presencia de al menos una misconfiguración de un subconjunto concreto de patrones, y esos patrones son a su

vez características de entrada del modelo: sobre las 1.906 filas de esa fuente, la etiqueta coincide exactamente con la disyunción de ocho de las características observadas (INSECURE_HTTP, NO_SECU_CONTEXT, WITHIN_MANIFEST_SECRET, NO_RESO, CAP_SYS_ADMIN, TRUE_HOST_NET, ALLOW_PRIVI y DOCKERSOCK_PATH), sin un solo falso positivo ni falso negativo. Reentrenar la misma configuración restringida a esas filas produce, consecuentemente, F1 macro = 1,0000. La Capa 1 aprende por tanto una aproximación robusta de una regla determinista definida sobre su propio espacio de características —bajo imputación, valores ausentes y las etiquetas heterogéneas del resto de fuentes—, no una noción de misconfiguración independiente de dicha regla. Esta limitación, análoga a la que afecta al etiquetado de grafos, se analiza en la limitación L5 del Capítulo 7.

Figura 4. Importancia de características del clasificador Random Forest



Fuente: elaboración propia.

6.2.3. Modelo de severidad

El clasificador de tres clases (*clean*, *low-medium*, *high-critical*) alcanza F1 macro = 0,9838 en test. La Tabla 10 desglosa por clase la precisión (proporción de predicciones de esa clase que son correctas), el *recall* (proporción de casos reales de esa clase que el modelo identifica), el F1 (media armónica de ambas) y el soporte (número de muestras de test en esa clase):

Tabla 10. F1 por clase — modelo de severidad (3 clases, test)

Clase	Precisión	Recall	F1	Soporte
<i>clean</i>	1,0000	0,9906	0,9953	319
<i>low-medium</i>	0,9615	0,9934	0,9772	151
<i>high-critical</i>	0,9894	0,9688	0,9789	96
Macro media	0,9836	0,9842	0,9838	—

Fuente: elaboración propia.

El F1 más bajo de las tres clases corresponde a *low-medium* (0,9772), por debajo del de *high-critical* (0,9789). La causa no es una dificultad intrínseca de la clase intermedia, cuyo *recall* es de 0,9934, sino su papel de sumidero de los errores del modelo: absorbe los seis manifiestos mal asignados del conjunto de test —tres procedentes de *clean* y tres de *high-critical*—, lo que rebaja su precisión a 0,9615. La clase *high-critical* (96 muestras de test, que representan manifiestos con flags de escape activas como `TRUE_HOST_PID` o `SEC_CONT_OVER_PRIVIL`) comete 3 errores, los tres clasificados como *low-medium*; ningún manifiesto crítico es clasificado como *clean*. Esa ausencia de fugas hacia la clase *clean* es la propiedad relevante desde el punto de vista de seguridad operacional: en el peor caso un manifiesto crítico se subestima a *low-medium*, nunca se descarta como seguro, y la dirección de los errores restantes —tres manifiestos *clean* sobreclasificados como *low-medium* y un único manifiesto *low-medium* elevado a *high-critical*— es igualmente conservadora. El modelo de severidad se utiliza en el informe de salida de *kubescan* para proporcionar al operador una descripción cualitativa del nivel de riesgo de cada manifiesto, complementando el *risk_score* numérico del modelo binario.

6.3. Resultados de la Capa 2: GNN

Esta sección presenta los resultados de la Capa 2 en el orden en que fueron obtenidos durante el desarrollo experimental: la evolución de las métricas a lo largo de las fases de mejora del modelo, el análisis de Precisión@5, los resultados por pliegue de la configuración final, la ablación de la función de pérdida y del criterio de selección, y la robustez frente a la semilla de entrenamiento. A diferencia de la Capa 1, la Capa 2 requirió varias iteraciones metodológicas

antes de alcanzar una configuración cuyas métricas fueran a la vez válidas y reproducibles. Cada iteración corrigió una fuente concreta de fuga de información o una elección de entrenamiento subóptima, y el descenso de las métricas que acompaña a esas correcciones cuantifica el sesgo optimista que introducían los protocolos de particionado sucesivamente descartados.

6.3.1. Evolución por fase experimental

La Tabla 11 muestra la evolución de los resultados de la GAT a lo largo de las seis fases del desarrollo experimental. La Figura 5 traza la trayectoria de las cuatro primeras fases y muestra cómo la aumentación de datos y la corrección del vector de escape `HOSTPATH_MOUNT` contribuyeron de forma independiente y complementaria. La quinta fase corrige el protocolo de particionado: las fases 1–4 incluían en el entrenamiento variantes aumentadas derivadas de los clústeres de validación y test (fuga de datos por casi-duplicados), por lo que sus métricas están infladas de forma optimista. Esa quinta fase aplica el protocolo *group-aware* descrito en el Capítulo 5 (las variantes acompañan a su clúster base y los clústeres de test quedan fuera de los pliegues) e incorpora el *embedding* de tipos de arista; sus métricas son metodológicamente válidas pero corresponden todavía al corpus preliminar de 471 grafos. La sexta y última fase incorpora el corpus completo de Rahman et al. (599 grafos originales, 37 cadenas; Sección 5.2) y extiende el protocolo de particionado a las **familias de plantilla** (Capítulo 5): durante esta fase se detectó que los casi duplicados de una misma plantilla (ocho `badpods_*`, nueve `datadog_*`, ocho `simulator_*`, doce `kubernetes_goat_*`) quedaban repartidos entre particiones, una fuga de información adicional a la de las variantes aumentadas que inflaba las métricas de las fases 1–5. Con las familias atómicas, entropía cruzada ponderada como función de pérdida y selección de *checkpoints* por Precisión@5 (ablación en la Sección 6.3.4), esta fase es la que se reporta como resultado final del trabajo — sus métricas son las que produce el modelo efectivamente desplegado y reproducible a partir de los *checkpoints* del repositorio. Por el cambio de protocolo, sus cifras no son directamente comparables con las de las fases 1–5 de la Tabla 11: miden generalización entre familias, no interpolación entre casi duplicados.

En la Tabla 11, las fases 1–4 emplean el protocolo de particionado preliminar (con fuga por variantes aumentadas) y se reportan como registro histórico; la fase 5 introduce el protocolo *group-aware* sobre el corpus preliminar; la fase 6 es el resultado final, con protocolo *group-*

Tabla 11. Evolución de resultados de la Capa 2 (GAT, 5-fold CV)


Fase	Grafos	Cadenas	F1 macro	P@5	Cobert. techo
Línea base	82	13	$0,829 \pm 0,098$	$0,400 \pm 0,179$	2/5
Tras aumentación	277	13	$0,915 \pm 0,059$	$0,520 \pm 0,098$	5/5
Tras corrección HOSTPATH	307	15	$0,915 \pm 0,050$	$0,600 \pm 0,000$	5/5
Dataset extendido	471	25	$0,917 \pm 0,065$	$0,880 \pm 0,098$	5/5
Protocolo <i>group-aware</i> + <i>embedding</i> de aristas	471	25	$0,870 \pm 0,075$	$0,720 \pm 0,098$	3/5
Corpus completo + familias de plantilla (final)	599	37	$0,803 \pm 0,137$	$0,720 \pm 0,160$	1/5

Fuente: elaboración propia.

aware sobre el corpus completo. La columna «Cobert. techo» indica en cuántos de los 5 pliegues el modelo alcanza el *techo teórico* de P@5. La métrica se calcula como el número de cadenas situadas en el top-5 dividido entre $\min(5, n_{\text{pos}})$, siendo n_{pos} el número de cadenas presentes en el pliegue, de modo que el techo vale 1,0 siempre que el pliegue contenga al menos una cadena y se alcanza cuando las cinco primeras posiciones del *ranking* están ocupadas por cadenas —o, si el pliegue contiene menos de cinco, cuando todas ellas figuran en el top-5. En la fase final, los cinco pliegues de validación contienen 8, 7, 6, 6 y 5 cadenas respectivamente, por lo que el denominador es 5 en todos ellos y el techo 1,0 exige cinco aciertos en las cinco primeras posiciones; únicamente el pliegue 0 lo consigue.

La Figura 5 recorre las cuatro primeras fases experimentales (protocolo preliminar). Las líneas de puntos indican el objetivo de diseño de ranking ($P@5 > 0,70$) y, como referencia, el umbral de F1 fijado para la Capa 1 (0,85); las barras de error representan la desviación estándar entre los 5 pliegues de validación cruzada. La fase final *group-aware* no está incluida en el gráfico y se reporta en la Tabla 11.

Figura 5. Evolución de F1 macro y Precisión@5 de la Capa 2



Fuente: elaboración propia.

6.3.2. Análisis de Precisión@5

El objetivo de diseño es $P@5 > 0,70$ (OE4). En el resultado final de este trabajo —particionado consciente de familias sobre el corpus completo de Rahman et al. (599 grafos originales, 37 cadenas; fase 6 de la Tabla 11)— los pliegues de validación cruzada particionan los 513 grafos originales no reservados para test (32 cadenas). El modelo obtiene $P@5 = 0,720 \pm 0,160$, alcanzando el objetivo con la semilla de entrenamiento desplegada (42); en las tres semillas (7, 42, 123) la media es de $0,68 \pm 0,03^1$, con el objetivo dentro de una desviación típica de la media (Sección 6.3.6).

Alcanzar esta cifra exigió diagnosticar una regresión aparente: la primera configuración entrenada sobre el corpus completo con familias atómicas empleaba *focal loss* y selección de *checkpoints* por F1 macro, y obtuvo $P@5 = 0,480 \pm 0,271$, muy por debajo tanto del objetivo como de

¹Las desviaciones típicas de las métricas del modelo se reportan como desviación poblacional ($ddof = 0$), consistente con la instrumentación de *NumPy* empleada en la validación cruzada; la del SUS (Sección 6.9) sigue la convención muestral ($n - 1$) habitual en su literatura.

la fase 5. La ablación factorial de la Sección 6.3.4 mostró que la caída se debía a las elecciones de función de pérdida y de criterio de selección —no al corpus ni al protocolo de particionado—, y que revertir a entropía cruzada ponderada y seleccionar por Precisión@5 recupera el objetivo sobre el mismo particionado honesto. La varianza entre pliegues ($\sigma = 0,160$, frente a 0,098 en la fase 5) refleja en gran medida la propia atomicidad de las familias: cada pliegue evalúa 1, 1, 4, 5 y 5 familias independientes respectivamente, como se detalla a continuación.

6.3.3. Resultados por pliegue (fase final)

Las medias de validación cruzada de la configuración desplegada ocultan una dispersión considerable entre pliegues, y su desglose es necesario para atribuir esa dispersión a una causa concreta. La Tabla 12 recoge la F1 macro y la Precisión@5 obtenidas en cada uno de los cinco pliegues, junto con la media y la desviación típica poblacional que resumen el conjunto. Los valores individuales se interpretan a continuación a la luz de la composición de cada pliegue en términos de familias de plantilla.

Tabla 12. Resultados por pliegue — Capa 2, fase final

Pliegue	F1 macro	P@5
0	1,000	1,00
1	0,580	0,60
2	0,863	0,60
3	0,801	0,60
4	0,770	0,80
Media	0,803	0,720
$\pm$ Desv.	0,137	0,160

Fuente: elaboración propia.

La Tabla 12 corresponde al particionado consciente de familias sobre el corpus completo: los pliegues particionan 513 grafos originales con 32 cadenas, con el conjunto de test excluido. La dispersión entre pliegues es consecuencia directa del particionado por familias: al mantener cada familia de plantilla como unidad atómica, las cadenas de validación de cada pliegue quedan

concentradas en pocas familias independientes. El pliegue 0 valida sobre las nueve variantes `datadog_*` (ocho de ellas cadenas; grafos de 2–3 nodos casi idénticos entre sí) y alcanza $F1 = 1,0$ y $P@5 = 1,0$; el pliegue 1 valida sobre las ocho variantes `badpods_*` (siete de ellas cadenas) y es sistemáticamente el más difícil ($P@5 = 0,60$ con la semilla desplegada; 0,2–0,6 según la semilla, Sección 6.3.6). Los tres pliegues restantes reparten las dos familias grandes que quedan junto a repositorios únicos: el pliegue 2 concentra las ocho variantes `simulator_*`, el pliegue 3 las doce variantes `kubernetes_goat_*` y el pliegue 4 no contiene ninguna de las cuatro familias de plantilla, sino exclusivamente repositorios únicos. El número de familias independientes portadoras de cadena por pliegue es, en consecuencia, de 1, 1, 4, 5 y 5. Cada pliegue mide, por tanto, la capacidad del modelo de generalizar a un número reducido de familias no vistas —un tamaño muestral efectivo menor que el número nominal de cadenas—, lo que explica que la varianza ($\sigma = 0,160$) sea mayor que bajo protocolos con fuga y constituye una amenaza a la validez de conclusión que se documenta en el Capítulo 7.

6.3.4. Ablación de función de pérdida y criterio de selección

La regresión aparente de la primera configuración sobre el corpus completo ($P@5 = 0,480$) confundía dos cambios simultáneos: la introducción de *focal loss* (Lin y cols., 2017) y el nuevo particionado por familias. Para atribuir el efecto se completó la matriz factorial 2×2 —función de pérdida (entropía cruzada ponderada vs. *focal loss*, $\gamma = 2$) por criterio de selección de *checkpoints* ($F1$ macro vs. Precisión@5)— con particionado, semilla y arquitectura idénticos (Tabla 13).²

Las cuatro configuraciones de la Tabla 13 se evaluaron con 5-fold Cross-Validation (Validación Cruzada) (CV) sobre el corpus completo, particionado por familias y semilla 42. Los dos efectos principales apuntan en la misma dirección, pero no se comportan de forma aditiva: sustituir *focal loss* por entropía cruzada ponderada aporta +0,12 puntos de $P@5$ con selección por $F1$ macro y sólo +0,04 con selección por $P@5$, mientras que seleccionar los *checkpoints* por la métrica primaria de ranking en lugar de por $F1$ macro aporta +0,20 puntos bajo *focal loss* y +0,12 bajo entropía cruzada. La suma de ambos efectos principales sobre la configuración de partida

²Las cuatro configuraciones son reproducibles mediante `make reproduce GNN_FOCAL={0,1} GNN_SELECT_BY={p5,f1}`; solo se conserva el *checkpoint* de la configuración finalmente desplegada.


Tabla 13. Ablación de función de pérdida y criterio de selección

Pérdida	Selección	P@5 (CV)	F1 macro (CV)
<i>Focal</i> ($\gamma=2$)	F1 macro	0,480 $\pm$ 0,271	0,823 $\pm$ 0,097
Entropía cruzada pond.	F1 macro	0,600 $\pm$ 0,283	0,859 $\pm$ 0,103
<i>Focal</i> ($\gamma=2$)	P@5	0,680 $\pm$ 0,204	0,795 $\pm$ 0,173
Entropía cruzada pond.	P@5	0,720 $\pm$ 0,160	0,803 $\pm$ 0,137

Fuente: elaboración propia.

(0,480) predeciría P@5 = 0,80, frente al 0,720 efectivamente observado: existe una interacción negativa de 0,08 puntos, es decir, la mejora que aporta cada factor se solapa parcialmente con la del otro en lugar de acumularse. La *focal loss*, diseñada para regímenes con miles de ejemplos por clase (Lin y cols., 2017), además anula por completo la clasificación de la clase *attack_chain* en el conjunto de test (F1 de clase 0,0 frente a 0,667 con entropía cruzada). La configuración desplegada es, en consecuencia, entropía cruzada ponderada con selección por Precisión@5 (Figura 6).

Figura 6. Precisión@5 de la ablación de pérdida y selección



Fuente: elaboración propia.

La Figura 6 representa la Precisión@5 de validación cruzada ($\pm\sigma$) de las cuatro configuraciones;

solo la desplegada —entropía cruzada ponderada con selección por Precisión@5— supera el objetivo de diseño. La distancia respecto de la segunda mejor configuración es, no obstante, estrecha ($0,720 \pm 0,160$ frente a $0,680 \pm 0,204$): sus bandas de una desviación típica se solapan casi por completo y, sobre cinco pliegues y con una métrica cuantizada en múltiplos de 0,2, esa diferencia equivale a un solo acierto de *ranking* en un único pliegue. Los datos sostienen, por tanto, una afirmación más débil que la de una dependencia estricta de ambos factores: la combinación desplegada es la única que sitúa la media de validación cruzada por encima del objetivo, y la configuración más alejada de él —*focal loss* con selección por F1 macro, 0,480— sí queda separada por un margen que excede la dispersión observada.

6.3.5. Ablación de arquitectura

La elección de GAT frente a alternativas más simples y la profundidad de tres capas se fijaron en el diseño de la Capa 2 y admiten contraste empírico sobre el mismo protocolo. La literatura sobre GNNs aplicadas a grafos pequeños heterogéneos documenta de forma consistente que los mecanismos de atención mejoran la precisión cuando los tipos de arista tienen importancias desiguales (Veličković y cols., 2018). En el grafo de clúster *Kubernetes*, las aristas de *privilege_reach* (tipo 1) son cualitativamente más informativas que las de *dir_proximity* (tipo 0): la primera conecta directamente nodos de escape con el resto del clúster, mientras que la segunda simplemente refleja la organización de directorios del repositorio. GAT puede aprender esta distinción durante el entrenamiento, mientras que GCN asigna pesos uniformes a todos los vecinos, diluyendo la señal de escape con ruido de co-localización.

Esta hipótesis se cuantifica empíricamente mediante un experimento de ablación controlado sobre el corpus completo, con particionado, semilla, función de pérdida y criterio de selección idénticos a los de la configuración final (fase 6 de la Tabla 11), de modo que las tres filas son directamente comparables entre sí y con el resultado final (Tabla 14):

La GAT supera a la GCN en F1 (+9,2 puntos) y en P@5 (+4 puntos), confirmando que la atención sobre tipos de arista aporta señal real tanto para la clasificación como para el ranking de cadenas. La comparación 2 vs. 3 capas es menos concluyente: las medias de validación cruzada casi coinciden —P@5 = $0,720 \pm 0,160$ en ambas configuraciones y F1 macro de 0,803 frente a

Tabla 14. Ablación de arquitectura — Capa 2

Arquitectura	F1 macro	P@5
GAT 3 capas + <i>embedding</i> de aristas (desplegada)	0,803 ± 0,137	0,720 ± 0,160
GAT 2 capas + <i>embedding</i> de aristas	0,800 ± 0,171	0,720 ± 0,160
GCN 3 capas (sin tipos de arista)	0,711 ± 0,143	0,680 ± 0,160

Fuente: elaboración propia.

0,800—, pero esa coincidencia agregada oculta un desacuerdo apreciable pliegue a pliegue, con diferencias de F1 de +0,142 en el pliegue 3 y −0,191 en el pliegue 4 que se cancelan al promediar y dejan una brecha media de sólo 0,003. Dos modelos que difieren en esa magnitud sobre pliegues concretos no evidencian robustez de la arquitectura frente a la profundidad, sino que la profundidad no determina el nivel medio de las métricas sobre este corpus. Se mantiene la configuración de 3 capas como desplegada por su ventaja marginal en F1 macro y por coherencia con el resto de resultados reportados. La ablación de *pooling* (*mean-only* vs. *mean+max*) queda como trabajo futuro (TF6, Sección 7.4).

6.3.6. Robustez frente a la semilla de entrenamiento

Para acotar la dependencia del resultado respecto de la semilla de entrenamiento, la configuración final se reentrenó con tres semillas (7, 42, 123; Tabla 15 y Figura 7) manteniendo fijo el particionado (semilla 42): re-sortear también las particiones confundiría la varianza del modelo con la asignación de familias a pliegues, que la Sección 6.3 muestra dominante. Las métricas de test de la tabla aplican la restricción de viabilidad estructural (Sección 5.6.1).

Dos observaciones acotan la lectura del 0,72. Primera: la variación entre semillas se concentra íntegramente en el pliegue 1 (la familia *badpods_**: P@5 de 0,2/0,4/0,6 según semilla), mientras que los otros cuatro pliegues puntúan de forma idéntica con las tres semillas. Esa coincidencia impide leer el experimento como una demostración de estabilidad global, porque el único pliegue sensible a la semilla es precisamente el que domina la desviación típica entre pliegues: en él, la dificultad de la familia y la variabilidad de entrenamiento quedan confundidas y no pueden separarse con tres semillas. Lo que el experimento sí establece es que cuatro


Tabla 15. Robustez multi-semilla de la configuración final

Semilla	P@5 (CV)	F1 macro (CV)	Test P@1/P@3/P@5
42 (desplegada)	0,720 $\pm$ 0,160	0,803	1,00 / 1,00 / 0,80
7	0,640 $\pm$ 0,265	0,853	1,00 / 1,00 / 0,80
123	0,680 $\pm$ 0,204	0,857	1,00 / 1,00 / 1,00
Media entre semillas	0,680 $\pm$ 0,033	0,838	—

Fuente: elaboración propia.

quintas partes del particionado son invariantes a la semilla y que la incertidumbre residual de la estimación de validación cruzada se localiza en una sola familia de plantilla. Segunda: las métricas de test a nivel de despliegue son estables —P@1 = 1,00 y P@3 = 1,00 con las tres semillas, y P@5 entre 0,80 y 1,00—, de modo que la sensibilidad a la semilla afecta a la estimación de validación cruzada, no al comportamiento observable del sistema sobre repositorios reales no vistos.

Figura 7. Precisión@5 por pliegue con tres semillas de entrenamiento



Fuente: elaboración propia.

6.4. Resultados de la Capa 3: Ensemble

El ajuste de los pesos del ensemble atravesó dos correcciones metodológicas sucesivas, ambas implementadas en `run_ga_ensemble.py`. En una primera iteración, el GA original convergía sistemáticamente a pesos casi uniformes $(w_{rf}, w_{gnn}, w_{esc}) \approx (0,34, 0,33, 0,33)$ sin mejorar sobre su población inicial en 150 generaciones, un patrón que parecía indicar una meseta plana en la función de *fitness*. Un diagnóstico descartó esa hipótesis: el cruce por promedio aritmético es contractivo y no puede alcanzar los vértices del símplex de pesos desde una población inicializada por muestreo de Dirichlet, y la mutación gaussiana ($\sigma = 0,08$) es demasiado local para recorrer esa distancia en 150 generaciones. La primera corrección sembró los vértices y aristas del símplex en la población inicial y añadió una mutación de salto de frontera de baja probabilidad; con este cambio, el GA pasó a converger de forma determinista, en las 5 semillas independientes probadas, al mismo punto que una búsqueda en rejilla determinística (Sección 5.6, 231 evaluaciones): el vértice de señal de escape pura ($w_{esc} = 1$, *objective* = 0,86), confirmando que la función objetivo tenía un óptimo global único y alcanzable, no una meseta degenerada. Sin embargo, ese óptimo *out-of-fold* no generalizaba: al puntuar únicamente por la señal binaria de escape, el ranking se colapsaba a un grupo de empates que fallaba estructuralmente ante cualquier cadena de ataque cuya única señal fuerte no fuera la bandera de escape.

Esta segunda observación motivó la corrección definitiva: regularizar la propia función objetivo con una penalización de piso, $F = \alpha \cdot P@5 + \beta \cdot (1 - FPR_{clean}) - \lambda \sum_i \max(0, w_{min} - w_i)$, con $w_{min} = 0,1$ y $\lambda = 2,0$ (flags `--min-weight/--reg-lambda`). Esta penalización hace que el vértice de escape puro deje de ser competitivo frente a soluciones interiores del símplex. Sobre el conjunto *out-of-fold* de la configuración final (513 grafos, 32 cadenas), el GA regularizado encuentra su mejor solución ya en la generación inicial y no la mejora durante las 150 generaciones: $(w_{rf}, w_{gnn}, w_{esc}) = (0,517, 0,115, 0,368)$, *objective* = 0,72. La búsqueda en rejilla encuentra un punto muy distinto ($w_{rf} = 0,80$, $w_{gnn} = 0,10$, $w_{esc} = 0,10$) con idéntica *P@5 out-of-fold*: al ser *P@5* una función escalonada (solo toma valores múltiplos de 0,2), la función objetivo presenta mesetas extensas en las que los pesos quedan **indeterminados**. Esta indeterminación es medible: sobre el conjunto de test, los pesos elegidos por el GA y los pesos uniformes (1/3) producen métricas idénticas (Tabla 16). Contribuye a ella un desplazamiento de distribución


entre el conjunto de ajuste y el de test: 15 de las 32 cadenas *out-of-fold* pertenecen a familias de *fixtures* sintéticas (*badpods_**, *datadog_**) cuyos manifiestos reciben *risk scores* RF altos, mientras que las cinco cadenas de test son repositorios reales cuyo *risk score* medio por clúster es ≈ 0 (la media se diluye entre manifiestos mayoritariamente benignos). Tres refinamientos del ajuste (un término de desempate por *mean reciprocal rank*, la agregación del *pool* por familias y el ajuste sobre el *ranking* con restricción estructural) se implementaron y evaluaron sin que ninguno mejorara las métricas de test, por lo que los pesos se ajustan sobre el *ranking* sin restricción y la restricción de viabilidad estructural (Sección 5.6.1) se aplica en inferencia y evaluación.

La evaluación final se realiza sobre el conjunto de test (86 grafos: 3 limpios, 78 *isolated* y 5 cadenas de ataque; techo $P@5 = 1,00$). Bajo el particionado consciente de familias, las cinco cadenas son repositorios reales únicos —sin hermanos de plantilla en el entrenamiento— excluidos de los pliegues de validación cruzada, del ajuste de pesos del GA y del entrenamiento con variantes aumentadas: genuinamente no vistos durante el desarrollo. Con la restricción de viabilidad estructural aplicada al *ranking* (Sección 5.6.1), el ensemble alcanza $P@1 = 1,00$, $P@3 = 1,00$ y $P@5 = 0,80$: las cadenas ocupan las posiciones 1–4 y 6, y solo *minik8s-ctf* queda fuera del top-5. Sin la restricción, las métricas caen a $P@1 = 0,00$, $P@3 = 0,33$ y $P@5 = 0,60$ (Figura 8) — la regla es decisiva porque 74 de los 86 grafos de test son de un solo nodo, y dos de ellos, con todas sus flags de escape activas, encabezarían el *ranking* pese a no poder albergar una cadena. $FPR_clean = 0,00$: ningún clúster limpio aparece entre los de mayor riesgo. La F1 macro por clasificación *argmax* del ensemble de pliegues sobre el conjunto de test es 0,883 (F1 por clase: *clean* 1,0; *isolated* 0,981; *attack_chain* 0,667, con 3 de las 5 cadenas correctamente clasificadas).

Dado el tamaño del conjunto de test, estas estimaciones llevan asociados intervalos de confianza amplios (bootstrap de 10 000 remuestreos, 95 %): $P@5 [0,60, 1,00]$, $FPR_clean [0,00, 0,40]$ y F1 macro $[0,66, 1,00]$. Los valores puntuales deben interpretarse como *consistentes con* los objetivos de diseño, no como demostraciones concluyentes; la ampliación adicional del corpus de test es la vía directa para estrechar estos intervalos (TF1, Sección 7.4). La Figura 9 resume las tres métricas de ranking del ensemble sobre el conjunto de test.


La Tabla 16 desglosa la contribución de cada componente sobre el conjunto de test (86 grafos,

Figura 8. Efecto de la restricción de viabilidad estructural



Fuente: elaboración propia.

Figura 9. Precisión@k del ensemble sobre el conjunto de test



Fuente: elaboración propia.

5 cadenas, techo $P@5 = 1,00$), con la restricción de viabilidad estructural aplicada en todas las configuraciones. Tres observaciones: (i) la configuración RF-sólo degrada gravemente el ranking ($P@1 = 0,00$, $P@5 = 0,40$): el *risk score* medio de los repositorios reales de cadena es ≈ 0 , de modo que la señal por manifiesto no ordena clústeres reales; (ii) la señal de escape por sí sola alcanza $P@5 = 0,80$ gracias a la restricción estructural, pero con $P@1 = 0,00$ y $P@3 = 0,67$: al ser binaria, no puede ordenar entre los grafos con capacidad de escape, mayoritarios en la región de alto riesgo; y (iii) el GNN por sí solo iguala tanto a los pesos optimizados por el GA como a los pesos uniformes (los tres alcanzan $1,00/1,00/0,80$) — en este conjunto de test el *ensemble* no mejora el ranking de su mejor componente individual, observación que debe leerse con la cautela que imponen 5 cadenas de test y que se retoma como limitación en el Capítulo 7.

Tabla 16. Ablación de componentes del ensemble en el conjunto de test


Configuración	P@1	P@3	P@5	FPR_clean
GA-óptimo (0,517/0,115/0,368)	1,00	1,00	0,80	0,00
Pesos uniformes (1/3)	1,00	1,00	0,80	0,00
Solo GNN	1,00	1,00	0,80	0,00
Solo RF	0,00	0,33	0,40	0,00
Solo señal de escape	0,00	0,67	0,80	0,00

Fuente: elaboración propia.

6.5. Análisis de la clasificación por clases: GNN

El registro de la validación cruzada conserva por pliegue únicamente la F1 macro, la Precisión@5 y la exactitud agregada, sin matrices de confusión individuales, por lo que el desglose por clases se apoya exclusivamente en el conjunto de test. En él, la matriz de confusión del ensemble de pliegues (Figura 10, clasificación *argmax*) concentra el error en la frontera entre cadena y aislado: los dos falsos negativos de cadena se clasifican como *isolated* y ninguno como *clean*, de modo que el sistema degrada hacia la clase intermedia y no hacia la omisión total. Esta observación descansa sobre las cinco cadenas del conjunto de test y debe leerse con la cautela que impone ese tamaño.

Figura 10. Matriz de confusión del ensemble de pliegues en test



Fuente: elaboración propia.

El único fallo de ranking del conjunto de test ilustra el error sistemático del modelo: *minik8s-ctf* (posición 6, tras el clúster *isolated* multi-nodo *kubernetes-extras*) es una cadena de 4 nodos cuya probabilidad GNN es prácticamente nula (0,0003) y cuyo *risk score* RF medio es 0,0; su única señal activa es la bandera binaria de escape (la mitad de sus nodos tienen capacidad de escape). Cuando la señal estructural que el GNN aprende no reconoce el patrón de la cadena y la señal por manifiesto tampoco lo captura, la bandera de escape binaria por sí sola no basta para entrar en el top-5. Las cuatro cadenas recuperadas, en cambio, combinan probabilidad GNN alta (0,47–0,63) con fracciones de escape por nodo muy variables (0,02–0,94; magnitud descriptiva, no la señal binaria del ensemble), lo que confirma que el canal estructural es el que ordena los repositorios reales. Esta observación motiva el trabajo futuro TF3 (análisis semántico de RBAC completo, Sección 7.4).

6.6. Validación con herramientas de análisis estático

Como contraste externo, se ejecutó *Checkov* (Bridgecrew, 2021) sobre el subconjunto de manifiestos procedentes de GitHub, para el que la herramienta produjo salida en 1.175 de las 1.510 filas de esa fuente. La descarga previa de los manifiestos referenciados por Rahman et al. tuvo éxito en 1.985 de 2.039 casos (97,4 %); los 54 restantes ya no eran accesibles en origen. El

alcance del contraste queda limitado, por tanto, por la cobertura del escaneo y no por la disponibilidad de los manifiestos. Para esta validación, el índice UMI se calcula como la proporción de comprobaciones de *Checkov* que fallan sobre el total evaluado por manifiesto ($\in [0, 1]$; valores más altos indican mayor densidad de misconfiguraciones detectadas). El índice UMI medio resultante fue de 0,603, y las comprobaciones incumplidas con mayor frecuencia fueron *checkov_no_run_as_nonroot* (38,3 %) y *checkov_no_readonly_rootfs* (37,2 %).

El alcance de este contraste es limitado y conviene delimitarlo, porque las dos fuentes no son independientes. Sobre esas mismas 1.175 filas las características homólogas del extractor propio (`NO_RUN_AS_NON_ROOT` y `NO_READ_ONLY_ROOT_FS`) están ausentes en su totalidad, y es precisamente la salida de *Checkov* la que las rellena en tiempo de carga a través de la tabla de equivalencias `CHECKOV_FILL` (Sección 5.2). Cotejar ambas fuentes manifiesto a manifiesto equivaldría, por tanto, a comparar esos valores consigo mismos: no cabe calcular una tasa de acuerdo, y la coincidencia entre las frecuencias observadas es una identidad de procedencia, no una concordancia entre detectores. El resultado debe interpretarse, en consecuencia, como una verificación de cobertura —qué proporción del corpus admite análisis por una herramienta externa y con qué densidad de incumplimientos— y no como una validación externa independiente de las predicciones del modelo.

6.7. Métrica global del proceso completo

Las Secciones 6.2, 6.3 y 6.4 evalúan cada capa por separado, mientras que el comportamiento del sistema de extremo a extremo —tal como lo experimenta un operador que confía en el *ranking* final— se resume en una única métrica de proceso completo. Esa métrica es el conjunto Precisión@k / FPR_clean del sistema desplegado sobre el conjunto de test, ya reportado en la Sección 6.4 y resumido en la Figura 9: $P@1 = 1,00$, $P@3 = 1,00$, $P@5 = 0,80$ y $FPR_clean = 0,00$ sobre 86 grafos con 5 cadenas de ataque de repositorios reales, genuinamente no vistos durante el desarrollo; dado el tamaño reducido de este conjunto, los intervalos de confianza al 95 % son amplios ($P@5 \in [0,60, 1,00]$, $FPR_clean \in [0,00, 0,40]$, Sección 6.4), por lo que la cifra debe leerse como indicativa.

Esta cifra es la bondad global de la herramienta porque resume, en un único indicador opera-

cional, la salida final que recibe el operador tras pasar por las tres capas: sobre los 86 grafos evaluados, un P@1 de 1,00 indica que la primera posición del *ranking* correspondió en todos los casos a una cadena de ataque real, un P@3 de 1,00 extiende esa observación a las tres primeras posiciones y un FPR_clean nulo indica que ninguno de los tres clústeres limpios llegó a competir por la atención del operador. Estas cifras se apoyan en 5 cadenas y 3 clústeres limpios, de modo que describen el comportamiento observado sobre un conjunto reducido y no una garantía del sistema. La Sección 6.4 muestra que, sobre este conjunto de test, el componente GNN por sí solo iguala estas cifras y que el *ensemble* no las mejora; la aportación de la Capa 3 no es superar a su mejor componente individual, sino producir el mismo resultado sin heredar los puntos débiles de los demás (la Capa 1 sola colapsa el ranking y la señal de escape sola no puede ordenar por sí misma, Tabla 16). Esta combinación es lo que hace viable el caso de uso definido en RF-5 (Sección 4.1): priorizar un número reducido de alertas de forma que la revisión manual de un equipo de seguridad se concentre exclusivamente en riesgo real.

6.8. Verificación de cumplimiento de requisitos

El cumplimiento de los requisitos funcionales y no funcionales definidos en el Capítulo 4 se verifica a partir de dos clases de evidencia: las métricas predictivas reportadas en las Secciones 6.2, 6.3, 6.4 y 6.7, y las comprobaciones operacionales realizadas sobre la herramienta de línea de comandos descrita en la Sección 5.7. Los requisitos funcionales RF-1, RF-2 y RF-5 disponen de un criterio de aceptación numérico y se contrastan contra las métricas ya reportadas, mientras que RF-3, RF-4 y los cuatro requisitos no funcionales se sustentan en evidencia de ejecución. Ambas clases de evidencia se recogen en los dos apartados siguientes.

6.8.1. Requisitos funcionales

RF-1 (detección de misconfiguraciones individuales) queda verificado por los resultados de la Capa 1 (Sección 6.2: F1 macro = 0,9946, cero falsos negativos en test). RF-2 (detección de cadenas de ataque) queda verificado con una salvedad: la Capa 2 y el *ensemble* recuperan 4 de las 5 cadenas de ataque del conjunto de test dentro del top-5 del *ranking* (Secciones 6.3 y 6.4) y clasifican correctamente 3 de esas 5 cadenas en la matriz de confusión por *argmax* (F1 *attack_chain* = 0,667, Sección 6.4); el requisito se cumple para el caso de uso de priorización (RF-

5) pero no de forma perfecta para la clasificación exacta de cada cadena. Ambos requisitos se confirman además mediante un test de integración de extremo a extremo: dado un directorio de manifiestos de prueba con flags de escape conocidas, la salida del comando `kubescan scan` produce el veredicto esperado (`ATTACK_CHAIN`) con *ensemble_score* por encima del umbral de clasificación; este test forma parte de la suite descrita en la Sección 5.9. RF-5 (priorización de riesgos) queda verificado por la métrica global de la Sección 6.7. RF-3 y RF-4 (interfaz de línea de comandos y formatos de salida) no admiten una métrica cuantitativa dedicada y se verifican operacionalmente a continuación.

RF-3 — Interfaz de línea de comandos. Los dos comandos definidos en la Sección 5.7 (`kubescan scan <dir>` y `kubescan live`) se ejercitaron exitosamente sobre los casos de uso documentados en el Apéndice B, incluyendo el análisis de un directorio de manifiestos y la consulta directa a un clúster en ejecución.

RF-4 — Formatos de salida. El comando `kubescan scan` produce tanto el informe en texto legible como la salida JSON estructurada; el campo `flags` de esta última, verificado en RNF-1 a continuación, es la evidencia de que el formato estructurado expone la información necesaria para su consumo automatizado.

6.8.2. Requisitos no funcionales

Los cuatro requisitos no funcionales definidos en el Capítulo 4 se verifican mediante evidencia operacional obtenida sobre la implementación descrita en el Capítulo 5.

Trazabilidad (RNF-1). El campo `flags` de la salida JSON lista explícitamente las características de seguridad activas en cada manifiesto, y el campo `escape_capable` indica qué nodos tienen capacidad de escape. Esto permite al operador de seguridad comprender y auditar las razones concretas de la clasificación de riesgo producida por el modelo.

Reproducibilidad (RNF-2). La cadena de resolución de *checkpoints* descrita en la Sección 5.7 garantiza que el mismo directorio de manifiestos produce siempre el mismo informe dado el mismo conjunto de pesos del modelo.

Instalabilidad (RNF-3). El paquete se instaló satisfactoriamente en entornos Python 3.10 y 3.11 mediante `pip install -e kubescan/` en sistemas macOS y Linux (Ubuntu 22.04). Las dependencias principales (*PyTorch Geometric*, *scikit-learn*, *Click*) se resuelven automáticamente sin compiladores externos.

Latencia (RNF-4). Se midió el tiempo de análisis sobre cuatro clústeres de prueba de diferente tamaño: 12 manifiestos (0,8 s), 47 manifiestos (1,4 s), 128 manifiestos (3,1 s) y 312 manifiestos (7,2 s) en un equipo con CPU Intel Core i7 de octava generación sin GPU. El mayor de los clústeres de prueba disponibles alcanza 312 manifiestos, de modo que el umbral de 500 manifiestos fijado en el requisito no llegó a medirse de forma directa. La progresión observada es aproximadamente lineal —en torno a 23 ms por manifiesto en el punto de mayor carga—, por lo que la extrapolación a 500 manifiestos sitúa el tiempo esperado en torno a 12 s, muy por debajo del límite de 60 s; el cumplimiento de RNF-4 se sostiene, por tanto, sobre una extrapolación y no sobre una medición en el tamaño nominal del requisito.

6.9. Evaluación de usabilidad y aplicabilidad con usuarios expertos

Además de la verificación de requisitos de la Sección 6.8, se realizó una evaluación de usabilidad y aplicabilidad de la herramienta con **usuarios expertos**, siguiendo el protocolo descrito en el repositorio (Anexo A). Participaron **tres profesionales** con experiencia en *Kubernetes* y CI/CD, a los que se entregó una guía de tareas con órdenes listas para ejecutar y un cuestionario en línea, en formato autoservicio asíncrono (≈ 10 minutos por participante). El instrumento se generó de forma reproducible mediante un *script* versionado (véase Anexo A) y el protocolo se depuró mediante una prueba piloto simulada, sin participantes reales, cuyo único objetivo fue verificar la consistencia del cuestionario y del guion de tareas antes de la sesión con los expertos. La muestra reducida ($n = 3$) se asume explícitamente como amenaza a la validez (Sección 6.9.5); aun así, tres participantes cubren una fracción sustancial de los problemas de

usabilidad en pruebas formativas (Nielsen, 2000).

6.9.1. Perfil de los participantes

La Tabla 17 resume el perfil de los tres participantes expertos, seleccionados por su experiencia operando *Kubernetes* y en seguridad de contenedores.

Tabla 17. Perfil de los participantes expertos

Participante	Rol	Años K8s	CI/CD	Seguridad
P1	Desarrollo/IA	3–5	Habitual	Alta
P2	DevOps/SRE	1–3	Habitual	Alta
P3	Desarrollo/IA	3–5	Habitual	Media

Fuente: elaboración propia.

6.9.2. Éxito por tarea

Cada participante ejecutó cinco tareas: instalar la herramienta (T1), realizar un escaneo básico e identificar el veredicto (T2), interpretar el informe con `--show-nodes` (T3), producir la salida JSON (T4) y, opcionalmente, escanear un caso propio (T5). La Tabla 18 recoge la tasa de éxito (logrado = 1; logrado con ayuda = 0,5; no logrado = 0).

Tabla 18. Tasa de éxito por tarea (3 participantes)

Tarea	T1	T2	T3	T4	T5	Global
Éxito	100 %	100 %	100 %	83 %	67 %	90 %

Fuente: elaboración propia.

El núcleo del flujo de trabajo —instalación, escaneo e interpretación del informe— se completó sin ayuda por los tres participantes. Las únicas fricciones fueron puntuales: un participante necesitó ayuda para extraer campos de la salida JSON (T4) y la tarea opcional sobre un caso propio (T5) se completó con ayuda en dos casos. La tasa de éxito global del 90 % (Tabla 18)

refleja, por tanto, un flujo de trabajo principal robusto con puntos de fricción concentrados en tareas secundarias u opcionales.

6.9.3. Usabilidad percibida (SUS)

La usabilidad se midió con la escala SUS de diez ítems (Brooke, 1996), que produce una puntuación en el rango 0–100. La media obtenida fue de **88,3 ± 10,4** (puntuaciones individuales de 100, 80 y 85), consistente con la media de referencia del sector (68) y situada en la banda cualitativa «excelente» de la escala de adjetivos de Bangor, Kortum, y Miller (2009). Con $n = 3$, sin embargo, el intervalo de confianza al 95 % de la media abarca [62,5; 114,2] y contiene ese valor de referencia, por lo que los datos no permiten afirmar que la herramienta se sitúe por encima de él. La puntuación debe interpretarse como indicativa y no como una estimación precisa del nivel de usabilidad percibida.

6.9.4. Aplicabilidad y análisis cualitativo

Los participantes valoraron cuatro afirmaciones de aplicabilidad (escala 1–5): integración en CI/CD o auditoría (A1), ajuste de la priorización de riesgo a su forma de auditar (A2), accionabilidad del informe (A3) y confianza en el veredicto (A4). Las medias fueron A1 = 4,3, A2 = 4,3, A4 = 4,3 y, como punto más bajo, A3 = 3,7. Con tres respuestas por ítem, estas medias son sensibles a una única puntuación y conviene acompañarlas de su dispersión: en A3 las puntuaciones individuales fueron 5, 2 y 4, de manera que el descenso de la media hasta 3,7 procede íntegramente de la valoración de un solo participante (P2), mientras que los otros dos se sitúan en el rango alto de la escala. Como fortaleza, un participante destacó exactamente la contribución central del trabajo: la herramienta «no solo te dice qué está mal en un manifiesto, sino que conecta varios problemas pequeños para mostrarte» una cadena de ataque, en lugar de fallos aislados; otros valoraron la interpretabilidad del informe y la rapidez del análisis. La debilidad más recurrente en las respuestas abiertas es la **accionabilidad**: el informe comunica el riesgo pero no las acciones concretas de remediación ni las reglas subyacentes al veredicto. Dos participantes la mencionaron en el apartado abierto —uno expresó que el JSON «muestra el estado actual pero no las acciones que debería tomar» y otro la dificultad de «confiar en un puntaje sin conocer bien qué reglas concretas hay detrás»—, si bien sólo uno de ellos la trasladó a la

escala numérica, ya que el segundo puntuó A3 con un 4. La convergencia entre el registro cualitativo y el cuantitativo es, por tanto, parcial. Esta limitación se recoge como línea de trabajo futuro (explicabilidad de reglas y recomendaciones de remediación) en el Capítulo 7. Los casos de uso propuestos —*gate* en el *pipeline* de CI/CD antes de desplegar a producción y auditoría de clústeres— coinciden con el paradigma *shift-left* que motiva el trabajo.

6.9.5. Amenazas a la validez de la evaluación

El tamaño de la muestra ($n = 3$) limita la precisión de las estimaciones puntuales, especialmente de la media SUS, por lo que los resultados se reportan como indicativos y no concluyentes. Los perfiles cubren desarrollo/IA y DevOps/SRE pero no un rol de Quality Assurance (Aseguramiento de la Calidad) (QA) de IaC puro, lo que acota la generalización. Por último, la participación voluntaria introduce un posible sesgo de autoselección. Ampliar la muestra y diversificar los perfiles es la vía directa para robustecer estas conclusiones.

7. Conclusiones y trabajo futuro

Este capítulo cierra el trabajo recogiendo las conclusiones vinculadas a cada objetivo, las consideraciones éticas derivadas del uso de la herramienta, las limitaciones del estudio y las líneas de trabajo futuro que se desprenden de los resultados obtenidos. Las conclusiones siguen el orden expositivo de los resultados del Capítulo 6 —de la Capa 1 al sistema distribuible—, que no coincide con el orden numérico de los objetivos específicos del Capítulo 3; cada conclusión declara explícitamente el objetivo que responde. Las limitaciones (L1–L9) y las líneas de trabajo futuro (TF1–TF8) llevan numeración propia, independiente de la de las conclusiones.

7.1. Conclusiones

Este trabajo ha mostrado la viabilidad de un enfoque híbrido de tres capas para la detección automática de cadenas de ataque en infraestructuras *Kubernetes*. Las conclusiones C1, C2, C4, C5, C6 y C7 responden, respectivamente, a los objetivos OE2, OE4, OE1, OE5, OE3 y OE6 definidos en el Capítulo 3; C3 no cierra un objetivo propio, sino que aporta evidencia complementaria sobre el impacto operacional del resultado de C2. En conjunto, estas conclusiones sostienen el objetivo general planteado en el Capítulo 3 —complementar el análisis estático por manifiesto individual con el contexto estructural del clúster—, cuya evidencia directa es la ablación de componentes recogida en C5: la configuración que emplea únicamente la señal por manifiesto de la Capa 1 desciende de $P@1 = 1,00$ a $P@1 = 0,00$ sobre el conjunto de test, de modo que el contexto de grafo no es un añadido marginal sino la componente que ordena los clústeres de cadena real. Las conclusiones principales son:

C1 — La Capa 1 supera ampliamente el objetivo de diseño (OE2). El clasificador *Random Forest* alcanza $F1 \text{ macro} = 0,9946$ y $AUC\text{-}ROC = 0,9986$ en test, superando el umbral objetivo del 0,85 en 14,5 puntos porcentuales. El modelo de severidad de tres clases logra $F1 \text{ macro} = 0,9838$, con la clase *high-critical* (96 muestras de test) en 0,9789 — el resultado más débil de los tres, aunque por encima de 0,95—; sus 3 errores se clasifican todos como *low-medium*, sin ningún

manifiesto crítico degradado a *clean*.

C2 — La Capa 2, en su configuración final, alcanza el objetivo de Precisión@5 (OE4). La GAT de 3 capas con *embedding* de tipos de arista, entrenada con entropía cruzada ponderada y selección de *checkpoints* por Precisión@5 bajo el particionado consciente de familias sobre el corpus completo de Rahman et al. (599 grafos originales, 37 cadenas), alcanza $P@5 = 0,720 \pm 0,160$ y $F1 \text{ macro} = 0,803 \pm 0,137$ en los 5 pliegues de validación cruzada, superando el objetivo de diseño $P@5 > 0,70$ con la semilla desplegada. Dos matices acotan esta cifra: a través de tres semillas de entrenamiento la media es de $0,68 \pm 0,03$ (objetivo dentro de una desviación típica, con la variación concentrada íntegramente en el pliegue de la familia *badpods_**), y alcanzar el objetivo exigió diagnosticar mediante una ablación factorial 2×2 que una primera configuración con *focal loss* y selección por F1 macro ($P@5 = 0,480 \pm 0,271$) atribuía erróneamente al corpus una regresión causada por esas dos elecciones (Sección 6.3.4). La ablación de arquitectura, repetida sobre el corpus completo con la configuración final (Tabla 14), muestra que la atención sobre tipos de arista aporta +9,2 puntos de F1 y +4 puntos de $P@5$ frente a una GCN sin tipos de arista, y que la profundidad (2 frente a 3 capas) no es el factor determinante del ranking. Esta equivalencia en la media no debe leerse como robustez frente a la profundidad: las dos configuraciones difieren por pliegue (+0,142 en el pliegue 3 y $-0,191$ en el 4) y solo coinciden al promediarse (Sección 6.5).

C3 — El *ensemble* final, combinado con la restricción de viabilidad estructural, mantiene un desempeño operacional sólido sobre el conjunto de test. Sobre los 86 grafos de test (5 cadenas de repositorios reales únicos, sin hermanos de plantilla en entrenamiento; techo $P@5 = 1,00$), el sistema completo de tres capas alcanza $P@1 = 1,00$, $P@3 = 1,00$ y $P@5 = 0,80$, recuperando 4 de las 5 cadenas en las primeras 5 posiciones del ranking sin ningún falso positivo de clúster limpio ($FPR_{\text{clean}} = 0,00$). Estas cifras no son atribuibles a la combinación de las tres capas: la ablación de la Tabla 16 muestra que la Capa 2 en solitario alcanza los mismos valores 1,00/1,00/0,80, de modo que el resultado operacional lo sostiene el componente GNN y el *ensemble* lo iguala sin superarlo (C5). $P@1$ y $P@3$ se mantienen idénticos (1,00) a través de las tres semillas de entrenamiento evaluadas, con $P@5$ entre 0,80 y 1,00. Parte esencial del resultado es la restricción de viabilidad estructural (un clúster de un solo manifiesto no puede albergar una cadena multi-salto, Sección 5.6.1): sin ella las métricas de ranking caen a $P@1 = 0,00$ y $P@5 = 0,60$, por-

que 74 de los 86 grafos de test son de un solo nodo. El tamaño reducido del conjunto de test (intervalo de confianza al 95 % de $P@5$: $[0,60, 1,00]$) limita la confianza que puede depositarse en cualquier comparación puntual.

C4 — La construcción del corpus y su protocolo de particionado anti-fuga son la contribución metodológica central (OE1). El conjunto de datos final satisface los criterios cuantitativos de OE1: 2.827 manifiestos (≥ 2.000) y una prevalencia de `TRUE_HOST_PID` del 3,78 % (≥ 2 %). La evolución en seis fases — línea base ($P@5 = 0,40$, 82 grafos), aumentación ($P@5 = 0,52$, 277 grafos), corrección `HOSTPATH_MOUNT` ($P@5 = 0,60$, 307 grafos), dataset extendido con 25 cadenas ($P@5 = 0,88$, 471 grafos, protocolo preliminar), corrección *group-aware* del particionado ($P@5 = 0,72$, mismos 471 grafos) y corpus completo con familias de plantilla atómicas ($P@5 = 0,72$, 599 grafos, resultado final) — enseña dos lecciones metodológicas. Primera: la aumentación de datos exige particionado consciente de grupos, pues parte de la mejora aparente de la cuarta fase procedía de fuga entre variantes aumentadas y sus grafos base de evaluación. Segunda, y descubierta en la fase final: los casi duplicados de plantilla (ocho `badpods_*`, nueve `datadog_*`) constituyen una segunda vía de fuga cuando se reparten entre particiones; su corrección hace que las cifras finales midan generalización entre familias no vistas, una vara de medir más exigente y más honesta que la de las fases 1–5, cuyas métricas estaban infladas por esta contaminación —las fases 1–4 lo estaban además por la fuga entre variantes aumentadas, corregida en la fase 5—.

C5 — El ensemble cumple los criterios de OE5, con una salvedad documentada sobre el valor añadido de los pesos optimizados. La ablación sobre el conjunto de test (Tabla 16) confirma que el componente GNN es indispensable: la configuración RF-sólo colapsa el ranking ($P@1$ de 1,00 a 0,00; $P@5$ de 0,80 a 0,40) porque el *risk score* medio por clúster de los repositorios reales de cadena es ≈ 0 —la media se diluye entre manifiestos mayoritariamente benignos—, mientras que `FPR_clean` = 0,00 se mantiene en todas las configuraciones. Los criterios de OE5 se cumplen: `FPR_clean` = 0 y $P@5$ del ensemble igual a la del mejor componente individual (0,80). Debe señalarse que los pesos optimizados por el GA no superan a los pesos uniformes ni al GNN en solitario: la función objetivo, escalonada, deja los pesos indeterminados sobre mesetas amplias, y el conjunto de ajuste *out-of-fold* (dominado por cadenas de *fixtures* sintéticas) presenta un desplazamiento de distribución respecto a las cadenas reales de test (Sección 6.4).

La aportación del *ensemble* en estos datos es igualar al mejor componente sin incurrir en los puntos débiles de ninguno, no mejorar su ranking.

C6 — El esquema de cinco tipos de arista amplía la cobertura de escalada de privilegios (OE3).

El diseño del grafo de clúster incorpora el tipo de arista RBAC mediante detección de roles privilegiados en dos pasadas sobre los manifiestos, limitando las aristas a cuentas de servicio vinculadas realmente a roles con permisos de escalada. Esta quinta arista está presente tanto en los grafos de entrenamiento como en el componente de producción de *kubescan*. El criterio declarado de OE3 —que la GAT con tipos de arista iguale o supere a una GCN sin ellos en F1 macro y Precisión@5 bajo idéntico protocolo— se considera cumplido: la configuración con tipos de arista supera a la GCN en +9,2 puntos de F1 macro y +4 puntos de P@5 sobre los mismos pliegues (Tabla 14). El cumplimiento debe leerse con el factor de confusión que la propia ablación introduce: el contraste varía a la vez la arquitectura de agregación (atención frente a convolución) y la presencia de tipado de arista, por lo que la ventaja medida no puede repartirse entre ambos factores. La ablación tampoco aísla la contribución específica del tipo de arista RBAC frente a los otros cuatro, por lo que su aporte incremental al ranking de cadenas de ataque queda como trabajo futuro (TF6).

C7 — *kubescan* es una herramienta distribuible, instalable y operacionalmente viable (OE6).

La evaluación funcional de la Sección 6.8 confirma que el sistema se instala sin compiladores externos (*pip install -e kubescan/*), analiza clústeres de hasta 312 manifiestos en menos de 8 segundos en hardware de gama media, produce salida en dos formatos (texto y JSON) adecuados para integración en pipelines CI/CD, e incorpora además un modo opcional de consulta directa a un clúster activo (*kubescan live*) para auditorías en caliente, sin que ello altere la vía principal de análisis sobre manifiestos estáticos. Esa misma verificación registra una salvedad sobre el cumplimiento del requisito RF-2: la Capa 2 y el *ensemble* sitúan 4 de las 5 cadenas de test en el top-5 del *ranking*, pero solo clasifican correctamente 3 de esas 5 cadenas por *argmax* ($F1_{attack_chain} = 0,667$), de modo que el requisito queda cubierto para el caso de uso de priorización y no para la clasificación exacta de cada clúster. La inferencia es reproducible sobre un mismo *backend* de cómputo mediante la resolución determinista de *checkpoints*, evidenciada por el test de integración de extremo a extremo de la Sección 6.8, que obtiene el veredicto esperado sobre un directorio de manifiestos con *flags* de escape conocidas. La reproducibilidad

de las cifras de entrenamiento entre *backends* de cómputo distintos es una cuestión separada, acotada en L6. El prototipo implementado en este trabajo demuestra que el paradigma *shift-left* —detectar cadenas de ataque antes del despliegue, sin requerir acceso al clúster activo— es técnicamente factible y operacionalmente eficiente. Complementariamente, la evaluación de usabilidad y aplicabilidad con usuarios expertos (Sección 6.9) respalda este objetivo desde la perspectiva del usuario: la herramienta obtiene una puntuación **SUS de 88,3** (valoración «excelente») y una aplicabilidad alta —integración en CI/CD, priorización de riesgo y confianza en el veredicto (medias de 4,3 sobre 5)—, con una tasa de éxito del 100 % en las tareas nucleares de instalación, escaneo e interpretación (90 % global sobre las cinco tareas, incluidas la extracción JSON y la tarea opcional). El principal punto de mejora señalado por los participantes es la **accionabilidad** del informe (A3 = 3,7): la herramienta comunica el riesgo pero no las acciones de remediación ni las reglas concretas tras el veredicto, lo que se recoge como limitación (L8) y como trabajo futuro (TF8). Estos resultados deben interpretarse como indicativos por el tamaño de la muestra ($n = 3$, Sección 6.9.5 y limitación L8).

7.2. Consideraciones éticas y uso responsable

kubescan es una herramienta de uso dual: aunque su propósito es defensivo —detectar cadenas de ataque potenciales antes de que sean explotadas— la información que produce (identificación de pods con flags de escape, rutas de privilegio RBAC) podría ser utilizada con fines ofensivos si cayera en manos de un actor no autorizado. En consecuencia, este trabajo adopta los principios de divulgación responsable (*responsible disclosure*) que rigen la investigación en ciberseguridad. Los patrones de ataque detectados por *kubescan* se basan exclusivamente en documentación pública —la guía NSA/CISA (National Security Agency y Cybersecurity and Infrastructure Security Agency, 2022), el trabajo de BishopFox (Art, 2021) y el marco MITRE ATT&CK for Containers (MITRE Corporation y Center for Threat-Informed Defense, 2021)— y no revelan ninguna vulnerabilidad nueva. El código fuente del sistema es de acceso abierto en el repositorio referenciado en el Anexo A, lo que permite la auditoría independiente de las reglas de detección, lo que permite a la comunidad verificar que las señales de riesgo generadas son correctas y no contienen sesgos perjudiciales. El uso de la herramienta sobre clústeres de terceros sin autorización explícita estaría fuera del ámbito previsto y podría constituir un

acceso no autorizado a sistemas informáticos según la legislación aplicable.

7.3. Limitaciones

Los resultados expuestos están acotados por nueve limitaciones, que abarcan la composición del corpus, el protocolo de evaluación, la definición de las etiquetas, el entorno de cómputo y el alcance de la evaluación con usuarios. Cada limitación se enuncia con la evidencia cuantitativa que la sustenta y con la línea de trabajo futuro que la atiende, cuando existe. La Sección 7.3.1 reagrupa las nueve según el tipo de amenaza a la validez que representan.

L1 — Concentración por familias y varianza entre pliegues. El particionado consciente de familias, al mantener cada familia de plantilla como unidad atómica, concentra las cadenas de validación de cada pliegue en 1, 1, 4, 5 y 5 familias independientes respectivamente: el pliegue 0 evalúa íntegramente la familia `datadog_*` ($F1 = 1,0$; $P@5 = 1,0$) y el pliegue 1 la familia `badpods_*` ($F1 = 0,58$), de modo que la varianza entre pliegues ($\sigma = 0,137$ para $F1$; $0,160$ para $P@5$) mide en gran parte la dispersión de dificultad entre familias, no inestabilidad del modelo — el análisis multi-semilla (Sección 6.3.6) muestra que cuatro de los cinco pliegues puntúan de forma idéntica con las tres semillas. El tamaño muestral efectivo por pliegue (número de familias, no de cadenas) es la limitación subyacente, y solo puede crecer incorporando repositorios de cadena estructuralmente independientes (TF1).

L2 — Imputación por mediana de las características extendidas. Seis de las siete características extendidas —todas salvo `HOSTPATH_MOUNT`, poblada en las 2.827 filas— sólo toman su valor real cuando el manifiesto de origen ha sido escaneado con éxito. El análisis sintáctico propio las obtiene para el 32,6 % de las filas y la salida de *Checkov* las cubre para otro 41,6 %, de modo que las 731 filas restantes (25,9 % del corpus) reciben la mediana de columna y ven diluida la señal de esas seis características (Sección 5.2). Una fracción de esa carencia es irreducible, pues 46 manifiestos del corpus de Rahman et al. responden 404 o 403 en el servidor de origen y no admiten recuperación; el resto depende de la cobertura alcanzable por las herramientas de escaneo sobre los manifiestos efectivamente disponibles. Un experimento de reescaneo sobre las filas recuperables acota el alcance de la limitación para la Capa 1: la $F1$ macro permanece inalterada ($0,9946$, $\Delta = 0,0000$) y la perturbación del `risk_score` por fila presenta media

0,0030 y máximo 0,1104, un orden de magnitud por debajo de la variabilidad entre semillas documentada para la Capa 2 ($\sigma = 0,033$ en P@5, Sección 6.3.6). No se ha medido, en cambio, el efecto sobre las salidas de las Capas 2 y 3, cuya cuantificación exigiría reconstruir los grafos de clúster y reentrenar el sistema completo.

L3 — Sesgo de muestreo en el dataset tabular. Los 10 repositorios más representados suponen el 47,6 % del dataset, y *gitcontroller* por sí solo aporta el 9,9 %. Un esquema de validación cruzada por repositorio ofrecería estimaciones más conservadoras de la generalización del modelo.

L4 — Evaluación en clústeres de producción reales. Toda la evaluación se ha realizado sobre repositorios públicos. La validación en entornos de producción de organizaciones reales es la siguiente etapa crítica para confirmar la validez externa del sistema.

L5 — Etiquetado derivado de reglas sobre el mismo espacio de características. Esta circularidad afecta a las dos capas de aprendizaje. Las etiquetas de grafo (clean / isolated / attack_chain) se generan mediante una regla determinista definida sobre las mismas *flags* y aristas que observan los modelos (Sección 5.3). En la Capa 1 la relación es aún más estrecha: sobre las 1.906 filas procedentes de Rahman et al. la etiqueta binaria coincide exactamente con la disyunción de ocho de las características de entrada, de modo que reentrenar restringiéndose a esa fuente produce F1 macro = 1,0000 (Sección 6.2.2). La F1 de 0,9946 sobre el corpus completo mide, en consecuencia, con qué fidelidad el modelo recupera esa regla —y las etiquetas heterogéneas de las demás fuentes— bajo imputación y valores ausentes, no su capacidad de detectar misconfiguraciones con un criterio ajeno a ella. El sistema aprende, por tanto, una aproximación robusta de dicha regla bajo ruido, enmascaramiento y observabilidad parcial — no una noción de cadena de ataque independiente de la regla. Esta circularidad es común en la literatura de detección de misconfiguraciones, pero limita el alcance de la afirmación «predice cadenas de ataque». Las vías para romperla son la validación externa frente a herramientas de grafo de ataque sobre clústeres activos (Datadog Security Labs, 2023; WithSecure Labs, 2023), el etiquetado experto de una submuestra, y la confirmación mediante explotación controlada en entornos de laboratorio como *kubernetes-goat* (Akula, 2020).

L6 — No determinismo de CUDA en las operaciones de *scatter* del GNN (hallazgo histórico,

no reverificado sobre el corpus completo). Durante la fase preliminar se observó que, al replicar el entrenamiento de la Capa 2 sobre una GPU NVIDIA A100 (CUDA) en lugar del *backend* MPS/CPU empleado entonces, las métricas de validación cruzada variaban de forma no trivial (F1 macro entre 0,845 y 0,882 frente a 0,917 en el *backend* de referencia de esa fase; P@5 entre 0,77 y 0,92 frente a 0,880), manteniendo semilla, datos, particiones e hiperparámetros idénticos. Estas cifras corresponden a la fase preliminar de 471 grafos (Tabla 11, fase 4, cuyo *backend* de referencia era MPS/CPU); los resultados finales de esta memoria se entrenaron y evaluaron sobre GPU NVIDIA T4 (CUDA), por lo que la amenaza se invierte para el lector que reproduzca en CPU/MPS: es esa réplica la que puede divergir de las cifras reportadas. El experimento no se ha repetido sobre el corpus completo, por lo que se reporta como hallazgo histórico sobre el mecanismo causal, no como una medición vigente sobre el modelo desplegado. Se descartaron como causa la precisión TF32 (confirmado en tiempo de ejecución que `torch.backends.cuda.matmul.allow_tf32` permanece desactivada) y la paralelización del cargador de datos (el conjunto es estático en memoria y el orden de muestreo está fijado por un generador con semilla). La causa confirmada son las operaciones `scatter_add/scatter_reduce` empleadas por GATConv y por las capas de *pooling* global (`global_max_pool`, `global_mean_pool`), que en CUDA se implementan mediante `atomicAdd` sin versión determinista disponible — extremo confirmado por los mantenedores de *PyTorch Geometric* en el seguimiento público de incidencias del proyecto. El orden de acumulación en punto flotante depende de la planificación de hilos de la GPU y, al no ser la suma en punto flotante asociativa, pequeñas diferencias numéricas cambian el *ranking* sobre un conjunto de validación reducido (471 grafos, entre 4 y 5 cadenas de ataque por pliegue en ese momento), amplificando el efecto sobre P@5 y F1 macro. Se incorporaron banderas de determinismo específicas de CUDA (`torch.use_deterministic_algorithms`, `cuda.deterministic`) que, aunque no resuelven la ausencia de una implementación determinista de `scatter_add`, sí lograron reproducibilidad exacta entre ejecuciones repetidas sobre la misma configuración de GPU. Esto indica que la brecha observada no es ruido aleatorio entre ejecuciones sino una divergencia numérica fija y reproducible entre *backends* (CUDA frente a MPS/CPU); su cierre completo requeriría sustituir la agregación por la ruta `SparseTensor` de *PyTorch Geometric*, documentada como determinista pero no evaluada en este trabajo, ni reverificada sobre el corpus completo.

L7 — Las métricas de las fases previas a la corrección por familias no son comparables con las finales, y las estimaciones finales llevan intervalos amplios. Las evaluaciones de las fases 1–5 estaban infladas por dos vías de fuga de información corregidas sucesivamente (variantes aumentadas en la fase 5 y familias de plantilla en la fase 6): el modelo «generalizaba» a casi duplicados de grafos vistos en entrenamiento. Tras la corrección, las cifras finales miden generalización a familias y repositorios no vistos — una cantidad distinta y sistemáticamente menor, por lo que ninguna comparación directa entre fases debe leerse como progresión del modelo. Como segunda cara de la misma limitación, el conjunto de test contiene solo 5 cadenas (todos los intervalos de confianza de test tienen una anchura $\geq 0,4$) y el *pool out-of-fold* contiene 32 cadenas de las que 15 son *fixtures* sintéticas: la evidencia sobre generalización a cadenas reales descansa en pocas muestras independientes, y ampliarlas es la vía prioritaria de trabajo futuro (TF1).

L8 — Alcance de la evaluación con usuarios y accionabilidad del informe. La evaluación de usabilidad y aplicabilidad se realizó con tres participantes expertos ($n = 3$, Sección 6.9.5), muestra que permite detectar problemas de usabilidad en una prueba formativa pero no estimar con precisión la puntuación SUS de 88,3 ni las medias de aplicabilidad; los perfiles cubren desarrollo/IA y DevOps/SRE, sin un rol de QA de laC puro, y la participación voluntaria admite sesgo de autoselección. Esas cifras se reportan, en consecuencia, como indicativas y no como estimaciones poblacionales. La propia evaluación identifica además una carencia funcional del sistema entregado: la accionabilidad del informe es la dimensión peor valorada ($A3 = 3,7$), pues la salida comunica el nivel de riesgo pero no las acciones de remediación ni las reglas concretas que sostienen el veredicto, lo que limita su utilidad para el operador que debe corregir la configuración (TF8).

L9 — Hiperparámetros fijados a priori. El número de cabezas de atención, la tasa de aprendizaje, la anchura oculta y la estrategia de *pooling* (*mean+max*) de la Capa 2 se fijaron a priori a partir de valores habituales en la literatura, sin búsqueda sistemática sobre los pliegues de validación (Sección 5.5). Las únicas elecciones de diseño contrastadas empíricamente son las cubiertas por las dos ablaciones realizadas: función de pérdida y criterio de selección de *check-points* (Sección 6.3.4) y arquitectura de agregación con o sin tipos de arista (Tabla 14). Las métricas reportadas corresponden, por tanto, a una configuración razonable pero no optimizada, y

no puede descartarse que un barrido sistemático de hiperparámetros altere las comparaciones entre configuraciones sobre un conjunto de validación tan reducido (TF6).

7.3.1. Amenazas a la validez

Las limitaciones L1–L9 se clasifican a continuación en cuatro categorías de amenaza a la validez: de constructo, interna, de conclusión y externa. La clasificación no añade limitaciones a las ya enunciadas, sino que las agrupa por el tipo de amenaza metodológica que cada una representa. Una misma limitación puede aparecer en más de una categoría cuando compromete simultáneamente varios aspectos de la validez.

Validez de constructo (¿miden las métricas lo que se pretende medir?): L6 cuestiona si las métricas reportadas en esta memoria (*backend* CUDA/T4) coinciden con las que obtendría una réplica en un *backend* CPU/MPS, dado el no determinismo documentado en las operaciones de *scatter*. L5 cuestiona si la etiqueta de grafo (derivada de reglas sobre el mismo espacio de características que observan los modelos) constituye un constructo de «cadena de ataque» independiente de la regla de etiquetado, o una aproximación circular a ella. La métrica FPR_clean plantea una tercera cuestión de constructo: mide la fracción de clústeres limpios dentro del top-*k* del *ranking*, no una tasa de falsos positivos en sentido estricto —que normalizaría por el total de clústeres limpios—, de modo que el valor FPR_clean = 0,00 invocado en C3 y C5 debe leerse como ausencia de clústeres limpios en la cabeza del *ranking* y no como ausencia de falsas alarmas sobre el conjunto completo (Sección 4.4).

Validez interna (¿las conclusiones causales están justificadas por el diseño experimental?): L7 impide atribuir diferencias entre fases experimentales al modelo, porque el protocolo de evaluación cambió entre ellas; la ablación factorial de la Sección 6.3.4 es el único contraste interno con protocolo constante. L2 acota la validez interna de las seis características extendidas que se imputan por mediana en el 25,9 % de las filas frente a las obtenidas por escaneo directo del manifiesto, si bien el reescaneo de las filas recuperables dejó la F1 macro de la Capa 1 sin variación. L9 añade una restricción del mismo orden: al haberse fijado los hiperparámetros a priori, las comparaciones entre configuraciones se establecen sobre un único punto del espacio de diseño y no sobre el óptimo de cada alternativa.

Validez de conclusión (¿son estadísticamente fiables las estimaciones puntuales reportadas?): el tamaño del conjunto de test (86 grafos, 5 cadenas) y del *pool out-of-fold* (513 grafos, 32 cadenas) se traduce en los intervalos de confianza amplios reportados en la Sección 6.4 (al 95 %: $P@5 \in [0,60, 1,00]$, $FPR_clean \in [0,00, 0,40]$ y $F1\ macro \in [0,66, 1,00]$), que limitan la confianza que puede depositarse en cualquier comparación puntual entre configuraciones del *ensemble* (C5). El intervalo de FPR_clean merece atención específica: el valor puntual 0,00 invocado en C3 y C5 es compatible con tasas de hasta 0,40, de modo que la ausencia de clústeres limpios en la cabeza del *ranking* de test no autoriza a afirmar que el sistema no producirá falsas alarmas sobre corpus mayores. A ello se suma la concentración por familias (L1): el tamaño muestral efectivo de la validación cruzada es el número de familias independientes por pliegue (1–3), no el número nominal de cadenas. Por su parte, L8 acota del mismo modo las cifras de usabilidad: con $n = 3$ participantes, la puntuación SUS de 88,3 y las medias de aplicabilidad son estimaciones indicativas, no medidas con precisión cuantificable.

Validez externa / generalización: L3 (sesgo de muestreo por repositorio) y L4 (ausencia de evaluación en clústeres de producción reales) acotan directamente hasta qué punto los resultados generalizan más allá de los repositorios públicos utilizados. El desplazamiento de distribución entre el *pool* de ajuste del GA (dominado por *fixtures* sintéticas) y las cadenas reales de test (Sección 6.4) es una amenaza externa adicional identificada empíricamente: los pesos del *ensemble* ajustados sobre cadenas sintéticas no aportan ventaja sobre cadenas reales. La composición de la muestra de usuarios (L8), restringida a perfiles de desarrollo/IA y DevOps/SRE y obtenida por participación voluntaria, acota igualmente la generalización de las conclusiones de usabilidad a otros roles operativos.

7.4. Líneas de trabajo futuro

Los resultados de este trabajo permiten formular las siguientes recomendaciones de trabajo futuro, ordenadas por impacto esperado. La mayoría atiende a una o varias de las limitaciones L1–L9 de la Sección 7.3, referenciadas por su identificador en el enunciado de cada recomendación. Las dos primeras (TF1 y TF2) son las de mayor impacto potencial sobre la validez de las métricas reportadas.

TF1 — Ampliar la población de cadenas reales estructuralmente independientes. Las limitaciones L1 y L7 comparten la misma causa raíz: pocas familias de cadena independientes. Cada nueva familia de plantilla añade poco (sus miembros son casi duplicados), mientras que cada repositorio real de cadena añade una muestra independiente que aumenta el tamaño muestral efectivo de la validación cruzada, estrecha los intervalos de test y reduce el desplazamiento de distribución del *pool* de ajuste del GA. La incorporación dirigida de repositorios de infraestructura de organizaciones de código abierto y de entornos de laboratorio multiclúster —priorizando diversidad estructural sobre volumen— es la línea de mayor impacto esperado de este trabajo.

TF2 — Implementar P@5 global como métrica alternativa. En lugar de P@5 por pliegue, evaluar el ranking del modelo sobre el conjunto completo de grafos en un único ranking global aumentaría el número de candidatos ordenados por evaluación y reduciría la granularidad escalonada (en pasos de 0,2) de la P@5 por pliegue, que amplifica la varianza entre pliegues señalada en L1.

TF3 — Incorporar análisis semántico de RBAC completo. El parser de YAML actual identifica roles privilegiados por nombre y por verbos de escalada. Una extensión natural es el análisis de la cadena completa Role/ClusterRole → RoleBinding → ServiceAccount → Pod para detectar rutas de escalada de privilegios mediante RBAC que no requieran flags de escape directas.

TF4 — Validación cruzada dejando un repositorio fuera. La estrategia *leave-one-repo-out* ofrece estimaciones más conservadoras de la generalización que la validación cruzada por fila, y es especialmente relevante dada la concentración del dataset en pocos repositorios.

TF5 — Modo de análisis continuo (*admission controller*). La integración de *kubescan* como un *validating admission webhook* de Kubernetes permitiría bloquear el despliegue de manifiestos que eleven el riesgo de cadena de ataque del clúster en tiempo real, sin necesidad de análisis *post-hoc*.

TF6 — Ablación de *pooling* e hiperparámetros restantes. La ablación de arquitectura (Tabla 14) ya cuantifica empíricamente GAT frente a GCN y 3 capas frente a 2. Queda pendiente extender ese mismo protocolo controlado (mismos pliegues, mismas semillas) a la elección de

mean+max pooling frente a *mean-only*, así como a un barrido más amplio de hiperparámetros del optimizador (número de cabezas de atención, *learning rate*, anchura oculta) que en este trabajo se fijaron a priori sin búsqueda sistemática (L9, Sección 5.5). Este mismo protocolo debería extenderse a una ablación por tipo de arista que aísle la contribución incremental de la arista RBAC frente a los otros cuatro tipos, cerrando la cuestión planteada en C6.

TF7 — Ajuste del *ensemble* robusto al desplazamiento de distribución. Los pesos del GA se ajustan sobre un *pool out-of-fold* en el que 15 de las 32 cadenas son *fixtures* sintéticas con *risk scores* RF altos, mientras que las cadenas reales de test tienen *risk score* medio ≈ 0 ; tres refinamientos evaluados (desempate por *mean reciprocal rank*, agregación del *pool* por familias, ajuste sobre el *ranking* con restricción estructural) no corrigieron el sesgo (Sección 6.4). Las vías naturales son ajustar sobre un *pool* restringido a cadenas de repositorios reales (viable a medida que TF1 amplíe esa población) o sustituir P@5 por una función objetivo continua menos escalonada, que reduzca las mesetas donde los pesos quedan indeterminados.

TF8 — Explicabilidad y recomendaciones de remediación. La evaluación con usuarios expertos (Sección 6.9) identificó la accionabilidad del informe como el principal punto de mejora (L8): dos participantes echaron en falta que la herramienta indicara *qué* corregir y expusiera las reglas concretas tras la puntuación de riesgo. Como trabajo futuro, el informe podría enriquecerse con recomendaciones de remediación por manifiesto (por ejemplo, la corrección de configuración asociada a cada *flag* de escape detectada) y con una explicación de la contribución de cada capa al veredicto, reforzando la confianza del operador sin sacrificar la brevedad del *ranking*.

Referencias bibliográficas

- Akula, M. (2020). *Kubernetes Goat: Interactive Kubernetes security learning playground*. GitHub. Descargado de <https://github.com/madhuakula/kubernetes-goat> (Accedido: 14 de julio de 2026)
- ARMO Ltd. (2021). *Kubescape: Open-source Kubernetes security platform*. Open source tool, CNCF incubating project. <https://github.com/kubescape/kubescape>. (Accedido: 14 de julio de 2026)
- Art, S. (2021). *Bad pods: Kubernetes pod privilege escalation*. BishopFox Blog. Descargado de <https://bishopfox.com/blog/kubernetes-pod-privilege-escalation> (Accedido: 14 de julio de 2026)
- Bangor, A., Kortum, P., y Miller, J. (2009). Determining what individual SUS scores mean: Adding an adjective rating scale. *Journal of Usability Studies*, 4(3), 114–123.
- Bilot, T., Madhoun, N. E., Agha, K. A., y Zouaoui, A. (2023). Graph neural networks for intrusion detection: A survey. *IEEE Access*, 11, 49114–49139. doi: 10.1109/ACCESS.2023.3275789
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi: 10.1023/A:1010933404324
- Bridgecrew. (2021). *Checkov: Open source static analysis for infrastructure as code*. GitHub. Descargado de <https://github.com/bridgecrewio/checkov> (Accedido: 14 de julio de 2026)
- Brooke, J. (1996). SUS: A quick and dirty usability scale. En P. W. Jordan, B. Thomas, B. A. Weerdmeester, y I. L. McClelland (Eds.), *Usability evaluation in industry* (pp. 189–194). London: Taylor & Francis.
- Cloud Native Computing Foundation. (2022). *CNCF annual survey 2021*. CNCF Report. Descargado de <https://www.cncf.io/reports/cncf-annual-survey-2021/> (Publicado en febrero de 2022. Accedido: 14 de julio de 2026)
- Datadog Security Labs. (2023). *KubeHound: Identifying attack paths in Kubernetes clusters*. Open source tool. <https://github.com/DataDog/KubeHound>. (Publicado en octubre de 2023. Accedido: 14 de julio de 2026)

- Fey, M., y Lenssen, J. E. (2019). Fast graph representation learning with PyTorch Geometric. En *Iclr workshop on representation learning on graphs and manifolds*. Descargado de <https://arxiv.org/abs/1903.02428>
- Hagberg, A. A., Schult, D. A., y Swart, P. J. (2008). Exploring network structure, dynamics, and function using NetworkX. En *Proceedings of the 7th python in science conference (scipy)* (pp. 11–15). Descargado de https://conference.scipy.org/proceedings/SciPy2008/paper_2/
- Hamilton, W. L. (2020). *Graph representation learning*. Morgan & Claypool. doi: 10.2200/S01045ED1V01Y202009AIM048
- Hamilton, W. L., Ying, Z., y Leskovec, J. (2017). Inductive representation learning on large graphs. En *Advances in neural information processing systems (neurips)* (Vol. 30).
- Holland, J. H. (1975). *Adaptation in natural and artificial systems*. University of Michigan Press.
- Hutchins, E. M., Cloppert, M. J., y Amin, R. M. (2011). Intelligence-driven computer network defense informed by analysis of adversary campaigns and intrusion kill chains. En *Proceedings of the 6th international conference on information warfare and security (iciw)* (pp. 113–125).
- Jabeen, G., Rahim, S., Afzal, W., Khan, D., Khan, A. A., Hussain, Z., y Bibi, T. (2022). Machine learning techniques for software vulnerability prediction: a comparative study. *Applied Intelligence*, 52(15), 17614–17635. doi: 10.1007/s10489-022-03350-5
- Kipf, T. N., y Welling, M. (2017). Semi-supervised classification with graph convolutional networks. En *International conference on learning representations (iclr)*. Descargado de <https://openreview.net/forum?id=SJU4ayYgl>
- Li, Z., Zeng, J., Chen, Y., y Liang, Z. (2022). AttackKG: Constructing technique knowledge graph from cyber threat intelligence reports. En *Computer security – esorics 2022* (pp. 589–609). doi: 10.1007/978-3-031-17140-6_29
- Lin, T.-Y., Goyal, P., Girshick, R., He, K., y Dollár, P. (2017). Focal loss for dense object detection. En *Proceedings of the ieee international conference on computer vision (iccv)* (pp. 2980–2988). doi: 10.1109/ICCV.2017.324
- Lo, W. W., Layeghy, S., Sarhan, M., Gallagher, M., y Portmann, M. (2022). E-GraphSAGE: A graph neural network based intrusion detection system for IoT. En *Ieee/ifip network operations and management symposium (noms)*. doi: 10.1109/NOMS54207.2022.9789878

- Malul, E., Meidan, Y., Mimran, D., Elovici, Y., y Shabtai, A. (2024). *GenKubeSec: LLM-based Kubernetes misconfiguration detection, localization, reasoning, and remediation*. Descargado de <https://arxiv.org/abs/2405.19954>
- MITRE Corporation, y Center for Threat-Informed Defense. (2021). *ATT&CK for Containers*. <https://ctid.mitre.org/projects/attck-for-containers/>. (Incorporado en ATT&CK versión 9. Accedido: 14 de julio de 2026)
- Moustafa, N., y Slay, J. (2015). UNSW-NB15: A comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set). En *2015 military communications and information systems conference (milcis)* (pp. 1–6). doi: 10.1109/MilCIS.2015.7348942
- National Security Agency, y Cybersecurity and Infrastructure Security Agency. (2022). *Kubernetes hardening guidance (v1.2)*. NSA/CISA Technical Report. Descargado de https://media.defense.gov/2022/Aug/29/2003066362/-1/-1/0/CTR_KUBERNETES_HARDENING_GUIDANCE_1.2_20220829.PDF (Publicado originalmente en agosto de 2021; revisión v1.2, agosto de 2022. Accedido: 14 de julio de 2026)
- Nielsen, J. (2000). *Why you only need to test with 5 users*. Nielsen Norman Group. Descargado de <https://www.nngroup.com/articles/why-you-only-need-to-test-with-5-users/> (Accedido: 14 de julio de 2026)
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... others (2019). PyTorch: An imperative style, high-performance deep learning library. En *Advances in neural information processing systems (neurips)* (Vol. 32). Descargado de <https://arxiv.org/abs/1912.01703>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Édouard Duchesnay (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Rahman, A., Shamim, S. I., Bose, D. B., y Pandita, R. (2023). Security misconfigurations in open source Kubernetes manifests: An empirical study. *ACM Transactions on Software Engineering and Methodology*, 32(4), 1–36. doi: 10.1145/3579639
- Red Hat. (2024). *State of Kubernetes security report 2024* (Inf. Téc.). Red Hat, Inc. Descargado de <https://www.redhat.com/en/resources/kubernetes-adoption-security-market-trends-overview> (Accedido: 14 de julio de 2026)

- StackRox. (2021). *kube-linter: Static analysis for Kubernetes YAML files and Helm charts*. GitHub. Descargado de <https://github.com/stackrox/kube-linter> (Accedido: 14 de julio de 2026)
- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., y Bengio, Y. (2018). Graph attention networks. En *International conference on learning representations (iclr)*. Descargado de <https://openreview.net/forum?id=rJXMpikCZ>
- WithSecure Labs. (2023). *IceKube: Finding complex attack paths in Kubernetes clusters*. Open source tool. <https://github.com/WithSecureLabs/IceKube>. (Accedido: 14 de julio de 2026)
- Xu, K., Hu, W., Leskovec, J., y Jegelka, S. (2019). How powerful are graph neural networks? En *International conference on learning representations (iclr)*. Descargado de <https://openreview.net/forum?id=ryGs6iA5Km>
- Zhong, M., Lin, M., Zhang, C., y Xu, Z. (2024). A survey on graph neural networks for intrusion detection systems: Methods, trends and challenges. *Computers & Security*, 141, 103821. doi: 10.1016/j.cose.2024.103821
- Zhou, J., Cui, G., Hu, S., Zhang, Z., Yang, C., Liu, Z., ... Sun, M. (2020). Graph neural networks: A review of methods and applications. *AI Open*, 1, 57–81. doi: 10.1016/j.aiopen.2021.01.001

Anexo A. Código fuente y datos analizados

El código fuente completo del sistema *kubescan*, incluyendo los *scripts* de adquisición de datos, entrenamiento de modelos, construcción de grafos y la interfaz de línea de comandos, se encuentra disponible en el siguiente repositorio de GitHub:

<https://github.com/ObedRav/kubescan>

El repositorio incluye los siguientes componentes:

- **kubescan/**: paquete Python instalable con la Command-Line Interface (Interfaz de Línea de Comandos) (CLI) y los modelos de inferencia.
- **kubescan/tests/**: batería de pruebas automatizadas, con siete módulos unitarios (`test_yaml_parser.py`, `test_graph_builder.py`, `test_gat_encoder.py`, `test_rf_classifier.py`, `test_ga_ensemble.py`, `test_device_utils.py` y `test_properties.py`, este último basado en pruebas de propiedades con *Hypothesis*) y una prueba de integración de extremo a extremo sobre la CLI (`integration/test_cli_scan.py`).
- **research/scripts/**: *scripts* de adquisición y preprocesamiento de los manifiestos YAML (fases 1 y 2).
- **research/models/**: código de entrenamiento del Random Forest (`train_rf.py`), de la GAT (`train_gnn.py`), y del Algoritmo Genético (`run_ga_ensemble.py`).
- **research/data/**: los grafos de clúster en formato `.npz` (NumPy, con campos `x`, `edge_index`, `edge_attr`, `y`, `node_labels` y `risk_scores`) y el dataset tabular en formato `.csv`.
- **research/models/checkpoints/**: *checkpoints* de los 5 modelos GAT entrenados en validación cruzada y el modelo RF (disponible también como enlace simbólico en `kubescan/checkpoints/trained/`).

- `thesis/usability-study/`: protocolo, cuestionario e instrumentos del estudio de usabilidad descrito en la Sección 6.9, junto con la plantilla de resultados y el *script* de agregación `compute_results.py`.
- `Makefile`: objetivos de reproducción del *pipeline* de investigación (`make data`, `make reproduce`).
- `requirements-lock.txt`: fijación exacta de versiones de todas las dependencias transitivas del entorno de entrenamiento.
- `.pre-commit-config.yaml` y `.github/workflows/ci.yml`: controles automáticos de estilo, tipado y ejecución de la batería de pruebas en integración continua.
- `thesis/`: fuentes LaTeX de esta memoria.

Los pesos entrenados se distribuyen junto con el código, de modo que un clon nuevo del repositorio puede ejecutar `kubescan scan` sin reentrenar ningún modelo. El directorio `research/models/checkpoints/` contiene los cinco *checkpoints* de validación cruzada (`gnn_fold_0.pt`–`gnn_fold_4.pt`), el *checkpoint* `gnn_best.pt`, los dos modelos RF serializados en formato `.skops` (`rf_model.skops` y `rf_severity.skops`), los pesos del *ensemble* en `ga_weights.json` y los ficheros de métricas (`cv_results.json`, `rf_results.json`, `ga_results.json` y `test_results.json`). El conjunto ocupa aproximadamente 32 MB y es el mismo que consume la CLI a través del enlace simbólico `kubescan/checkpoints/trained/`.

Para garantizar la reproducibilidad, los resultados finales de esta memoria se entrenaron y evaluaron sobre una GPU NVIDIA T4 (CUDA) con Python 3.12, PyTorch 2.11 (CUDA 12.8), PyTorch Geometric 2.8, scikit-learn 1.6 y NumPy 2.0. Esa configuración corresponde al entorno de entrenamiento e investigación, que exige GPU y las dependencias completas de *PyTorch Geometric*; el paquete distribuible admite un rango de instalación más amplio y su instalación se verificó también en entornos Python 3.10 y 3.11, según se detalla en la Sección 6.8 (RNF-3). Las versiones exactas de todas las dependencias, junto con las semillas, las particiones y las sumas de verificación (*checksums*) de los datos y los *checkpoints*, se registran en `research/models/checkpoints/run_manifest.json`; el flujo completo se reproduce mediante los objetivos del `Makefile` (`make data`, `make reproduce`).

El estudiante es el único autor de todos los *commits* del repositorio. Los datos públicos utilizados provienen de las fuentes citadas en la Sección 5.2.1 (Rahman et al., BishopFox BadPods, Kubernetes Goat y repositorios de seguridad adicionales de dominio público).

Anexo B. Guía de uso y reproducción

La instalación de *kubescan*, la interpretación del informe que produce sobre un caso real y la reproducción del *pipeline* de entrenamiento de investigación descrito en el Capítulo 5 requieren los pasos concretos que se detallan en los apartados siguientes. Los criterios de diseño y las decisiones de implementación que sustentan cada uno de esos pasos se documentan en la Sección 5.7. Salvo indicación en contrario, todos los comandos se ejecutan desde la raíz del repositorio.

B.1. Instalación

El paquete se instala en modo editable desde la raíz del repositorio:

```
pip install -e kubescan/
```

Las versiones de Python soportadas y la resolución de dependencias se verifican en la Sección 6.8 (RNF-3).

B.2. Uso de la interfaz de línea de comandos

B.2.1. Análisis de un directorio de manifiestos

El comando `kubescan scan` analiza un directorio de manifiestos YAML de forma recursiva. A modo de ejemplo, se analiza un directorio con dos manifiestos: un *pod* con montaje del sistema de ficheros del anfitrión y contenedor privilegiado (`pod-privilegiado.yaml`, adaptado de *BishopFox BadPods*), y un *Deployment* sin `securityContext` ni `NetworkPolicy` definidos (`deployment-web.yaml`, adaptado de *Kubernetes Goat*).

La Figura 11 traza el recorrido completo de esta invocación: extracción de características, construcción del grafo, las tres señales de entrada al *ensemble* (RF, GAT y escape) fusionadas por

`EnsembleScorer.score()`, y la clasificación final mediante los umbrales de la Sección 5.6.

Como se observa en la Figura 11, las tres señales convergen ponderadas por w_{rf} , w_{gnn} y w_{esc} (optimizados por el GA) en un único *ensemble_score*; en este caso, la presencia de un nodo con flags de escape activas (`pod-privilegiado.yaml`) lo sitúa muy por encima del umbral de 0,60, lo que da como resultado el veredicto `ATTACK_CHAIN`. La transcripción completa de esta ejecución es la siguiente:

```
$ kubescan scan /tmp/manifests-ejemplo --cluster-name produccion-web
Scanning /tmp/manifests-ejemplo (5 GNN fold models loaded)...
  2 manifest(s) with workload resources found

=====

KUBESCAN · Attack-Chain Risk Report
Cluster : produccion-web
Path    : /tmp/manifests-ejemplo
=====

VERDICT · ATTACK_CHAIN          X HIGH RISK - review immediately

Ensemble score      : 0.9472
Chain probability   : 0.5445   (5-fold GNN ensemble)
Clean probability   : 0.0001
Mean RF risk       : 0.9997
Escape fraction     : 0.5000   (1/2 manifests have escape flags)
Lateral fraction    : 2/2 manifests have lateral flags


Weights: w_rf=0.517  w_gnn=0.115  w_escape=0.368

=====
```

En esa transcripción, el carácter X sustituye al símbolo *Unicode* U+2717 que imprime la herramienta, ausente en la fuente monoespaciada de esta memoria; el resto de los caracteres reproduce literalmente la salida de `cli.py`.

El indicador `--show-nodes` añade un desglose por manifiesto con tres columnas: el *risk score*

Figura 11. Flujo de ejecución de kubescan scan



Fuente: elaboración propia.

del RF, la columna Type y las flags activas. La columna Type no contiene el *kind* del recurso de Kubernetes, sino las etiquetas de capacidad del nodo derivadas de la taxonomía de la Sección 5.8: ESC cuando el manifiesto activa alguna flag de escape, LAT cuando activa alguna flag de movimiento lateral, y ESCLAT cuando concurren ambas. El indicador `--format json` produce el mismo informe en formato JSON estructurado para integración con otras herramientas; la salida de `kubescan scan` sobre `/tmp/manifests-ejemplo`, con los campos de detalle por manifiesto truncados mediante elipsis, es la siguiente:

```
$ kubescan scan /tmp/manifests-ejemplo --cluster-name produccion-web --format json
{
  "cluster": "produccion-web",
  "verdict": "ATTACK_CHAIN",
  "ensemble_score": 0.947236,
  "chain_probability": 0.5445,
  "mean_rf_risk": 0.999711,
  "n_manifests": 2,
  "n_escape_capable": 1,
  "manifests": [
    {
      "file": "pod-privilegiado.yaml",
      "risk_score": 1.0,
      "escape_capable": true,
      "flags": ["TRUE_HOST_PID", "TRUE_HOST_IPC", "..."]
    },
    "..."
  ]
}
```

Los pesos del modelo se resuelven mediante la cadena descrita en la Sección 5.7 (argumento `--checkpoints-dir` → variable de entorno `KUBESCAN_CHECKPOINTS` → enlace simbólico); no es necesario indicarlos explícitamente si el paquete se instaló junto con el repositorio completo.

B.2.2. Análisis de un clúster en ejecución

El comando `kubescan live` aplica el mismo *pipeline* sobre el estado actual de un clúster accesible mediante `kubectl`, sin necesidad de exportar manifiestos manualmente. La herramienta invoca `kubectl` para volcar *pods*, *deployments*, *daemonsets*, *statefulsets*, *replicasets*, *jobs*, *cron-jobs*, *roles* y *rolebindings* a un directorio temporal, y a partir de ahí ejecuta la misma cadena de extracción, construcción del grafo y puntuación del *ensemble*. Las dos formas de invocación admitidas son las siguientes:

```
kubescan live -n produccion
kubescan live --all-namespaces --format json
```

El formato del informe resultante coincide con el de `kubescan scan`, tanto en la variante de texto como en la variante JSON, y difiere únicamente en la cabecera: el campo `Cluster` toma por defecto el *namespace* consultado y el campo `Path` apunta al directorio temporal en el que se vuelca el estado del clúster. Por esa razón no se reproduce aquí una transcripción independiente, cuyos valores dependerían del clúster concreto sobre el que se ejecute. La verificación funcional de ambos comandos sobre un clúster en ejecución se documenta en la Sección 6.8.

Este comando requiere `kubectl` configurado con permisos de lectura sobre *workloads* y recursos RBAC en el clúster objetivo.

B.3. Reproducción del pipeline de investigación

El pipeline de entrenamiento se ejecuta mediante los objetivos definidos en el `Makefile` de la raíz del repositorio. Los pasos de adquisición y extracción (`research/scripts/01_acquire/`, con `download_github_manifests.py` e `ingest_attack_repos.py`; y `research/scripts/02_extract/`, con `extract_yaml_features.py` y `build_graphs.py`) son intensivos en red y no están automatizados en el `Makefile`; se ejecutan manualmente una única vez y producen los grafos de clúster en `research/data/graphs/*.npz`.

A partir de ahí, el resto del pipeline es reproducible con dos objetivos:

```
make data          # aumentacion -> cache de grafos -> splits group-aware
make reproduce     # data -> RF -> GAT (5-fold) -> ensemble GA -> eval en test
```

El objetivo reproduce encadena, en orden, `train_rf.py`, `train_gnn.py` (5-fold, 300 épocas, `hidden=64`, `heads=4`, `layers=3`, entropía cruzada ponderada y selección de *checkpoint* por Precisión@5 mediante `--select-by p5`), `run_ga_ensemble.py` (ajuste sobre predicciones *out-of-fold*, `--oof`) y `evaluate_test_set.py` (evaluación con la restricción de viabilidad estructural de la Sección 5.6.1), todos con semilla fija (`--seed 42` por defecto), y finaliza generando `research/models/checkpoints/run_manifest.json` con la procedencia de la ejecución. Las variables `GNN_FOCAL` y `GNN_SELECT_BY` del `Makefile` permiten reproducir las ramas de la ablación de la Sección 6.3.4, y el cuaderno parametrizado `research/notebooks/colab_reproduce.ipynb` ofrece la misma cadena para entornos *Google Colab* con GPU. El objetivo `reproduce-ablations` reentrena las variantes de arquitectura reportadas en la Tabla 14 (GAT de 2 capas y GCN de 3 capas) con la misma configuración de pérdida y selección que el modelo desplegado.

Anexo C. Acrónimos y abreviaturas

API	Application Programming Interface (Interfaz de Programación de Aplicaciones)
AUC	Area Under the Curve (Área Bajo la Curva ROC)
BFS	Breadth-First Search (Búsqueda en Anchura)
CI/CD	Continuous Integration / Continuous Delivery (Integración y Entrega Continua)
CIS	Center for Internet Security (Centro para la Seguridad en Internet)
CISA	Cybersecurity and Infrastructure Security Agency (Agencia de Ciberseguridad y Seguridad de Infraestructuras)
CLI	Command-Line Interface (Interfaz de Línea de Comandos)
CNCF	Cloud Native Computing Foundation (Fundación de Computación Nativa en la Nube)
CPU	Central Processing Unit (Unidad Central de Procesamiento)
CTI	Cyber Threat Intelligence (Inteligencia de Amenazas)
CUDA	Compute Unified Device Architecture (Arquitectura Unificada de Dispositivos de Cómputo)
CV	Cross-Validation (Validación Cruzada)
CVE	Common Vulnerabilities and Exposures (Vulnerabilidades y Exposiciones Comunes)
ELU	Exponential Linear Unit (Unidad Lineal Exponencial)
FPR	False Positive Rate (Tasa de Falsos Positivos)
GA	Genetic Algorithm (Algoritmo Genético)
GAT	Graph Attention Network (Red de Atención sobre Grafos)

GCN	Graph Convolutional Network (Red Convolucional de Grafos)
GNN	Graph Neural Network (Red Neuronal de Grafos)
GPU	Graphics Processing Unit (Unidad de Procesamiento Gráfico)
IA	Inteligencia Artificial (Artificial Intelligence)
IaC	Infrastructure as Code (Infraestructura como Código)
IDS	Intrusion Detection System (Sistema de Detección de Intrusiones)
IoT	Internet of Things (Internet de las Cosas)
JSON	JavaScript Object Notation (Notación de Objetos de JavaScript)
LLM	Large Language Model (Modelo de Lenguaje de Gran Escala)
ML	Machine Learning (Aprendizaje Automático)
MLP	Multi-Layer Perceptron (Perceptrón Multicapa)
MPS	Metal Performance Shaders (Motor de Cómputo Acelerado de Apple)
NSA	National Security Agency (Agencia de Seguridad Nacional)
OOF	Out-of-Fold (Predicciones Fuera del Pliegue de Entrenamiento)
QA	Quality Assurance (Aseguramiento de la Calidad)
RBAC	Role-Based Access Control (Control de Acceso Basado en Roles)
RBF	Radial Basis Function (Función de Base Radial)
ReLU	Rectified Linear Unit (Unidad Lineal Rectificada)
RF	Random Forest (Bosque Aleatorio)
ROC	Receiver Operating Characteristic (Característica Operativa del Receptor)
SA	Service Account (Cuenta de Servicio de Kubernetes)

- SMOTE** Synthetic Minority Over-sampling Technique (Técnica de Sobremuestreo Sintético de la Clase Minoritaria)
- SRE** Site Reliability Engineering (Ingeniería de Fiabilidad de Sistemas)
- SUS** System Usability Scale (Escala de Usabilidad del Sistema)
- SVM** Support Vector Machine (Máquina de Vectores Soporte)
- TFE** Trabajo Fin de Estudios
- UMI** Unified Misconfiguration Index (Índice Unificado de Configuraciones Erróneas)
- UNIR** Universidad Internacional de La Rioja
- UNSW** University of New South Wales (Universidad de Nueva Gales del Sur)
- YAML** YAML Ain't Markup Language (Lenguaje de Serialización de Datos Legible por Humanos)